

Tài Liệu Ôn Tập Toàn Diện: Toán Cho Tin Học

Hệ thống lý thuyết, Công thức & Bài tập số học giải mẫu chi tiết

Ngày 30 tháng 5 năm 2026

Mục lục

1	Đại Số Tuyến Tính (Linear Algebra)	3
1.1	Ký Pháp và Khái Niệm Cơ Bản	3
1.2	Các Phép Nhân Vectơ và Ma Trận	3
1.2.1	Tích trong của hai vectơ (Inner Product / Dot Product)	3
1.2.2	Tích ngoài của hai vectơ (Outer Product)	3
1.2.3	Tích ma trận và vectơ (Matrix-Vector Product)	4
1.2.4	Tích vectơ và ma trận (Vector-Matrix Product)	4
1.2.5	Tích ma trận với ma trận (Matrix-Matrix Product)	4
1.3	Các Ma Trận Đặc Biệt và Phép Biến Đổi	4
1.3.1	Ma trận đơn vị và Ma trận đường chéo	4
1.3.2	Phép chuyển vị và Phân tích đối xứng	5
1.3.3	Vết của ma trận (Trace)	5
1.3.4	Ma Trận Nghịch Đảo (Matrix Inverse)	5
1.3.5	Ma Trận Trực Giao (Orthogonal Matrix)	5
1.4	Các Loại Chuẩn (Norms)	5
1.4.1	Chuẩn của vectơ	5
1.4.2	Chuẩn của ma trận (Chuẩn Frobenius)	6
1.5	Hạng, Không Gian Con và Phép Chiếu	6
1.5.1	Hạng của ma trận (Rank)	6
1.5.2	Không gian cột (Range) và Không gian hạt nhân (Nullspace)	6
1.5.3	Phép chiếu lên không gian cột (Projection)	6
1.6	Định Thức và Dạng Toàn Phương	6
1.6.1	Định thức ma trận vuông	6
1.6.2	Dạng Toàn Phương (Quadratic Forms)	7
1.6.3	Tính Xác Định Dương và Tiêu Chuẩn Sylvester	7
1.6.4	Ma Trận Gram ($A^T A$)	7
1.7	Trị Riêng và Vectơ Riêng (Eigenvalues & Eigenvectors)	7
1.8	Giải Tích Ma Trận (Matrix Calculus)	7
2	Tối Ưu Hóa (Optimization)	8
2.1	Tối Ưu Hóa Không Ràng Buộc (Unconstrained Optimization)	8
2.1.1	Hàm một biến và Thuật toán Tìm kiếm tỷ lệ vàng	8

2.1.2	Thuật Toán Tìm kiếm Nhị phân (Binary Search) giải phương trình $f'(x) = 0$	9
2.1.3	Bài toán mẫu: Tìm cực trị hàm nhiều biến tự do	9
2.2	Tính Lồi Lõm (Convexity) và Cực Trị Toàn Cục	10
2.2.1	Định nghĩa lý thuyết	10
2.2.2	Tính chất cực trị toàn cục	10
2.3	Tối Ưu Hóa Có Ràng Buộc Bằng Nhau (Lagrange Multipliers)	10
2.4	Điều Kiện Karush-Kuhn-Tucker (KKT) Cho Ràng Buộc Bất Đẳng Thức	11
2.5	Tính Đối Ngẫu (Duality) trong Tối Ưu Hóa	11
2.5.1	Bài toán gốc và Bài toán đối ngẫu	11
2.5.2	Tính đối ngẫu yếu và đối ngẫu mạnh	11
3	Ứng Dụng Trong Học Máy (Machine Learning)	12
3.1	Bài Toán Bình Phương Nhỏ Nhất (Least Squares)	12
3.2	Phân Rã Giá Trị Kỳ Dị (Singular Value Decomposition - SVD)	12
3.3	Phân Tích Ngữ Nghĩa Tiềm Ẩn (Latent Semantic Analysis - LSA)	13
3.4	Toán Học Của Hồi Quy Tuyến Tính Bằng Gradient Descent	13
3.5	Thuật Toán Phân Tích Thành Phần Chính (PCA)	14
3.6	Máy Học Vectơ Hỗ Trợ (SVM, Proximal SVM & Giải thuật SMO)	15
3.6.1	Mô hình SVM chuẩn và mô hình Proximal SVM	15
3.6.2	Giải thuật SMO (Sequential Minimal Optimization) tối ưu hóa SVM	16
4	Bảng Tổng Hợp Công Thức Nhanh (Cheat Sheet)	17

1 Đại Số Tuyến Tính (Linear Algebra)

1.1 Ký Pháp và Khái Niệm Cơ Bản

Trong các bài toán Tin học và Học máy, các ký pháp cơ bản được quy ước như sau:

- $A \in \mathbb{R}^{m \times n}$: Ma trận kích thước m hàng và n cột, các phần tử của A là số thực. Phần tử ở hàng i , cột j ký hiệu là a_{ij} hoặc A_{ij} .
- $x \in \mathbb{R}^n$: Vectơ cột gồm n phần tử. Phần tử thứ i của vectơ x được ký hiệu là x_i .
- Vectơ hàng được ký hiệu thông qua phép chuyển vị (transpose): $x^T = [x_1, x_2, \dots, x_n]$.
- Ma trận đơn vị $I \in \mathbb{R}^{n \times n}$ là ma trận vuông có các phần tử trên đường chéo bằng 1, các phần tử khác bằng 0:

$$I_{ij} = \begin{cases} 1 & \text{nếu } i = j \\ 0 & \text{nếu } i \neq j \end{cases}$$

1.2 Các Phép Nhân Vectơ và Ma Trận

1.2.1 Tích trong của hai vectơ (Inner Product / Dot Product)

Cho hai vectơ $x, y \in \mathbb{R}^n$. Tích trong của chúng là một số thực, ký hiệu là $x^T y$, được tính bằng:

$$x^T y = \sum_{i=1}^n x_i y_i = y^T x$$

Ví dụ số học mẫu: Cho $x = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$ và $y = \begin{pmatrix} 4 \\ 5 \\ 6 \end{pmatrix}$. Tích trong của x và y là:

$$x^T y = 1(4) + 2(5) + 3(6) = 4 + 10 + 18 = 32$$

1.2.2 Tích ngoài của hai vectơ (Outer Product)

Cho hai vectơ $x \in \mathbb{R}^m$ và $y \in \mathbb{R}^n$. Tích ngoài của chúng là một ma trận kích thước $m \times n$, ký hiệu là xy^T , được tính bằng:

$$(xy^T)_{ij} = x_i y_j \implies xy^T = \begin{pmatrix} x_1 y_1 & x_1 y_2 & \dots & x_1 y_n \\ x_2 y_1 & x_2 y_2 & \dots & x_2 y_n \\ \vdots & \vdots & \ddots & \vdots \\ x_m y_1 & x_m y_2 & \dots & x_m y_n \end{pmatrix}$$

Ví dụ số học mẫu: Cho $x = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$ và $y = \begin{pmatrix} 4 \\ 5 \end{pmatrix}$. Tích ngoài xy^T là:

$$xy^T = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} \begin{pmatrix} 4 & 5 \end{pmatrix} = \begin{pmatrix} 1(4) & 1(5) \\ 2(4) & 2(5) \\ 3(4) & 3(5) \end{pmatrix} = \begin{pmatrix} 4 & 5 \\ 8 & 10 \\ 12 & 15 \end{pmatrix}$$

1.2.3 Tích ma trận và vectơ (Matrix-Vector Product)

Cho ma trận $A \in \mathbb{R}^{m \times n}$ gồm các cột $a_1, a_2, \dots, a_n \in \mathbb{R}^m$ và vectơ $x \in \mathbb{R}^n$. Tích $y = Ax \in \mathbb{R}^m$ có thể biểu diễn dưới dạng tổ hợp tuyến tính của các cột của A :

$$y = Ax = \sum_{j=1}^n x_j a_j$$

Ví dụ số học mẫu: Cho $A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$ và $x = \begin{pmatrix} 5 \\ 6 \end{pmatrix}$. Ta tính Ax bằng cách tổ hợp tuyến tính cột:

$$Ax = 5 \begin{pmatrix} 1 \\ 3 \end{pmatrix} + 6 \begin{pmatrix} 2 \\ 4 \end{pmatrix} = \begin{pmatrix} 5(1) + 6(2) \\ 5(3) + 6(4) \end{pmatrix} = \begin{pmatrix} 17 \\ 39 \end{pmatrix}$$

1.2.4 Tích vectơ và ma trận (Vector-Matrix Product)

Cho ma trận $A \in \mathbb{R}^{m \times n}$ gồm các dòng $a_1^T, a_2^T, \dots, a_m^T \in \mathbb{R}^n$ và vectơ $x \in \mathbb{R}^m$. Tích $y^T = x^T A \in \mathbb{R}^n$ có thể biểu diễn dưới dạng tổ hợp tuyến tính của các dòng của A :

$$y^T = x^T A = \sum_{i=1}^m x_i a_i^T$$

Ví dụ số học mẫu: Cho $A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$ có các dòng $a_1^T = [1, 2]$, $a_2^T = [3, 4]$ và vectơ $x = \begin{pmatrix} 2 \\ 3 \end{pmatrix}$. Ta tính $x^T A$ dưới dạng tổ hợp dòng:

$$x^T A = 2 \begin{pmatrix} 1 & 2 \end{pmatrix} + 3 \begin{pmatrix} 3 & 4 \end{pmatrix} = \begin{pmatrix} 2(1) + 3(3) & 2(2) + 3(4) \end{pmatrix} = \begin{pmatrix} 11 & 16 \end{pmatrix}$$

1.2.5 Tích ma trận với ma trận (Matrix-Matrix Product)

Cho hai ma trận $A \in \mathbb{R}^{m \times n}$ và $B \in \mathbb{R}^{n \times p}$. Tích của chúng là ma trận $C = AB \in \mathbb{R}^{m \times p}$, với phần tử C_{ij} được tính bằng:

$$C_{ij} = \sum_{k=1}^n A_{ik} B_{kj}$$

Cách biểu diễn khác (Tổng các tích ngoài - Sum of Outer Products): Tích ma trận AB có thể được viết dưới dạng tổng tích ngoài của các cột của A và các dòng của B :

$$AB = \sum_{i=1}^n a_i b_i^T$$

Trong đó a_i là cột thứ i của A , và b_i^T là dòng thứ i của B .

1.3 Các Ma Trận Đặc Biệt và Phép Biến Đổi

1.3.1 Ma trận đơn vị và Ma trận đường chéo

- Ma trận đơn vị I : Thỏa mãn $AI = A = IA$ với mọi ma trận A .
- Ma trận đường chéo $D = \text{diag}(d_1, d_2, \dots, d_n)$: Ma trận vuông có tất cả các phần tử nằm ngoài đường chéo chính bằng 0.

1.3.2 Phép chuyển vị và Phân tích đối xứng

Phép chuyển vị đổi các hàng của ma trận thành các cột. Các tính chất quan trọng:

$$(A^T)^T = A, \quad (AB)^T = B^T A^T, \quad (A + B)^T = A^T + B^T$$

Mọi ma trận vuông $A \in \mathbb{R}^{n \times n}$ bất kỳ đều có thể phân tích duy nhất thành tổng của một ma trận đối xứng ($A_{\text{sym}} = A_{\text{sym}}^T$) và một ma trận phản đối xứng ($A_{\text{asym}} = -A_{\text{asym}}^T$):

$$A = \frac{1}{2}(A + A^T) + \frac{1}{2}(A - A^T) = A_{\text{sym}} + A_{\text{asym}}$$

1.3.3 Vết của ma trận (Trace)

Vết của ma trận vuông $A \in \mathbb{R}^{n \times n}$ là tổng các phần tử trên đường chéo chính:

$$\text{tr}(A) = \sum_{i=1}^n A_{ii}$$

1.3.4 Ma Trận Nghịch Đảo (Matrix Inverse)

Nghịch đảo của một ma trận vuông $A \in \mathbb{R}^{n \times n}$ ký hiệu là A^{-1} , là ma trận duy nhất thỏa mãn:

$$AA^{-1} = I = A^{-1}A$$

- Ma trận A được gọi là khả đảo (invertible / non-singular) nếu tồn tại A^{-1} . Điều kiện cần và đủ để A khả đảo là A có hạng đầy đủ ($\text{rank}(A) = n$), tương đương định thức $\det(A) \neq 0$.
- Ngược lại, nếu không tồn tại A^{-1} , ma trận được gọi là bất khả đảo (singular).

1.3.5 Ma Trận Trực Giao (Orthogonal Matrix)

Ma trận vuông $U \in \mathbb{R}^{n \times n}$ được gọi là trực giao nếu tất cả các cột của nó trực giao với nhau và đều được chuẩn hóa (độ dài bằng 1):

$$U^T U = I = U U^T \implies U^{-1} = U^T$$

1.4 Các Loại Chuẩn (Norms)

1.4.1 Chuẩn của vectơ

Chuẩn đo lường độ lớn (chiều dài) của vectơ $x \in \mathbb{R}^n$:

- **Chuẩn L_1 :** $\|x\|_1 = \sum_{i=1}^n |x_i|$
- **Chuẩn L_2 (chuẩn Euclid):** $\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{x^T x}$
- **Chuẩn L_∞ :** $\|x\|_\infty = \max_i |x_i|$
- **Chuẩn L_p tổng quát:** $\|x\|_p = (\sum_{i=1}^n |x_i|^p)^{1/p}$

1.4.2 Chuẩn của ma trận (Chuẩn Frobenius)

Chuẩn Frobenius đo độ lớn của ma trận vuông hoặc chữ nhật $A \in \mathbb{R}^{m \times n}$:

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n A_{ij}^2} = \sqrt{\text{tr}(A^T A)}$$

1.5 Hạng, Không Gian Con và Phép Chiếu

1.5.1 Hạng của ma trận (Rank)

Hạng của ma trận ký hiệu là $\text{rank}(A)$. Tính chất: $\text{rank}(A) \leq \min(m, n)$. Nếu $\text{rank}(A) = \min(m, n)$, ma trận có hạng đầy đủ (full rank).

1.5.2 Không gian cột (Range) và Không gian hạt nhân (Nullspace)

Cho ma trận $A \in \mathbb{R}^{m \times n}$:

- **Không gian cột (Range / Columnspace)** ký hiệu là $\mathcal{R}(A)$, là không gian con được sinh bởi các cột của A :

$$\mathcal{R}(A) = \{v \in \mathbb{R}^m : v = Ax, x \in \mathbb{R}^n\}$$

- **Không gian hạt nhân (Nullspace / Kernel)** ký hiệu là $\mathcal{N}(A)$, là tập hợp các vectơ x sao cho tích với A bằng vectơ không:

$$\mathcal{N}(A) = \{x \in \mathbb{R}^n : Ax = 0\}$$

1.5.3 Phép chiếu lên không gian cột (Projection)

Cho ma trận $A \in \mathbb{R}^{m \times n}$ có hạng đầy đủ và vectơ $y \in \mathbb{R}^m$. Hình chiếu vuông góc của y lên không gian cột $\mathcal{R}(A)$ là:

$$\text{Proj}(y; A) = A(A^T A)^{-1} A^T y$$

Nếu A chỉ gồm một cột duy nhất $a \in \mathbb{R}^m$, phép chiếu điểm lên đường thẳng có công thức đặc biệt:

$$\text{Proj}(y; a) = \frac{aa^T}{a^T a} y$$

1.6 Định Thức và Dạng Toàn Phương

1.6.1 Định thức ma trận vuông

Định thức của ma trận vuông $A \in \mathbb{R}^{n \times n}$ ký hiệu là $|A|$ hoặc $\det(A)$. **Công thức khai triển Laplace (Cofactor Expansion)** theo hàng i :

$$\det(A) = \sum_{j=1}^n (-1)^{i+j} a_{ij} \det(A_{\setminus i, \setminus j})$$

1.6.2 Dạng Toàn Phương (Quadratic Forms)

Cho ma trận vuông đối xứng $A \in \mathbb{R}^{n \times n}$ và vectơ $x \in \mathbb{R}^n$. Biểu thức có dạng:

$$x^T A x = \sum_{i=1}^n \sum_{j=1}^n A_{ij} x_i x_j$$

1.6.3 Tính Xác Định Dương và Tiêu Chuẩn Sylvester

- Ma trận đối xứng A được gọi là **xác định dương** nếu với mọi vectơ $x \neq 0$: $x^T A x > 0$.
- **Tiêu chuẩn Sylvester:** Ma trận đối xứng A xác định dương $\iff$ tất cả các định thức con chính đều dương: $\det(A_i) > 0, \forall i = 1, \dots, n$.

1.6.4 Ma Trận Gram ($A^T A$)

Cho ma trận $A \in \mathbb{R}^{m \times n}$ bất kỳ. Ma trận $G = A^T A \in \mathbb{R}^{n \times n}$ được gọi là ma trận Gram.

- Ma trận Gram $G = A^T A$ luôn đối xứng và ****nửa xác định dương**** ($G \succeq 0$).
- Nếu $m \geq n$ và A có hạng đầy đủ ($\text{rank}(A) = n$), ma trận Gram $G = A^T A$ là ma trận ****xác định dương**** ($G \succ 0$).

1.7 Trị Riêng và Vectơ Riêng (Eigenvalues & Eigenvectors)

Cho ma trận vuông $A \in \mathbb{R}^{n \times n}$. Nếu tồn tại số phức $\lambda \in \mathbb{C}$ và vectơ khác không $x \in \mathbb{C}^n$ sao cho: $Ax = \lambda x, x \neq 0$. Ta giải phương trình đặc trưng: $\det(\lambda I - A) = 0$.

Định lý cực đại cực tiểu (Rayleigh Quotient): Nếu A là ma trận đối xứng, khi đó:

$$\max_{\|x\|_2=1} x^T A x = \lambda_{\max}(A), \quad \min_{\|x\|_2=1} x^T A x = \lambda_{\min}(A)$$

1.8 Giải Tích Ma Trận (Matrix Calculus)

Gradient $\nabla_x f(x) \in \mathbb{R}^n$ và Hessian $\nabla_x^2 f(x) \in \mathbb{R}^{n \times n}$ có các công thức đạo hàm trọng tâm:

$$\nabla_x (b^T x) = b, \quad \nabla_x (x^T A x) = 2Ax, \quad \nabla_x^2 (x^T A x) = 2A \quad (\text{với } A \text{ đối xứng})$$

2 Tối Ưu Hóa (Optimization)

2.1 Tối Ưu Hóa Không Ràng Buộc (Unconstrained Optimization)

2.1.1 Hàm một biến và Thuật toán Tìm kiếm tỷ lệ vàng

Để tìm cực đại của hàm một biến $f(x)$ trên đoạn $[a, b]$, ta sử dụng thuật toán Tìm kiếm tỷ lệ vàng nhằm thu hẹp khoảng tìm kiếm một cách nhanh nhất.

- Định nghĩa hằng số tỷ lệ vàng: $r = \frac{\sqrt{5}-1}{2} \approx 0.618034$
- Chọn hai điểm c và d trong đoạn $[a, b]$:

$$c = a + r(b - a), \quad d = b + r(a - b) \quad (\text{với } a < d < c < b)$$

Ví dụ số học minh họa: Tìm cực đại của hàm số $f(x) = -x^2 + 4x$ trên khoảng $[0, 3]$ trong 2 bước lặp đầu tiên. **Lời giải chi tiết:**

- **Khởi tạo:** $a = 0, b = 3, r \approx 0.618$.
- **Tính toán hai điểm trong:**

$$\begin{aligned} c &= a + r(b - a) = 0 + 0.618(3 - 0) = 1.854 \\ d &= b + r(a - b) = 3 + 0.618(0 - 3) = 1.146 \end{aligned}$$

- **Bước lặp 1:** Tính giá trị hàm số:

$$\begin{aligned} f(c) &= f(1.854) = -(1.854)^2 + 4(1.854) \approx 3.979 \\ f(d) &= f(1.146) = -(1.146)^2 + 4(1.146) \approx 3.271 \end{aligned}$$

Vì $f(c) > f(d)$, cực đại nằm trong khoảng $[d, b] = [1.146, 3]$. Ta gán biên trái mới: $a \leftarrow d = 1.146$.

- **Bước lặp 2:** Khoảng mới $[1.146, 3]$. Tính toán điểm mới:

$$\begin{aligned} c_{\text{mới}} &= 1.146 + 0.618(3 - 1.146) \approx 2.292 \\ d_{\text{mới}} &= 1.854 \quad (\text{Tận dụng lại điểm cũ để giảm chi phí tính toán}) \end{aligned}$$

Tính giá trị hàm số:

$$\begin{aligned} f(c_{\text{mới}}) &= f(2.292) \approx 3.915 \\ f(d_{\text{mới}}) &= f(1.854) \approx 3.979 \end{aligned}$$

Vì $f(c_{\text{mới}}) < f(d_{\text{mới}})$, khoảng cực đại thu hẹp về $[a, c_{\text{mới}}] = [1.146, 2.292]$.

2.1.2 Thuật Toán Tìm kiếm Nhị phân (Binary Search) giải phương trình $f'(x) = 0$

Khi đạo hàm $f'(x)$ liên tục và có tính đơn điệu, ta có thể dùng thuật toán chia đôi để tìm điểm dừng cực đại của $f(x)$ (thỏa mãn $f'(x) = 0$):

- **Điều kiện áp dụng:** Tồn tại hai điểm a và b sao cho $f'(a) > 0$ (hàm đang đồng biến) và $f'(b) < 0$ (hàm đang nghịch biến).

Ví dụ số học minh họa: Tìm điểm dừng của hàm $f(x) = -x^2 + 4x$ trên khoảng $[0, 3]$ bằng thuật toán Tìm kiếm Nhị phân trong 2 bước lặp. Ta có đạo hàm $f'(x) = -2x + 4$.
Lời giải chi tiết:

- **Khởi tạo:** $a = 0 \implies f'(0) = 4 > 0$. $b = 3 \implies f'(3) = -2 < 0$. Điều kiện thỏa mãn.
- **Bước lặp 1:** Tính trung điểm:

$$m = \frac{a+b}{2} = \frac{0+3}{2} = 1.5$$

Đạo hàm tại m : $f'(1.5) = -2(1.5) + 4 = 1 > 0$. Vì $f'(1.5) > 0$, cực đại nằm ở khoảng bên phải $[1.5, 3]$. Ta gán $a \leftarrow m = 1.5$.

- **Bước lặp 2:** Khoảng mới $[1.5, 3]$. Tính trung điểm mới:

$$m_{\text{mới}} = \frac{1.5+3}{2} = 2.25$$

Đạo hàm tại $m_{\text{mới}}$: $f'(2.25) = -2(2.25) + 4 = -0.5 < 0$. Vì $f'(2.25) < 0$, cực đại nằm ở khoảng bên trái $[1.5, 2.25]$. Ta gán $b \leftarrow m_{\text{mới}} = 2.25$.

2.1.3 Bài toán mẫu: Tìm cực trị hàm nhiều biến tự do

Tìm cực trị của hàm số sau:

$$f(x_1, x_2) = x_1^3 + x_2^3 - 3x_1x_2$$

Lời giải chi tiết:

1. **Tìm các điểm dừng ($\nabla f(x) = 0$):**

$$\nabla f(x_1, x_2) = \begin{pmatrix} 3x_1^2 - 3x_2 \\ 3x_2^2 - 3x_1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies x_2 = x_1^2 \text{ và } x_1 = x_2^2$$

Giải hệ phương trình ta được hai điểm dừng: $M_1(0, 0)$ và $M_2(1, 1)$.

2. **Xây dựng ma trận Hessian:**

$$H(x_1, x_2) = \begin{pmatrix} 6x_1 & -3 \\ -3 & 6x_2 \end{pmatrix}$$

3. **Kiểm tra tại từng điểm dừng:**

- **Tại điểm** $M_1(0, 0)$:

$$H(0, 0) = \begin{pmatrix} 0 & -3 \\ -3 & 0 \end{pmatrix} \implies \det(H) = -9 < 0 \implies \text{Điểm yên ngựa.}$$

- **Tại điểm** $M_2(1, 1)$:

$$H(1, 1) = \begin{pmatrix} 6 & -3 \\ -3 & 6 \end{pmatrix} \implies \det(H_1) = 6 > 0, \det(H) = 27 > 0 \implies \text{Cực tiểu cục bộ.}$$

2.2 Tính Lồi Lõm (Convexity) và Cực Trị Toàn Cục

2.2.1 Định nghĩa lý thuyết

- Hàm số $f(x)$ được gọi là **hàm lồi (convex function)** nếu đoạn thẳng nối bất kỳ hai điểm trên đồ thị luôn nằm trên hoặc trùng với đồ thị của hàm số đó:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y), \quad \forall \alpha \in (0, 1)$$

- Hàm số $f(x)$ được gọi là **hàm lõm (concave function)** nếu $-f(x)$ là hàm lồi.
- **Kiểm tra tính lồi lõm bằng đạo hàm cấp 2:**

- $f''(x) \geq 0$ (hoặc ma trận Hessian $H(x) \succeq 0$) $\iff f(x)$ là hàm lồi.
- $f''(x) \leq 0$ (hoặc ma trận Hessian $H(x) \preceq 0$) $\iff f(x)$ là hàm lõm.

2.2.2 Tính chất cực trị toàn cục

- Nếu $f(x)$ là hàm lồi, mọi điểm cực tiểu cục bộ đều là điểm **cực tiểu toàn cục**.
- Nếu $f(x)$ là hàm lõm, mọi điểm cực đại cục bộ đều là điểm **cực đại toàn cục**.

2.3 Tối Ưu Hóa Có Ràng Buộc Bằng Nhau (Lagrange Multipliers)

Xét bài toán: $\min_x f(x)$ thỏa mãn $h_i(x) = b_i, i = 1, \dots, m$. Ta tối ưu hàm Lagrange:

$$L(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i(b_i - h_i(x))$$

Bài toán mẫu: Tìm giá trị cực tiểu của hàm số $f(x_1, x_2) = 2x_1^2 + x_2^2$ với điều kiện $x_1 + x_2 = 1$. **Lời giải chi tiết:**

1. Thiết lập hàm Lagrange: $L(x_1, x_2, \lambda) = 2x_1^2 + x_2^2 + \lambda(1 - x_1 - x_2)$.
2. Đạo hàm riêng và cho bằng 0:

$$\frac{\partial L}{\partial x_1} = 4x_1 - \lambda = 0, \quad \frac{\partial L}{\partial x_2} = 2x_2 - \lambda = 0, \quad \frac{\partial L}{\partial \lambda} = 1 - x_1 - x_2 = 0$$

3. Giải hệ phương trình:

$$x_1 = \frac{\lambda}{4}, \quad x_2 = \frac{\lambda}{2} \implies \frac{\lambda}{4} + \frac{\lambda}{2} = 1 \implies \lambda^* = \frac{4}{3}$$

Ta được nghiệm tối ưu: $x_1^* = \frac{1}{3}, x_2^* = \frac{2}{3}$.

2.4 Điều Kiện Karush-Kuhn-Tucker (KKT) Cho Ràng Buộc Bất Đẳng Thức

Xét bài toán: $\max_x f(x)$ thỏa mãn $g_i(x) \leq d_i, i = 1, \dots, p$. Hàm Lagrange mở rộng: $L(x, \mu) = f(x) + \sum_{i=1}^p \mu_i (d_i - g_i(x))$. Hệ điều kiện KKT:

$$\nabla_x L(x^*, \mu^*) = 0, \quad \mu_j^* (g_j(x^*) - d_j) = 0, \quad \mu_j^* \geq 0, \quad g_j(x^*) \leq d_j \quad (\forall j)$$

2.5 Tính Đối Ngẫu (Duality) trong Tối Ưu Hóa

2.5.1 Bài toán gốc và Bài toán đối ngẫu

Xét bài toán gốc (Primal Problem) dạng cực đại hóa:

$$\max_x f(x) \quad \text{thỏa mãn } h_i(x) = b_i \text{ và } g_j(x) \leq d_j$$

- Định nghĩa hàm đối ngẫu Lagrange (Lagrange Dual Function):

$$\Theta_D(\lambda, \mu) = \max_x L(x, \lambda, \mu)$$

- Bài toán đối ngẫu (Lagrange Dual Problem) là bài toán cực tiểu hóa hàm đối ngẫu:

$$\min_{\lambda, \mu \geq 0} \Theta_D(\lambda, \mu) = \min_{\lambda, \mu \geq 0} \max_x L(x, \lambda, \mu)$$

2.5.2 Tính đối ngẫu yếu và đối ngẫu mạnh

- **Tính đối ngẫu yếu (Weak Duality):** Giá trị tối ưu của bài toán gốc luôn nhỏ hơn hoặc bằng giá trị tối ưu của bài toán đối ngẫu:

$$\max_x \min_{\lambda, \mu \geq 0} L(x, \lambda, \mu) \leq \min_{\lambda, \mu \geq 0} \max_x L(x, \lambda, \mu)$$

- **Tính đối ngẫu mạnh (Strong Duality):** Khi dấu đẳng thức xảy ra. Điều này đạt được khi hàm mục tiêu lồi/lõm và các ràng buộc thỏa mãn **điều kiện Slater** (tồn tại một điểm nằm hoàn toàn trong miền khả thi nghiêm ngặt). Mô hình SVM dựa vào tính chất đối ngẫu mạnh này để chuyển sang bài toán đối ngẫu dễ giải hơn.

3 Ứng Dụng Trong Học Máy (Machine Learning)

3.1 Bài Toán Bình Phương Nhỏ Nhất (Least Squares)

Khi giải hệ phương trình tuyến tính $Ax = b$ dạng $m > n$, ta cực tiểu hóa sai số $\|Ax - b\|_2^2$. Công thức nghiệm giải tích dạng giải tích (Normal Equation) là:

$$x^* = (A^T A)^{-1} A^T b$$

3.2 Phân Rã Giá Trị Kỳ Dị (Singular Value Decomposition - SVD)

Mọi ma trận $A \in \mathbb{R}^{m \times n}$ đều có thể phân rã thành tích của 3 ma trận:

$$A = U S V^T$$

Ví dụ số học minh họa từng bước: Tìm phân rã SVD của ma trận đối xứng sau:

$$A = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$$

Lời giải chi tiết:

1. **Tính ma trận Gram $A^T A$:** Do A đối xứng nên:

$$A^T A = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} = \begin{pmatrix} 5 & 4 \\ 4 & 5 \end{pmatrix}$$

2. **Tìm các trị riêng của $A^T A$:** Giải phương trình đặc trưng $\det(A^T A - \lambda I) = 0$:

$$\det \begin{pmatrix} 5 - \lambda & 4 \\ 4 & 5 - \lambda \end{pmatrix} = (5 - \lambda)^2 - 16 = \lambda^2 - 10\lambda + 9 = 0 \implies \lambda_1 = 9, \lambda_2 = 1$$

3. **Xác định các giá trị kỳ dị và ma trận S :**

$$\sigma_1 = \sqrt{9} = 3, \quad \sigma_2 = \sqrt{1} = 1 \implies S = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}$$

4. **Tìm các vectơ riêng trực chuẩn cho ma trận V :**

- Với $\lambda_1 = 9$: Hệ phương trình $(A^T A - 9I)v_1 = 0 \implies \begin{pmatrix} -4 & 4 \\ 4 & -4 \end{pmatrix} v_1 = 0 \implies$

$$v_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

- Với $\lambda_2 = 1$: Hệ phương trình $(A^T A - I)v_2 = 0 \implies \begin{pmatrix} 4 & 4 \\ 4 & 4 \end{pmatrix} v_2 = 0 \implies v_2 =$

$$\frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix}.$$

Ma trận trực giao: $V = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix}$.

5. **Tìm các vectơ riêng trực chuẩn cho ma trận U :** Sử dụng công thức $u_i = \frac{1}{\sigma_i} A v_i$:

$$u_1 = \frac{1}{3} \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \left[\frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \right] = \frac{1}{3\sqrt{2}} \begin{pmatrix} 3 \\ 3 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$u_2 = \frac{1}{1} \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \left[\frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix} \right] = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

Ma trận trực giao: $U = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$.

Ta có phân rã SVD hoàn chỉnh: $A = U S V^T$.

3.3 Phân Tích Ngữ Nghĩa Tiềm Ẩn (Latent Semantic Analysis - LSA)

LSA áp dụng phân rã SVD rút gọn (Truncated SVD) lên ma trận tài liệu-thuật ngữ (term-document matrix) $D \in \mathbb{R}^{m \times n}$ để tìm mối quan hệ ngữ nghĩa tiềm ẩn giữa các từ và văn bản.

- Giả sử phân rã SVD rút gọn giữ lại k thành phần: $D \approx U_{\text{red}} S_{\text{red}} V_{\text{red}}^T$.
- **Độ tương tự giữa các thuật ngữ (Terms similarity):** Tính qua ma trận Gram dòng của D :

$$D D^T \approx (U_{\text{red}} S_{\text{red}})(U_{\text{red}} S_{\text{red}})^T$$

- **Độ tương tự giữa các tài liệu (Documents similarity):** Tính qua ma trận Gram cột của D :

$$D^T D \approx (V_{\text{red}} S_{\text{red}})(V_{\text{red}} S_{\text{red}})^T$$

- **Chiều tài liệu mới (d_{new}) lên không gian ngữ nghĩa:**

$$z_{\text{new}} = d_{\text{new}}^T U_{\text{red}}$$

- **Chiều thuật ngữ mới (w_{new}) lên không gian ngữ nghĩa:**

$$w_{\text{new}} = d_{\text{new}} V_{\text{red}}$$

3.4 Toán Học Của Hồi Quy Tuyến Tính Bằng Gradient Descent

Trong thực tế với dữ liệu cực lớn, ma trận nghịch đảo $(X^T X)^{-1}$ tốn quá nhiều chi phí tính toán. Ta sử dụng thuật toán tối ưu Gradient Descent để tìm θ .

- **Hàm lỗi (Cost Function):**

$$J(\theta) = \frac{1}{2m} \|X\theta - y\|_2^2 = \frac{1}{2m} (X\theta - y)^T (X\theta - y)$$

- **Gradient của hàm lỗi:** Áp dụng công thức đạo hàm ma trận:

$$\nabla_{\theta} J(\theta) = \frac{1}{m} X^T (X\theta - y)$$

- **Công thức cập nhật tham số (Update Rule):**

$$\theta^{(\text{new})} = \theta^{(\text{old})} - \eta \nabla_{\theta} J(\theta)$$

Ví dụ số học minh họa từng bước: Cho tập dữ liệu có $m = 2$ mẫu, với ma trận thuộc tính và nhãn tương ứng:

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}, \quad y = \begin{pmatrix} 2 \\ 4 \end{pmatrix}$$

Sử dụng hằng số khởi tạo $\theta^{(0)} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$ và tốc độ học $\eta = 0.1$. Tính toán giá trị $\theta^{(1)}$ sau bước lặp cập nhật đầu tiên. **Lời giải chi tiết:**

1. **Tính toán Gradient tại bước 0 ($\theta = \theta^{(0)}$):**

$$\begin{aligned} \nabla_{\theta} J(\theta^{(0)}) &= \frac{1}{m} X^T (X\theta^{(0)} - y) = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}^T \left[\begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \begin{pmatrix} 2 \\ 4 \end{pmatrix} \right] \\ &= \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} -2 \\ -4 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 1(-2) + 1(-4) \\ 1(-2) + 2(-4) \end{pmatrix} = \begin{pmatrix} -3 \\ -5 \end{pmatrix} \end{aligned}$$

2. **Cập nhật bộ tham số $\theta^{(1)}$:**

$$\theta^{(1)} = \theta^{(0)} - \eta \nabla_{\theta} J(\theta^{(0)}) = \begin{pmatrix} 0 \\ 0 \end{pmatrix} - 0.1 \begin{pmatrix} -3 \\ -5 \end{pmatrix} = \begin{pmatrix} 0.3 \\ 0.5 \end{pmatrix}$$

3.5 Thuật Toán Phân Tích Thành Phần Chính (PCA)

PCA tìm không gian chiều mới để tối đa hóa phương sai dữ liệu sau khi chiếu. Quy trình toán học của PCA:

1. Quy tâm dữ liệu (Mean centering): $x^{(i)} \leftarrow x^{(i)} - \mu$.
2. Tính ma trận hiệp phương sai: $C = \frac{1}{m} X^T X$.
3. Tính trị riêng và vectơ riêng của C : Giải $\det(C - \lambda I) = 0$ để tìm các trị riêng λ_i .
4. Sắp xếp trị riêng giảm dần: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$. Giữ lại k vectơ riêng tương ứng để tạo ma trận chiếu U_{reduce} .
5. **Tỉ lệ phương sai được giải thích (Explained Variance Ratio):** Để chọn số lượng thành phần chính k tối ưu, ta chọn k nhỏ nhất sao cho giữ lại được ít nhất 99% (hoặc 95%) phương sai ban đầu:

$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^n \lambda_i} \geq 0.99$$

6. Chiếu dữ liệu sang không gian mới k chiều: $Z = XU_{\text{reduce}}$.

Ví dụ số học minh họa từng bước: Cho tập dữ liệu gồm $m = 2$ mẫu trong không gian 2D, các mẫu đã được quy tâm (trung bình bằng 0):

$$X = \begin{pmatrix} 1 & 2 \\ -1 & -2 \end{pmatrix}$$

Thực hiện giảm chiều dữ liệu từ 2D về 1D bằng thuật toán PCA. **Lời giải chi tiết:**

1. **Tính toán ma trận hiệp phương sai C :**

$$C = \frac{1}{m} X^T X = \frac{1}{2} \begin{pmatrix} 1 & -1 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ -1 & -2 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 2 & 4 \\ 4 & 8 \end{pmatrix} = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}$$

2. **Tìm các trị riêng của C :** Giải phương trình đặc trưng $\det(C - \lambda I) = 0$:

$$\det \begin{pmatrix} 1 - \lambda & 2 \\ 2 & 4 - \lambda \end{pmatrix} = (1 - \lambda)(4 - \lambda) - 4 = \lambda^2 - 5\lambda = 0 \implies \lambda_1 = 5, \lambda_2 = 0$$

3. **Tìm vectơ riêng trực chuẩn của trị riêng lớn nhất $\lambda_1 = 5$:**

$$(C - 5I)u_1 = 0 \implies \begin{pmatrix} -4 & 2 \\ 2 & -1 \end{pmatrix} \begin{pmatrix} u_{11} \\ u_{12} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \implies -4u_{11} + 2u_{12} = 0 \implies u_{12} = 2u_{11}$$

Chọn vectơ riêng chuẩn hóa (độ dài bằng 1):

$$u_1 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

Ma trận chiếu giảm chiều về 1D là: $U_{\text{reduce}} = u_1 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ 2 \end{pmatrix}$.

4. **Chiếu dữ liệu mẫu đầu tiên $x^{(1)} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$ sang không gian 1D:**

$$z^{(1)} = U_{\text{reduce}}^T x^{(1)} = \left[\frac{1}{\sqrt{5}} \begin{pmatrix} 1 & 2 \end{pmatrix} \right] \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \frac{1(1) + 2(2)}{\sqrt{5}} = \frac{5}{\sqrt{5}} = \sqrt{5}$$

3.6 Máy Học Vectơ Hỗ Trợ (SVM, Proximal SVM & Giải thuật SMO)

3.6.1 Mô hình SVM chuẩn và mô hình Proximal SVM

SVM tìm siêu phẳng tách lớp bằng bài toán quy hoạch có ràng buộc:

$$\min_{w, b} \frac{1}{2} \|w\|^2 \quad \text{thỏa mãn } y^{(i)}(w^T x^{(i)} + b) \geq 1, \quad i = 1, \dots, m$$

Mô hình Proximal SVM thay thế ràng buộc bất đẳng thức thành bài toán tối ưu không ràng buộc với sai số bình phương, cho nghiệm giải tích dạng đóng cực kỳ nhanh:

$$u = \left(\frac{1}{c} I + A^T A \right)^{-1} A^T y \quad \left(\text{với } A = [X \quad \mathbf{1}] \text{ và } u = \begin{pmatrix} w \\ b \end{pmatrix} \right)$$

3.6.2 Giải thuật SMO (Sequential Minimal Optimization) tối ưu hóa SVM

SMO là thuật toán cực kỳ hiệu quả để giải bài toán đối ngẫu của SVM:

$$\max_{\alpha} W(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m y^{(i)} y^{(j)} \alpha_i \alpha_j \langle x^{(i)}, x^{(j)} \rangle \quad \text{s.t. } 0 \leq \alpha_i \leq C, \sum_{i=1}^m \alpha_i y^{(i)} = 0$$

- **Tại sao phải chọn tối ưu hai nhân tử cùng lúc?** Do có ràng buộc đẳng thức chặt $\sum_{i=1}^m \alpha_i y^{(i)} = 0$, nếu chỉ chọn thay đổi duy nhất một nhân tử α_i thì ràng buộc này chắc chắn sẽ bị vi phạm. Vì thế, giải thuật SMO bắt buộc phải chọn ngẫu nhiên cặp nhân tử (α_i, α_j) để tối ưu hóa đồng thời tại mỗi bước.
- **Cách thức SMO biến đổi và cập nhật:** Giả sử tối ưu hai nhân tử α_1, α_2 , ta cố định các nhân tử khác. Ràng buộc trở thành:

$$\alpha_1 y^{(1)} + \alpha_2 y^{(2)} = \zeta \quad (\text{với } \zeta \text{ là hằng số})$$

Nhân hai vế với $y^{(1)}$, ta biểu diễn được α_1 qua α_2 :

$$\alpha_1 = (\zeta - \alpha_2 y^{(2)}) y^{(1)}$$

Thế biểu thức này ngược lại vào hàm mục tiêu $W(\alpha)$, lúc này bài toán chỉ còn lại một biến α_2 và trở thành **phương trình bậc hai dạng $a\alpha_2^2 + b\alpha_2 + c$ **. Phương trình này có nghiệm giải tích chính xác cực kỳ nhanh, sau đó nghiệm α_2 được cắt tỉa (clipped) về đoạn $[L, H]$ cho phù hợp với hộp ràng buộc $0 \leq \alpha_2 \leq C$. Từ đó suy ra nghiệm cập nhật của α_1 .

4 Bảng Tổng Hợp Công Thức Nhanh (Cheat Sheet)

Bảng 1: Bảng tổng hợp công thức đạo hàm ma trận và vectơ

Hàm số $f(x)$	Gradient $\nabla_x f(x)$	Hessian $\nabla_x^2 f(x)$
$b^T x$ hoặc $x^T b$	b	$\mathbf{0}$
$x^T A x$ (Tổng quát)	$(A + A^T)x$	$A + A^T$
$x^T A x$ (A đối xứng)	$2Ax$	$2A$

Bảng 2: Bảng so sánh tính chất của ma trận chuyển vị và ma trận nghịch đảo

Ma trận chuyển vị A^T	Ma trận nghịch đảo A^{-1}
$(A^T)^T = A$	$(A^{-1})^{-1} = A$
$(A + B)^T = A^T + B^T$	$(AB)^{-1} = B^{-1}A^{-1}$ (nếu A, B khả đảo)
$(AB)^T = B^T A^T$	$(A^{-1})^T = (A^T)^{-1}$
$(cA)^T = cA^T$ (với $c \in \mathbb{R}$)	$(cA)^{-1} = \frac{1}{c}A^{-1}$ (với $c \neq 0$)

Bảng 3: Bảng tổng hợp các chuẩn vectơ và ma trận thông dụng

Loại Chuẩn	Công thức toán học	Ý nghĩa hình học / Ứng dụng
Chuẩn L_1	$\ x\ _1 = \sum_{i=1}^n x_i $	Đo khoảng cách Manhattan
Chuẩn L_2 (Euclid)	$\ x\ _2 = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{x^T x}$	Đo khoảng cách đường thẳng
Chuẩn L_∞	$\ x\ _\infty = \max_i x_i $	Khoảng cách lớn nhất từng chiều
Chuẩn Frobenius	$\ A\ _F = \sqrt{\sum_{i,j} A_{ij}^2} = \sqrt{\text{tr}(A^T A)}$	Độ lớn tổng thể của ma trận

Bảng 4: Bảng tóm tắt mối quan hệ giữa Trị riêng (λ), Vết (tr) và Định thức ($\det$)

Tính chất	Tính toán qua ma trận A	Tính toán qua Trị riêng λ_i
Tổng giá trị đường chéo	$\text{tr}(A) = \sum_{i=1}^n A_{ii}$	$\text{tr}(A) = \sum_{i=1}^n \lambda_i$
Định thức ma trận	$\det(A) = A $	$\det(A) = \prod_{i=1}^n \lambda_i$
Khả năng nghịch đảo	Khả đảo $\iff \det(A) \neq 0$	Khả đảo $\iff \lambda_i \neq 0, \forall i$
Hạng ma trận	$\text{rank}(A)$	Số lượng trị riêng $\lambda_i \neq 0$