



Khoa Công Nghệ Thông Tin
Trường Đại Học Cần Thơ



Giải thuật gom cụm Clustering algorithms

Đỗ Thanh Nghị
dtnghe@cit.ctu.edu.vn

Cần Thơ
12-02-2019

Nội dung

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển

Nội dung

- **Giới thiệu về clustering**
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển

Clustering

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển

■ gom nhóm

- nature của dữ liệu thường không có nhiều thông tin sẵn có như lớp (nhãn)
- gom nhóm : mô hình gom cụm dữ liệu (không có nhãn) sao cho các dữ liệu cùng nhóm có các tính chất tương tự nhau và dữ liệu của 2 nhóm khác nhau sẽ có các tính chất khác nhau
- có nhiều nhóm giải thuật khác nhau : hierarchical clustering, partitioning, density-based, model-based, etc.
- được sử dụng nhiều : K-Means, Dendrogram, SOM, EM
- được ứng dụng thành công trong hầu hết các lĩnh vực tìm kiếm thông tin, phân tích dữ liệu, etc.

Top 10 DM algorithms (2015)

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển



Here are the algorithms:

- 1. C4.5
- 2. k-means
- 3. Support vector machines
- 4. Apriori
- 5. EM
- 6. PageRank
- 7. AdaBoost
- 8. kNN
- 9. Naive Bayes
- 10. CART

Clustering

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển

■ gom nhóm

- thường dựa trên cơ sở khoảng cách
- nên chuẩn hóa dữ liệu
- khoảng cách được tính theo từng kiểu của dữ liệu : số thực, nhị phân, rời rạc

Kiểu số thực

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển

- khoảng cách *Minkowski*

$$d(i, j) = \sqrt[q]{(|x_{i1} - x_{j1}|^q + |x_{i2} - x_{j2}|^q + \dots + |x_{ip} - x_{jp}|^q)}$$

$i = (x_{i1}, x_{i2}, \dots, x_{ip})$ và $j = (x_{j1}, x_{j2}, \dots, x_{jp})$ là 2 phần tử dữ liệu trong p -dimensional, q là số nguyên dương

- nếu $q = 1$, d là khoảng cách Manhattan
- nếu $q = 2$, d là khoảng cách Euclid
- khoảng cách cosine : $d_{\cos}(i, j) = i^T j / (\|i\| \|j\|)$

Nội dung


- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển

Hierarchical clustering

- bottom up
 - bắt đầu với những clusters chỉ là 1 phần tử
 - ở mỗi bước, merge 2 clusters gần nhau thành 1
 - khoảng cách giữa 2 clusters : 2 điểm gần nhất từ 2 clusters (single linkage), 2 điểm xa nhất từ 2 clusters (complete linkage), hoặc khoảng cách trung bình (average linkage), etc.
- top down
 - bắt đầu với 1 cluster là tất cả dữ liệu
 - tìm 2 clusters con
 - tiếp tục đệ quy trên 2 clusters con
- kết quả sinh ra dendrogram

Hierarchical clustering

- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển



Hierarchical clustering (Single link)

- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển



Hierarchical clustering (Single link)

- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển



Hierarchical clustering (Single link)

- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển




Hierarchical clustering (Single link)

- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển




Hierarchical clustering (Single link)

- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển




Hierarchical clustering (Single link)

- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển




Hierarchical clustering (Single link)

- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển




Hierarchical clustering (Single link)

- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển




Hierarchical clustering (Single link)

- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển




Hierarchical clustering (Single link)

- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển




Hierarchical clustering (Single link)

- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển



Hierarchical clustering (Single link)

- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển



Hierarchical clustering

- Giới thiệu về clustering
- **Hierarchical clustering**
- K-Means
- EM
- Kết luận và hướng phát triển

■ nhận xét

1. giải thuật đơn giản
2. cho kết quả dễ hiểu
3. không cần tham số
4. chạy chậm
5. BIRCH (Zhang et al., 1996) sử dụng cấu trúc index để xử lý dữ liệu lớn

Nội dung


- Giới thiệu về clustering
- Hierarchical clustering
- **K-Means**
- EM
- Kết luận và hướng phát triển

Giải thuật K-Means

- giải thuật
 1. khởi động ngẫu nhiên K tâm (center) của K clusters
 2. mỗi phần tử được gán cho tâm gần nhất với phần tử dựa vào khoảng cách (e.g. khoảng cách Euclid)
 3. cập nhật lại các tâm của K clusters, mỗi tâm là giá trị trung bình (mean) của các phần tử trong cluster của nó
 4. lặp lại bước 2,3 cho đến khi hội tụ


Giải thuật K-Means

- Giới thiệu về clustering
- Hierarchical clustering
- **K-Means**
- EM
- Kết luận và hướng phát triển



Giải thuật K-Means


- Giới thiệu về clustering
- Hierarchical clustering
- **K-Means**
- EM
- Kết luận và hướng phát triển



Giải thuật K-Means


- Giới thiệu về clustering
- Hierarchical clustering
- **K-Means**
- EM
- Kết luận và hướng phát triển

cập nhật lại
tâm của các
cluster (giá trị
trung bình của
các phần tử
trong cluster)



Giải thuật K-Means

- Giới thiệu về clustering
- Hierarchical clustering
- **K-Means**
- EM
- Kết luận và hướng phát triển




Giải thuật K-Means

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển

mỗi phần tử
được gán lại
cho tâm
cluster gần
nhất của nó


có 2 phần tử
thay đổi nhóm



Giải thuật K-Means

- Giới thiệu về clustering
- Hierarchical clustering
- **K-Means**
- EM
- Kết luận và hướng phát triển


cập nhật lại
tâm của các
cluster (giá trị
trung bình của
các phần tử
trong cluster)



Giải thuật K-Means


- Giới thiệu về clustering
- Hierarchical clustering
- **K-Means**
- EM
- Kết luận và hướng phát triển

cập nhật lại
tâm của các
cluster (giá trị
trung bình của
các phần tử
trong cluster)



Giải thuật K-Means

- Giới thiệu về clustering
- Hierarchical clustering
- **K-Means**
- EM
- Kết luận và hướng phát triển



Giải thuật K-Means

■ nhận xét

1. giải thuật đơn giản
2. cho kết quả dễ hiểu
3. cần cho tham số K (số lượng clusters)
4. kết quả phụ thuộc vào việc khởi động ngẫu nhiên K tâm (center) của K clusters : có thể khắc phục bằng cách khởi động lại nhiều lần.
5. khả năng chịu đựng nhiễu không tốt (ảnh hưởng bởi các phần tử outliers) : có thể khắc phục bằng K-Medoids, không sử dụng giá trị trung bình, nhưng sử dụng phần tử ngay giữa

Nội dung

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- **EM**
- Kết luận và hướng phát triển

Expectation maximization (EM)

- tại sao EM?
 - k -Means gán cluster cứng (mỗi phần tử thuộc một cluster)
 - trong thực tế, các clusters có thể chồng chéo lên nhau
 - cần gán mềm (xác suất thuộc cluster)
 - Expectation-Maximization (EM): gán xác suất thuộc cluster của phần tử, Gaussian Mixture Models (GMMs)
 - thực hiện một cách lặp lại ước lượng tham số của mô hình xác suất

Expectation maximization (EM)

- nguyên lý: the EM algorithm consists of two steps
 - Expectation (E-step): given the current estimates of parameters, compute the expected values of the hidden variables (soft cluster assignments),
 - Maximization (M-step): update the model parameters by maximizing the likelihood of the data given these expectations.
 - The process is repeated iteratively until convergence (i.e., when parameter changes become negligible).

Expectation maximization (EM)

■ Step 1: initialize Parameters

For clustering, we typically use a **Gaussian Mixture Model (GMM)**, which assumes that data points are generated from a mixture of **k Gaussian distributions** with unknown parameters.

The parameters to estimate are:

- π_j (mixing coefficients, representing the probability of each cluster).
- μ_j (mean of each Gaussian component).
- Σ_j (covariance matrix of each Gaussian component).

Randomly initialize these parameters or use k-means to get a good starting point.

Expectation maximization (EM)

■ Step 2: expectation step (E-step)

Given the current estimates of π_j, μ_j, Σ_j , compute the probability that each data point x_i belongs to cluster j , using Bayes' theorem:

$$w_{ij} = P(Z_i = j | x_i) = \frac{\pi_j \cdot \mathcal{N}(x_i | \mu_j, \Sigma_j)}{\sum_{l=1}^k \pi_l \cdot \mathcal{N}(x_i | \mu_l, \Sigma_l)}$$

where:

- $\mathcal{N}(x_i | \mu_j, \Sigma_j)$ is the Gaussian probability density function (PDF) for cluster j .
- w_{ij} represents the **soft assignment** of data point x_i to cluster j .

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển

Expectation maximization (EM)

■ Step 3: maximization step (M-step)

Update the parameters π_j, μ_j, Σ_j by maximizing the expected log-likelihood using the new assignments w_{ij} :

Update mixing coefficients

$$\pi_j = \frac{1}{N} \sum_{i=1}^N w_{ij}$$

Update means

$$\mu_j = \frac{\sum_{i=1}^N w_{ij} x_i}{\sum_{i=1}^N w_{ij}}$$

Update covariances

$$\Sigma_j = \frac{\sum_{i=1}^N w_{ij} (x_i - \mu_j)(x_i - \mu_j)^T}{\sum_{i=1}^N w_{ij}}$$

These updates refine the parameters based on the probability assignments computed in the E-step.

Expectation maximization (EM)


- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển

■ Step 4: check convergence

Repeat **E-step** and **M-step** until the parameters converge (i.e., the changes in π_j, μ_j, Σ_j become very small) or the log-likelihood does not significantly improve.


Expectation maximization (EM)

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển




Expectation maximization (EM)

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển




Expectation maximization (EM)

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển




Expectation maximization (EM)

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển




Expectation maximization (EM)

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển




Expectation maximization (EM)

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển




Expectation maximization (EM)

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển




Expectation maximization (EM)

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển




Expectation maximization (EM)

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển




Expectation maximization (EM)

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển



Expectation maximization (EM)

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển



Expectation maximization (EM)

- comments
 - EM algorithm is a powerful approach for clustering when data follows a mixture model
 - it iteratively estimates parameters in the presence of hidden variables, such as cluster memberships
 - EM is widely used in Gaussian Mixture Models (GMMs) for clustering applications in image processing, bioinformatics, and speech recognition

k -means versus EM

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển

Feature	K-Means	EM (GMM)
Cluster Shape	Spherical	Elliptical
Cluster Assignment	Hard	Soft (probabilistic)
Probability Outputs	✗ No	✓ Yes
Speed	✓ Faster	✗ Slower
Handling Uncertainty	✗ No	✓ Yes
Works with Missing Data	✗ No	✓ Yes

Thus, EM is preferable when clusters are not spherical, or when we want probability estimates for cluster membership.

Nội dung

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- **Kết luận và hướng phát triển**


Giải thuật clustering

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển

-
- còn nhiều phương pháp khác
 - density-based : DBSCAN (Ester et al., 1996), OPTICS (Ankerst et al., 1999), DENCLUE (Hinneburg & Keim, 1998)
 - model-based : EM (Expected maximization), SOM (Kohonen, 1995)


Clustering với OPTICS

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển



Clustering 12088 web articles với SOM

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển



Hướng phát triển

- Giới thiệu về clustering
- Hierarchical clustering
- K-Means
- EM
- Kết luận và hướng phát triển

- các kiểu dữ liệu phức tạp
- tăng tốc độ xử lý
- các tham số đầu vào của giải thuật
- diễn dịch kết quả sinh ra
- phương pháp kiểm chứng chất lượng mô hình



Cám ơn !