

k nearest neighbors

1) Giả sử có tập dữ liệu:

X1	X2	Class
0.376000	0.488000	0
0.312000	0.544000	0
0.298000	0.624000	0
0.394000	0.600000	0
0.506000	0.512000	0
0.488000	0.334000	1
0.478000	0.398000	1
0.606000	0.366000	1
0.428000	0.294000	1
0.542000	0.252000	1

- Sử dụng 1NN, 3NN để phân lớp các phần tử sau:

X1	X2	Class
0.550000	0.364000	?
0.558000	0.470000	?
0.456000	0.450000	?
0.450000	0.570000	?

2) Viết chương trình C/C++ (hay Matlab/Octave/R/Python/Java) nhận tham số đầu vào là:

- tên tập dữ liệu huấn luyện
- tên tập dữ liệu kiểm thử
- số láng giềng k

Tập tin dữ liệu có m phần tử và n chiều (thuộc tính), c lớp (nhãn hoặc là $0, 1, \dots, c-1$) có dạng như sau:

```
val_i1_a1 val_i1_a2 ... val_i1_an class_i1
val_i2_a1 val_i2_a2 ... val_i2_an class_i2
...
val_im_a1 val_im_a2 ... val_im_an class_im
```

Chương trình có thể phân lớp tập dữ liệu kiểm tra với thuật toán k láng giềng, in ra kết quả ma trận phân lớp và độ chính xác dự báo tổng thể và của từng lớp.

Sử dụng chương trình để phân lớp các tập dữ liệu sau:

- Iris (**.trn**: trainset, **.tst**: testset)
- Optics (**.trn**: trainset, **.tst**: testset)
- Letter (**.trn**: trainset, **.tst**: testset)
- Face (**.trn**: trainset, **.tst**: testset)
- Fp (**.trn**: trainset, **.tst**: testset)

Download các datasets: <http://www.cit.ctu.edu.vn/~dtngchi/ml/data.tar.gz>

- Thay đổi tham số k để chọn giá trị k có độ chính xác cao nhất
- Nhận xét gì về kết quả
- Đề xuất cải tiến

3) Chứng minh định lý Cover-Hart:

For sufficiently large training set size m , the error rate of the $1NN$ classifier is less than twice the Bayes error rate.