

Họ và tên: Đặng Thành Trung

MSHV: M3725014

Decision trees

Câu 1: Dựng cây quyết định

$$Entropy(S) = - \sum_{i=1}^c p_i \log_2(p_i)$$

$$Entropy(S) = - \left(\frac{9}{14} \log_2 \left(\frac{9}{14} \right) + \frac{5}{14} \log_2 \left(\frac{5}{14} \right) \right) \approx 0.9403$$

➤ Thuộc tính Outlook

$$Entropy(S_{sunny}) = - \left(\frac{2}{5} \log_2 \left(\frac{2}{5} \right) + \frac{3}{5} \log_2 \left(\frac{3}{5} \right) \right) \approx 0.9710$$

$$Entropy(S_{overcast}) = 0$$

$$Entropy(S_{rain}) = - \left(\frac{3}{5} \log_2 \left(\frac{3}{5} \right) + \frac{2}{5} \log_2 \left(\frac{2}{5} \right) \right) \approx 0.9710$$

$$\begin{aligned} Entropy(S, Outlook) &= \frac{5}{14} Entropy(S_{sunny}) + \frac{4}{14} Entropy(S_{overcast}) \\ &\quad + \frac{5}{14} Entropy(S_{rain}) \end{aligned}$$

$$Entropy(S, Outlook) = \frac{5}{14} \times 0.9710 + \frac{4}{14} \times 0 + \frac{5}{14} \times 0.9710 \approx 0.6936$$

$$IG(S, Outlook) = 0.9403 - 0.6936 = 0.2467$$

➤ Thuộc tính Windy

$$Entropy(S_{false}) = - \left(\frac{6}{8} \log_2 \left(\frac{6}{8} \right) + \frac{2}{8} \log_2 \left(\frac{2}{8} \right) \right) \approx 0.8113$$

$$Entropy(S_{true}) = - \left(\frac{3}{6} \log_2 \left(\frac{3}{6} \right) + \frac{3}{6} \log_2 \left(\frac{3}{6} \right) \right) = 1.0000$$

$$Entropy(S, Windy) = \frac{8}{14} \times 0.8113 + \frac{6}{14} \times 1.0000 \approx 0.8922$$

$$IG(S, Windy) = 0.9403 - 0.8922 = 0.0481$$

➤ Thuộc tính Temperature

$$Entropy(S, T = 84.0) = \frac{13}{14} \times \left(-\frac{9}{13} \log_2 \left(\frac{9}{13} \right) - \frac{4}{13} \log_2 \left(\frac{4}{13} \right) \right) + \frac{1}{14} \times 0 \approx 0.8266$$

$$IG(S, Temperature) = 0.9403 - 0.8266 = 0.1137$$

➤ Thuộc tính Humidity

$$\begin{aligned} Entropy(S, T = 82.5) &= \frac{9}{14} \times \left(-\frac{7}{9} \log_2 \left(\frac{7}{9} \right) - \frac{2}{9} \log_2 \left(\frac{2}{9} \right) \right) + \frac{5}{14} \times \left(-\frac{2}{5} \log_2 \left(\frac{2}{5} \right) - \frac{3}{5} \log_2 \left(\frac{3}{5} \right) \right) \\ &\approx 0.8380 \end{aligned}$$

$$IG(S, Humidity) = 0.9403 - 0.8380 = 0.1023$$

Vì thuộc tính Outlook có độ lợi thông tin lớn nhất, ta chọn Outlook làm nút gốc.

Nhánh 1: Outlook = overcast

Outlook=overcast $\Rightarrow$ Play

Nhánh 2: Outlook = sunny

$Entropy(S_{sunny}) \approx 0.9710$

$$IG(S_{sunny}, Humidity \leq 75) = Entropy(S_{sunny}) - \left(\frac{2}{5} \times 0 + \frac{3}{5} \times 0 \right) = 0.9710$$

Nếu $Humidity \leq 75 \Rightarrow$ Play $Humidity \leq 75 \Rightarrow$ Play

Nếu $Humidity > 75 \Rightarrow$ Don't Play $Humidity > 75 \Rightarrow$ Don't Play

Nhánh 3: Outlook = rain

$Entropy(S_{rain}) \approx 0.9710$


$$IG(S_{rain}, Windy) = Entropy(S_{rain}) - \left(\frac{3}{5} \times 0 + \frac{2}{5} \times 0 \right) = 0.9710$$

Nếu $Windy = \text{false} \Rightarrow$ Play $Windy = \text{false} \Rightarrow$ Play

Nếu $Windy = \text{true} \Rightarrow$ Don't Play $Windy = \text{true} \Rightarrow$ Don't Play

Các luật:

1. Outlook=overcast $\Rightarrow$ Class=Play
2. Outlook=sunny $\wedge$ Humidity $\leq 75 \Rightarrow$ Class=Play
3. Outlook=sunny $\wedge$ Humidity $> 75 \Rightarrow$ Class=Don't Play
4. Outlook=rain $\wedge$ Windy=false $\Rightarrow$ Class=Play
5. Outlook=rain $\wedge$ Windy=true $\Rightarrow$ Class=Don't Play



Phân lớp

Outlook	Temperature	Humidity	Windy	Class
overcast	63	70	false	Play
rain	73	90	true	Don't Play
sunny	70	73	true	Don't Play

Câu 2: Cài đặt thuật toán Decision Tree bằng python

Kết quả chạy chương trình của thuật toán Cây quyết định tự viết trên 5 tập dữ liệu được trình bày chi tiết trong các hình. Từ kết quả thực nghiệm, chúng tôi rút ra một số nhận xét và đánh giá sau:

- **Về thời gian thực thi:** Thời gian chạy có sự chênh lệch rõ rệt giữa các tập dữ liệu, phản ánh rõ nét độ phức tạp về số lượng mẫu và số lượng thuộc tính:

- + Với tập Iris, thời gian chạy cực kỳ nhanh (chỉ mất 0.0013 giây) do tập này có kích thước rất nhỏ (150 mẫu, 4 thuộc tính).



- + Với hai tập dữ liệu có số lượng mẫu lớn là Optics và Letter, nhờ áp dụng kỹ thuật lấy mẫu phân vị để giới hạn số lượng ngưỡng phân chia ứng viên thay vì duyệt vét cạn, thời gian chạy được kiểm soát rất tốt (lần lượt là 1.67 giây và 1.55 giây).



- + Ngược lại, tập Face có thời gian chạy lâu nhất (14.64 giây). Nguyên nhân là do tập Face có số lượng thuộc tính rất lớn. Tại mỗi bước đệ quy dựng cây, thuật toán phải duyệt qua toàn bộ số lượng thuộc tính khổng lồ này để tính toán độ lợi thông tin, làm tăng đáng kể khối lượng tính toán.


- **Về độ chính xác:** Thuật toán tự viết cho kết quả phân lớp tương đối khả quan trên các tập dữ liệu, tuy nhiên có sự phân hóa tùy thuộc vào đặc thù cấu trúc nhãn:

- + Độ chính xác đạt mức cao trên tập Iris (94.00%) nhờ các ranh giới phân lớp rõ ràng, và đạt mức tốt trên các tập Face (82.81%), Optics (87.70%), Fp (78.75%).

- + Độ chính xác đạt thấp nhất trên tập Letter (65.84%). Quan sát ma trận nhầm lẫn của tập Letter (kích thước 26 x 26 lớp), nguyên nhân là do tập này có số lượng lớp quá nhiều (26 chữ cái) với các đặc trưng chồng lấn mạnh. Một cây quyết định đơn lẻ có không chế độ sâu tối đa ($\text{max_depth} = 8$) rất khó phân tách triệt để không gian đặc trưng phức tạp này. Kết quả này phản ánh giới hạn của mô hình một cây khi đối mặt với bài toán nhiều lớp, đồng thời mở ra nhu cầu cải thiện bằng các phương pháp tập hợp mô hình ở các câu sau.







- Đề xuất cải tiến:

+ **Áp dụng các kỹ thuật cắt tỉa cây:** Sử dụng phương pháp cắt tỉa trước hoặc cắt tỉa sau để loại bỏ các nhánh cây phụ, không mang lại nhiều thông tin. Việc này giúp kiểm soát kích thước của cây, từ đó giảm thiểu tối đa hiện tượng overfitting và nâng cao khả năng tổng quát hóa của mô hình trên dữ liệu mới.

+ **Sử dụng phương pháp học tập hợp:** Thay thế một cây quyết định đơn lẻ bằng các kỹ thuật tập hợp nhiều cây như Rừng ngẫu nhiên hoặc các mô hình tăng cường. Giải pháp này giúp kết hợp thế mạnh dự báo của nhiều cây quyết định khác nhau, từ đó cải thiện đáng kể độ chính xác phân lớp tổng thể và tăng tính vững vững của mô hình trước các biến động ngẫu nhiên của dữ liệu huấn luyện.

Câu 3: Giải thích vì sao phương pháp tập hợp mô hình có thể cải thiện được kết quả phân lớp của mô hình chỉ có một cây?

Cây quyết định đơn lẻ là một mô hình trực quan nhưng lại có nhược điểm lớn là phương sai cao và dễ rơi vào hiện tượng quá khớp khi cây mọc quá sâu để cố gắng học thuộc lòng dữ liệu huấn luyện. Phương pháp tập hợp mô hình khắc phục nhược điểm này bằng cách kết hợp nhiều cây quyết định lại với nhau dựa trên các cơ chế:

1. Giảm phương sai: Một cây quyết định đơn lẻ rất nhạy cảm với các điểm dữ liệu nhiễu. Phương pháp Bagging huấn luyện nhiều cây độc lập trên các mẫu dữ liệu khác nhau. Khi dự báo, mô hình lấy kết quả bỏ phiếu của số đông hoặc trung bình cộng của tất cả các cây. Điều này giúp giảm các lỗi sai ngẫu nhiên của từng cây riêng lẻ, làm mượt ranh giới quyết định và giúp mô hình hoạt động tốt hơn trên dữ liệu thực tế.

2. Giảm độ chệch: Khác với cơ chế chạy song song của Bagging, phương pháp Boosting huấn luyện các cây quyết định một cách tuần tự. Mỗi cây mới sinh ra sẽ tập trung sửa chữa các lỗi phân lớp sai của cây đứng trước nó bằng cách tăng trọng số của các mẫu bị dự báo sai. Cơ chế này giúp kết hợp một chuỗi các cây quyết định rất đơn giản thành một mô hình tập hợp mạnh, từ đó giảm thiểu độ chệch của hệ thống.

3. Hạn chế hiện tượng đồng loạt sai lỗi: Nếu các cây trong tập hợp quá giống nhau, lỗi hệ thống của chúng sẽ trùng khớp. Random Forest cải tiến Bagging bằng cách chỉ lấy mẫu ngẫu nhiên dữ liệu dòng mà còn ngẫu nhiên lựa chọn một tập con các thuộc tính tại mỗi nút phân chia. Việc này buộc các cây quyết định phải học dữ liệu ở nhiều góc nhìn khác nhau, làm giảm tối đa độ tương quan lỗi giữa các cây riêng lẻ.

4. Nâng cao tính vững bền: Mô hình một cây quyết định đơn lẻ có tính không ổn định cao, nghĩa là chỉ cần dữ liệu huấn luyện thay đổi một chút thì cấu trúc cây sẽ bị thay đổi hoàn toàn. Phương pháp tập hợp giúp trung hòa tính nhạy cảm, làm cho hệ thống dự báo trở nên ổn định và ít bị biến động trước các nhiễu từ dữ liệu huấn luyện.

Câu 4: Viết chương trình sử dụng thư viện sklearn, để huấn luyện các mô hình Bagging, Boosting và Rừng ngẫu nhiên Random forest và thực hiện phân lớp các tập dữ liệu.

BẢNG TỔNG HỢP KẾT QUẢ CÂY QUYẾT ĐỊNH (TỰ VIẾT)		
Tập dữ liệu	Độ chính xác	Thời gian chạy
Iris	94.00%	0.0012 giây
Face	82.81%	13.9079 giây
Optics	87.70%	1.6469 giây
Letter	65.84%	1.5045 giây
Fp	78.75%	1.7648 giây


```

dangthanhtrung@MacBook-Pro-2 src % python3 tap_hop_mo_hinh.py

```

TẬP DỮ LIỆU	MÔ HÌNH	ĐỘ CHÍNH XÁC (ACC)	THỜI GIAN
Iris	Bagging	92.00%	0.0475s
Iris	Boosting (AdaBoost)	94.00%	0.0006s
Iris	Random Forest	92.00%	0.0361s
Optics	Bagging	92.99%	1.5521s
Optics	Boosting (AdaBoost)	96.83%	3.1092s
Optics	Random Forest	97.33%	0.3290s
Letter	Bagging	93.01%	2.4550s
Letter	Boosting (AdaBoost)	96.05%	3.4368s
Letter	Random Forest	95.65%	0.9329s
Face	Bagging	100.00%	45.2488s
Face	Boosting (AdaBoost)	86.46%	0.7864s
Face	Random Forest	100.00%	1.2551s
Fp	Bagging	89.38%	1.4595s
Fp	Boosting (AdaBoost)	76.25%	0.0227s
Fp	Random Forest	96.88%	0.0928s

Nhận xét kết quả thực nghiệm

Dựa trên kết quả thực nghiệm huấn luyện mô hình Cây quyết định tự viết và các phương pháp học tập hợp sử dụng thư viện sklearn trên 5 tập dữ liệu, chúng tôi rút ra các kết luận sau:

Về độ chính xác dự báo: Cải thiện về độ chính xác so với mô hình một cây quyết định đơn lẻ trên hầu hết các tập dữ liệu thực nghiệm:

- Đối với bài toán phân loại phức tạp và nhiều lớp mô hình một cây quyết định tự viết bị giới hạn bởi độ sâu (`max_depth = 8`) nên chỉ đạt độ chính xác là 65.84%. Tuy nhiên, khi áp dụng các mô hình tập hợp, độ chính xác đã đạt 93.01%, Random Forest đạt 95.65% và Boosting với 96.05%.

- Đối với bài toán có không gian đặc trưng lớn, nhiều chiều: Cây quyết định đơn lẻ đạt kết quả khá tốt ở mức 82.81%. Tuy nhiên, hai phương pháp Bagging và Random Forest đã đạt độ chính xác tuyệt đối 100.00%. Điều này chứng tỏ khi làm việc trên không gian nhiều chiều, việc xây dựng tập hợp nhiều cây quyết định kết hợp lấy mẫu

ngẫu nhiên dữ liệu giúp mô hình bao phủ được toàn diện các thuộc tính mà không bị rơi vào hiện tượng overfitting.

- Đối với bài toán quy mô trung bình (tập Optics và Fp): Cây quyết định đơn lẻ đạt độ chính xác lần lượt là 87.70% và 78.75%. Các phương pháp tập hợp tiếp tục thể hiện sự vượt trội, đặc biệt là Random Forest với 97.33% trên tập Optics và 96.88% trên tập Fp.

- Đối với tập dữ liệu nhỏ và đơn giản (tập Iris - 150 mẫu): Cây quyết định đơn lẻ đạt độ chính xác rất cao là 94.00% (tương đương với AdaBoost). Trong khi đó, Bagging và Random Forest đạt kết quả thấp hơn một chút ở mức 92.00%. Hiện tượng này hoàn toàn hợp lý về mặt lý thuyết, bởi vì với tập dữ liệu quá nhỏ, cơ chế lấy mẫu ngẫu nhiên có lặp lại (Bootstrap) của Bagging đôi khi vô tình làm mất đi các mẫu dữ liệu biên quan trọng trong quá trình huấn luyện của một số cây con, làm giảm nhẹ độ chính xác cục bộ.

Về thời gian thực thi

- Thuật toán Cây quyết định tự viết: Nhờ áp dụng kỹ thuật lấy mẫu phân vị để giới hạn số lượng ngưỡng thử nghiệm liên tục, cây tự viết có thời gian chạy rất tốt trên các tập dữ liệu có số mẫu lớn như Optics (1.64 giây) và Letter (1.50 giây). Tuy nhiên, trên tập Face có số chiều đặc trưng cực kỳ lớn, thời gian chạy của cây tự viết bị kéo dài lên đến 13.90 giây do vòng lặp đệ quy phải duyệt tìm điểm chia trên quá nhiều thuộc tính tại mỗi nút cây.

- Thuật toán Random Forest (sklearn): Đây là thuật toán tối ưu nhất về mặt tốc độ khi chạy cực kỳ nhanh trên hầu hết các tập dữ liệu (Optics: 0.32s, Letter: 0.93s, Face: 1.25s, Fp: 0.09s). Có được ưu thế vượt trội này là nhờ cơ chế "Lấy mẫu không gian thuộc tính" (Feature Subspace Sampling) - chỉ chọn ngẫu nhiên một nhóm nhỏ thuộc tính để tìm điểm chia tại mỗi nút thay vì duyệt toàn bộ thuộc tính, kết hợp với khả năng tính toán song song hóa mạnh mẽ của thư viện sklearn.

- Thuật toán Bagging (sklearn): Bagging tốn nhiều thời gian huấn luyện nhất trên tập dữ liệu nhiều chiều như Face (mất đến 45.24 giây). Nguyên nhân là vì mô hình này phải xây dựng đồng thời 100 cây quyết định có độ sâu đầy đủ trên toàn bộ không gian số chiều lớn mà không có cơ chế giới hạn thuộc tính như Random Forest, dẫn đến chi phí tính toán tăng lên rất nhiều lần.

Kết luận chung

- Phương pháp tập hợp mô hình đã mang lại hiệu quả cải thiện độ chính xác phân lớp rõ rệt, đặc biệt đối với các tập dữ liệu phân loại đa lớp phức tạp và dữ liệu có số chiều thuộc tính lớn (như Face).
- Trong ba phương pháp tập hợp thử nghiệm, Random Forest thể hiện vai trò là thuật toán toàn diện và hiệu quả nhất khi vừa đạt độ chính xác nằm trong nhóm dẫn đầu trên mọi tập dữ liệu, vừa sở hữu thời gian thực thi tối ưu nhất nhờ cơ chế lấy mẫu thuộc tính ngẫu nhiên thông minh.