ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG

BÁO CÁO CHUYÊN ĐỀ

TRỰC QUAN HOÁ DỮ LIỆU

Giảng viên hướng dẫn: PGS.TS Đỗ Thanh Nghị
Thành viên: 1. Đặng Thành Trung - M3725014
2. Trần Anh Khoa - M3725005
3. Nguyễn Lê Vĩnh Kỳ - M3725023
4. Ngô Lê Ngọc Anh - M3725015

Cần Thơ, tháng 11 năm 2026

MỤC LỤC

MỞ ĐẦU **1**
1. Lý do thực hiện và mục tiêu 1
2. Công cụ và môi trường 1
3. Bố cục báo cáo 1
CHƯƠNG 1. CƠ SỞ LÝ THUYẾT **2**
1.1. Khái niệm và vai trò 2
1.2. Phân loại kỹ thuật trực quan hoá (theo Keim) 2
1.3. Tiêu chí lựa chọn và đánh giá phương pháp hiển thị 2
CHƯƠNG 2. BÀI TẬP 1: CÁC PHƯƠNG PHÁP HIỂN THỊ DỮ LIỆU **3**
2.1. Yêu cầu của đề 3
2.2. Dữ liệu sử dụng 3
2.3. Chương trình hiển thị 3
2.4. Nguyên lý, ưu nhược điểm và kết quả từng phương pháp 4
2.4.1. Line (biểu đồ đường) 4
2.4.2. Histogram 6
2.4.3. Boxplot (biểu đồ hộp) 8
2.4.4. Pie (biểu đồ tròn) 10
2.4.5. Scatter plot 2D (biểu đồ phân tán) 12
2.4.6. Matrix of scatterplot (ma trận biểu đồ phân tán) 15
2.4.7. Parallel coordinates (toạ độ song song) 18
2.4.8. Starglyph (biểu đồ ngôi sao) 20
2.5. Bảng so sánh tổng hợp các phương pháp 23
2.6. Đánh giá và nhận xét chung theo từng tập dữ liệu 24
2.7. Nhận xét 24
CHƯƠNG 3. BÀI TẬP 2: GIẢI THUẬT HIỂN THỊ TREEMAP VÀ ỨNG DỤNG **25**
3.1. Yêu cầu của đề 25
3.2. Cơ sở lý thuyết về Treemap 25
3.2.1. Ý tưởng 25
3.2.2. Giải thuật chia: slice-and-dice 25
3.2.3. Ứng dụng, ưu và nhược điểm của Treemap 25
3.3. Cài đặt và làm quen phần mềm Treemap 26
3.4. Dữ liệu từ Tổng cục Thống kê và tiền xử lý 27
3.4.1. Chọn và tải dữ liệu 27
3.4.2. Tiền xử lý và chuyển định dạng 27
3.5. Kết quả hiển thị 29
3.5.1. Ba giải thuật trên cùng dữ liệu dân số 29
3.5.2. Thay đổi ánh xạ: tốc độ tăng dân số 2015–2024 32
3.5.3. Bộ dữ liệu thứ hai: sản lượng lương thực có hạt 33
3.6. Phân tích kết quả 33
3.6.1. Dữ liệu dân số (Hình 3.2 đến 3.5) 33
3.6.2. Dữ liệu sản lượng lương thực (Hình 3.6) 34

3.7. Đánh giá.....35
CHƯƠNG 4. BÀI TẬP 3: XÂY DỰNG TRỰC QUAN CÂY QUYẾT ĐỊNH THEO PBC. 36
4.1. Yêu cầu của đề.....36
4.2. Cơ sở lý thuyết: ý tưởng của bài báo PBC.....36
4.2.1. Đặt vấn đề và hạn chế của các phương pháp truyền thống.....36
4.2.2. Giải pháp: Hợp tác hiệu quả giữa con người và máy tính (Human-Computer Cooperation).....36
4.2.3. Kỹ thuật xây dựng trực quan cây quyết định (PBC).....37
4.2.4. Đánh giá hiệu quả và giá trị ứng dụng.....38
4.3. Quy trình và kết quả xây dựng cây quyết định bằng VisualDT.....38
4.3.1. Phần mềm VisualDT.....38
4.3.2. Quy trình thực hiện tổng quát.....39
4.3.3. Kết quả trên từng tập dữ liệu.....40
4.4. Nhận xét và đánh giá.....45
4.4.1. Hiểu dữ liệu qua phương pháp Trực quan hóa Tương tác.....45
4.4.2. Kích thước Cây và Độ chính xác (So sánh với Bài báo PBC).....46
4.4.3. Đánh giá chi phí và phạm vi ứng dụng.....46
4.4.4. Phong cách hợp tác người - máy trong VisualDT.....47
4.4.5. Kết luận Chương.....47
CHƯƠNG 5. BÀI TẬP 4: SỬ DỤNG TREEVIEW.....48
5.1. Yêu cầu của đề.....48
5.2. Cơ sở lý thuyết.....48
5.2.1. Luật quyết định từ cây.....48
5.2.2. Độ đo đánh giá luật.....48
5.2.3. Các kiểu hiển thị (view) cho cây quyết định.....48
5.3. Dữ liệu.....49
5.4. Cài đặt và xây dựng cây bằng TreeView.....50
5.5. Trả lời các câu hỏi của đề.....55
5.5.1. Có bao nhiêu luật quyết định?.....55
5.5.2. Các luật quan trọng và lý do.....56
5.5.3. View hiệu quả nhất để hiển thị cây quyết định.....59
CHƯƠNG 6. TỔNG KẾT.....61
6.1. Tóm tắt kết quả.....61
6.2. Lựa chọn phương pháp trực quan theo nhiệm vụ.....62
6.3. Hạn chế.....62
6.4. Hướng phát triển.....63
TÀI LIỆU THAM KHẢO.....64

DANH MỤC HÌNH

Hình 2.1.	Line trên tập Iris	5
Hình 2.2.	Line trên tập Segment	5
Hình 2.3.	Line trên tập Satellite Image	5
Hình 2.4.	Histogram trên tập Iris	7
Hình 2.5.	Histogram trên tập Segment	7
Hình 2.6.	Histogram trên tập Satellite Image	7
Hình 2.7.	Boxplot trên tập Iris	9
Hình 2.8.	Boxplot trên tập Segment	9
Hình 2.9.	Boxplot trên tập Satellite Image	9
Hình 2.10.	Pie trên tập Iris	11
Hình 2.11.	Pie trên tập Segment	11
Hình 2.12.	Pie trên tập Satellite Image	11
Hình 2.13.	Scatter plot 2D trên tập Iris	13
Hình 2.14.	Scatter plot 2D trên tập Segment	13
Hình 2.15.	Scatter plot 2D trên tập Satellite Image	14
Hình 2.16.	Matrix of scatterplot trên tập Iris	15
Hình 2.17.	Matrix of scatterplot trên tập Segment	16
Hình 2.18.	Matrix of scatterplot trên tập Satellite Image	17
Hình 2.19.	Parallel coordinates trên tập Iris	19
Hình 2.20.	Parallel coordinates trên tập Segment	19
Hình 2.21.	Parallel coordinates trên tập Satellite Image	19
Hình 2.22.	Starglyph trên tập Iris	21
Hình 2.23.	Starglyph trên tập Segment	21
Hình 2.24.	Starglyph trên tập Satellite Image	22
Hình 3.1.	Giao diện Treemap 4.1 sau khi nạp dan_so_2024.tm3, chưa gán cấp bậc, Size và Color	26
Hình 3.2.	Treemap dân số 2024 dùng Slice-and-dice	29
Hình 3.3.	Treemap dân số 2024 dùng Squarified	30
Hình 3.4.	Treemap dân số 2024 dùng Strip	31
Hình 3.5.	Treemap dân số 2024 với màu là tốc độ tăng dân số 2015–2024 (bố cục Strip)	32
Hình 3.6.	Treemap sản lượng lương thực có hạt 2024 với màu là tốc độ tăng 2015–2024	33
Hình 4.1.	Quy trình hợp tác Người - Máy	37

Hình 4.2.	Giao diện phần mềm VisualDT	39
Hình 4.3.	Giao diện phần mềm VisualDT và kết quả xây dựng cây quyết định trên tập Iris	41
Hình 4.4.	Giao diện phần mềm VisualDT và kết quả xây dựng cây quyết định trên tập Segment	42
Hình 4.5.	Giao diện phần mềm VisualDT và kết quả xây dựng cây quyết định trên tập Satellite Image	45
Hình 5.1.	Giao diện phần mềm TreeView	50
Hình 5.2.	Cây quyết định spambase (mở rộng) ở Radial View	51
Hình 5.3.	Cây quyết định spambase_1 (6 lá) ở Radial View	52
Hình 5.4.	Cây quyết định kddcupmini1 ở Radial View	53
Hình 5.5.	Cây quyết định kddcupmini2 ở Radial View	54
Hình 5.6.	Cây quyết định kddcupmini2 ở Bar View	55

MỞ ĐẦU

1. Lý do thực hiện và mục tiêu

Dữ liệu trong khai phá dữ liệu ngày càng lớn về số mẫu và số chiều, khiến việc đọc trực tiếp các bảng số rất khó khăn. Trực quan hoá dữ liệu chuyển dữ liệu sang dạng hình ảnh để con người dùng năng lực thị giác của mình phát hiện cấu trúc, cụm, ngoại lai và mối liên hệ giữa các thuộc tính. Trong khai phá dữ liệu trực quan, con người được đưa trực tiếp vào vòng lặp phân tích, thay vì chỉ nhận kết quả từ thuật toán. Báo cáo tổng hợp bốn bài tập của Chuyên đề Trực quan hoá dữ liệu, với các mục tiêu sau:

- Bài tập 1: nghiên cứu nguyên lý, ưu và nhược điểm của tám phương pháp hiển thị dữ liệu và áp dụng lên các tập dữ liệu Iris, Segment, Satellite Image.
- Bài tập 2: nghiên cứu giải thuật hiển thị Treemap và ứng dụng để hiển thị dữ liệu thống kê của Việt Nam.
- Bài tập 3: nghiên cứu xây dựng trực quan cây quyết định theo giải thuật PBC (Perception-Based Classifier) và xây cây cho Iris, Segment, Satellite Image.
- Bài tập 4: nghiên cứu TreeView để xây dựng, hiển thị cây quyết định cho spambase và kddcup 1999, trích luật, đánh giá và chọn kiểu hiển thị hiệu quả.

2. Công cụ và môi trường

Bài	Công cụ	Phiên bản / nguồn
1	Python 3; chương trình bai1_visualization.py	Dữ liệu từ UCI Machine Learning Repository
2	Treemap 4.1, chạy trên Java; Python (pandas, openpyxl) để tiền xử lý dữ liệu	HCIL, University of Maryland: http://www.cs.umd.edu/projects/hcil/treemap/
3	VisualDT (Java, cần cài Java để chạy)	VisualDT.zip tải từ http://www.cit.ctu.edu.vn/~dtnghi/dataminingR/VisualDT.zip; chạy trên Windows
4	TreeView (bản Windows)	TreeView-Win.zip chạy trên Windows

3. Bố cục báo cáo

Chương 1 trình bày cơ sở lý thuyết chung. Các Chương 2 đến 5 lần lượt ứng với Bài tập 1 đến 4, mỗi chương gồm yêu cầu, lý thuyết, các bước thực hiện, kết quả, phân tích và đánh giá. Chương 6 tổng kết. Phụ lục gồm danh mục kiểm tra, mã nguồn và câu hỏi ôn tập.

CHƯƠNG 1. CƠ SỞ LÝ THUYẾT

1.1. Khái niệm và vai trò

Trực quan hoá dữ liệu là việc biểu diễn dữ liệu bằng các yếu tố đồ hoạ để con người nhận thức và khám phá thông tin nhanh hơn so với đọc dữ liệu thô. Khai phá dữ liệu trực quan kết hợp trực quan hoá với các kỹ thuật khai phá dữ liệu và sự tương tác của người dùng. Ưu thế chính: tận dụng tri thức nghiệp vụ và khả năng nhận dạng mẫu của thị giác con người, nhất là khi mục tiêu phân tích chưa rõ ràng. Theo Keim (2002), trực quan hoá trong khai phá dữ liệu có ba hướng: (1) trực quan hoá dữ liệu gốc để khám phá; (2) trực quan hoá kết quả của thuật toán khai phá (ví dụ cây quyết định, luật); (3) trực quan hoá quá trình trung gian và cho phép người dùng điều khiển thuật toán. Bài tập 1 và 2 thuộc hướng (1); Bài tập 3 và 4 thuộc hướng (2) và (3).

1.2. Phân loại kỹ thuật trực quan hoá (theo Keim)

Nhóm kỹ thuật	**Ý tưởng**	**Ví dụ**	**Bài tập liên quan**
Hiển thị chuẩn 2D/3D	Ánh xạ trực tiếp giá trị sang toạ độ	Line, Histogram, Boxplot, Pie, Scatter plot 2D	Bài 1
Biến đổi hình học	Biến đổi để thể hiện nhiều chiều trên mặt phẳng	Matrix of scatterplot, Parallel coordinates	Bài 1
Dựa trên biểu tượng	Mỗi mẫu là một biểu tượng mà hình dạng mã hoá giá trị các thuộc tính	Starglyph, Chernoff faces	Bài 1
Hướng điểm ảnh (pixel-oriented)	Mỗi giá trị là một điểm ảnh, màu mã hoá giá trị hoặc lớp	Recursive pattern, Circle segments; trực quan hoá dữ liệu trong PBC	Bài 3
Phân cấp / xếp chồng	Biểu diễn cấu trúc cây bằng hình chữ nhật lồng nhau	Treemap, cây nút-liên kết	Bài 2, 3, 4

1.3. Tiêu chí lựa chọn và đánh giá phương pháp hiển thị

- Số chiều (thuộc tính): phương pháp xử lý được bao nhiêu thuộc tính cùng lúc?
- Số lượng mẫu: có bị chồng lấn (overplotting) khi dữ liệu lớn không?
- Kiểu thuộc tính: số liên tục, rời rạc có thứ tự hay danh nghĩa.
- Nhiệm vụ phân tích: xem phân bố, tương quan, cụm, ngoại lai, khả năng tách lớp hay cấu trúc phân cấp.
- Khả năng nhận thức: người xem đọc đúng và nhanh đến đâu?
- Tương tác: có lọc, chọn, phóng to, brushing để xử lý dữ liệu lớn không?

CHƯƠNG 2. BÀI TẬP 1: CÁC PHƯƠNG PHÁP HIỂN THỊ DỮ LIỆU

2.1. Yêu cầu của đề

Đọc, tìm hiểu các phương pháp hiển thị dữ liệu: Line, Histogram, Boxplot, Pie, Scatter plot 2D, Matrix of scatterplot, Parallel coordinates, Starglyph. Viết chương trình (Python, R hoặc Java) hiển thị dữ liệu các tập Iris, Segment, Satellite Image từ UCI repository. Từ đó trình bày nguyên lý của từng phương pháp, chỉ ra ưu và nhược điểm, và hiển thị dữ liệu.

2.2. Dữ liệu sử dụng

Tập dữ liệu	Số mẫu	Số thuộc tính	Số lớp	Ghi chú
Iris	150	4 (số, cm)	3 (50 mẫu/lớp)	setosa, versicolor, virginica; Fisher (1936)
Segment (Image Segmentation)	2310 (210 huấn luyện + 2100 kiểm tra)	19 (số); dùng 18 vì region-pixel-count luôn bằng 9	7 (330 mẫu/lớp)	brickface, sky, foliage, cement, window, path, grass; ảnh ngoài trời được phân đoạn thủ công
Satellite Image (Statlog Landsat)	6435 (4435 huấn luyện + 2000 kiểm tra)	36 (số, 0–255)	6 (lớp 6 không dùng)	4 dải phổ × vùng lân cận 3×3 điểm ảnh; Attribute 17–20 là bốn dải phổ của điểm ảnh trung tâm; lớp không cân bằng

Cả ba tập dữ liệu lấy từ UCI Machine Learning Repository. Dữ liệu được lưu thành các file CSV trong thư mục data/ để dùng lại.

Tập dữ liệu	Địa chỉ trang dữ liệu	Mã (id)
Iris	https://archive.ics.uci.edu/dataset/53/iris	53
Image Segmentation	https://archive.ics.uci.edu/dataset/50/image+segmentation	50
Statlog (Landsat Satellite)	https://archive.ics.uci.edu/dataset/146/statlog+landsat+satellite	146

2.3. Chương trình hiển thị

Chương trình bai1_visualization.py được viết bằng Python, gồm các nhóm hàm: (i) nạp dữ liệu (load_uci, load_segment_df, load_iris_df, load_csv_df); (ii) tiện ích chuẩn hoá min–max, chọn thuộc tính phân biệt lớp bằng thống kê F (ANOVA), lấy mẫu theo

lớp; (iii) tám hàm vẽ tương ứng tám phương pháp. Toàn bộ mã nguồn xem Phụ lục B. Các quy ước chung: màu sắc mã hoá lớp thống nhất cho mọi phương pháp; thuộc tính được chuẩn hoá về [0, 1] trước khi vẽ Line, Parallel coordinates và Starglyph; mọi lần lấy mẫu dùng hạt giống ngẫu nhiên cố định nên kết quả tái lập được.

Với Iris dùng cả 4 thuộc tính. Với Segment và Satellite, do có nhiều thuộc tính, chương trình chọn k = 8 thuộc tính có thống kê F cao nhất: với Satellite là Attribute18, 17, 21, 22, 14, 13, 29, 30; với Segment là tám thuộc tính hiển thị trên các trục của Hình 2.20. Tham số dùng cho từng phương pháp được ghi trong mục "Thực hiện" ở các mục 2.4.1 đến 2.4.8.

2.4. Nguyên lý, ưu nhược điểm và kết quả từng phương pháp

2.4.1. Line (biểu đồ đường)

Nguyên lý: Mỗi giá trị là một điểm (x, y); các điểm kề nhau được nối bằng đoạn thẳng. Trục x thường là thời gian hoặc thứ tự quan sát, trục y là giá trị thuộc tính. Vẽ nhiều thuộc tính thành nhiều đường trên cùng một trục để so sánh.

Ưu điểm:

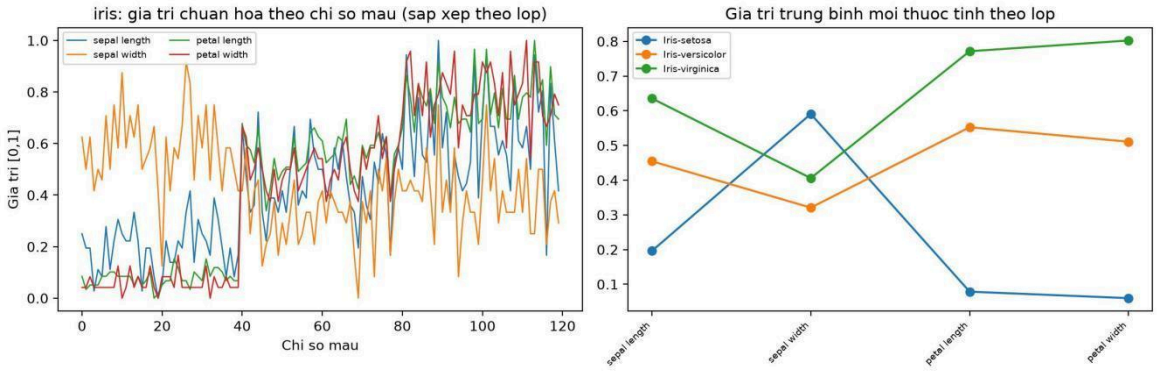
- Thể hiện rõ xu hướng, chu kỳ và biến động.
- Đơn giản, quen thuộc; so sánh được nhiều chuỗi trên cùng hình.

Nhược điểm:

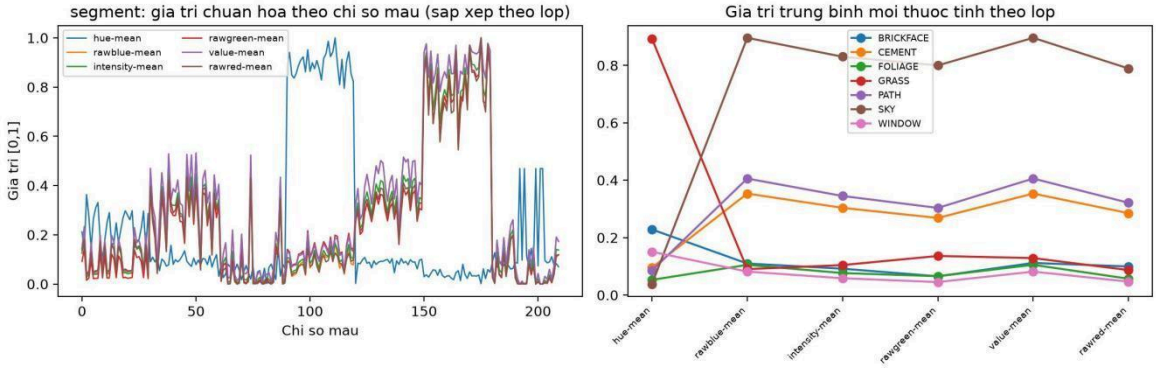
- Chỉ có ý nghĩa khi trục x có thứ tự; với dữ liệu phân lớp, việc nối các mẫu bất kỳ dễ gây hiểu sai.
- Nhiều đường hoặc nhiều mẫu thì chồng chéo, rối.
- Các thuộc tính khác thang đo phải chuẩn hoá trước.

Thực hiện: Các mẫu được sắp theo lớp và lấy tối đa 40 mẫu mỗi lớp; vẽ 6 thuộc tính đã chuẩn hoá min–max về [0, 1] (hình trái) và giá trị trung bình của từng thuộc tính theo lớp (hình phải).

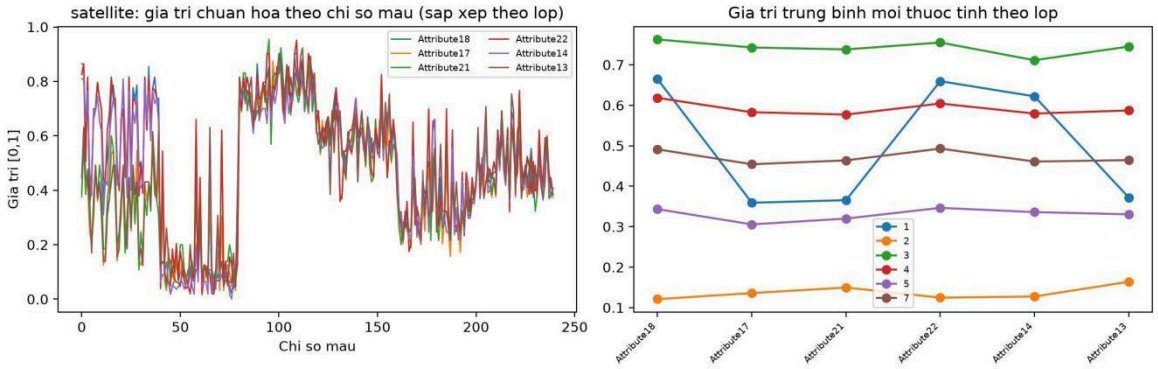
Kết quả trên ba tập dữ liệu Iris, Segment và Satellite Image lần lượt là Hình 2.1, Hình 2.2 và Hình 2.3.



Hình 2.1. *Line trên tập Iris*



Hình 2.2. *Line trên tập Segment*



Hình 2.3. *Line trên tập Satellite Image*

Nhận xét

Tập	Quan sát được từ hình	Kết luận
Iris	Hình 2.1 (trái): mẫu sắp theo lớp, hai thuộc tính cánh hoa (petal length, petal width) ở mức rất thấp (≈0,05) trong đoạn setosa rồi tăng vọt ở hai lớp sau; sepal width thì cao nhất ở setosa. Hình phải: trung bình petal length lần lượt ≈0,08 (setosa), ≈0,55 (versicolor), ≈0,77 (virginica); petal width ≈0,06; 0,51; 0,80.	Hai thuộc tính cánh hoa phân biệt rõ ba lớp, nhất là setosa; sepal width chiều ngược lại. Đường zig-zag trong từng lớp chỉ phản ánh thứ tự mẫu tuỳ ý, không phải xu hướng, nên hình trung bình theo lớp mới là phần có giá trị.
Segment	Hình 2.2 (trái): hue-mean vọt lên ≈0,9 ở đúng một đoạn mẫu, còn năm thuộc tính màu thô (rawblue, intensity, rawgreen, value, rawred) lên xuống gần như cùng lúc. Hình phải: lớp GRASS có hue-mean ≈0,9 trong khi các thuộc tính còn lại thấp; lớp SKY ≈0,8–0,9 ở các thuộc tính màu thô nhưng hue-mean gần 0; CEMENT và PATH ở mức 0,3–0,4; BRICKFACE, FOLIAGE, WINDOW đều thấp.	Line nhận ra GRASS (nhờ hue-mean) và SKY (nhờ độ sáng), đồng thời cho thấy năm thuộc tính màu thô biến thiên cùng nhau (dư thừa). Ba lớp BRICKFACE, FOLIAGE, WINDOW gần như trùng nhau nên Line không tách được.
Satellite	Hình 2.3 (phải): lớp 3 cao nhất (≈0,75) ở cả sáu thuộc tính, lớp 2 thấp nhất (≈0,12–0,16); các lớp 4 (≈0,6), 7 (≈0,47) và 5 (≈0,33) nằm giữa; lớp 1 dao động zig-zag (≈0,66; 0,36; 0,36; 0,66; 0,62; 0,37). Hình trái: đoạn lớp 2 thấp rõ rệt, đoạn lớp 3 cao.	Line tách được hai lớp cực (2 và 3). Các lớp 1, 4, 5, 7 có mức trung bình sát nhau nên khó tách bằng Line; riêng lớp 1 có dạng zig-zag đặc trưng.

2.4.2. Histogram

Nguyên lý: Chia miền giá trị của một thuộc tính thành các khoảng liên tiếp, đếm số mẫu rơi vào từng khoảng; chiều cao cột biểu diễn tần suất.

Ưu điểm:

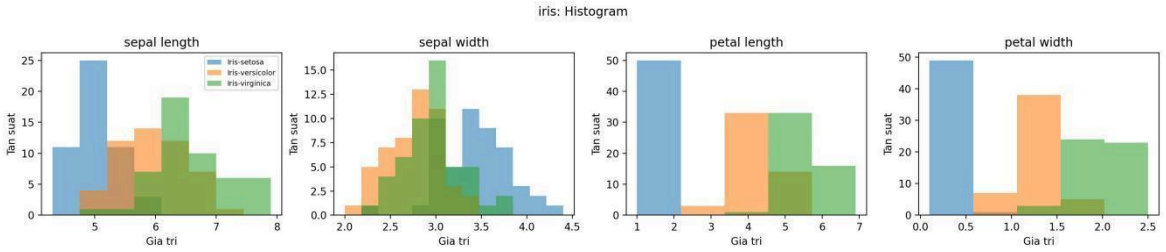
- Cho thấy hình dạng phân bố: đối xứng, lệch, đa đỉnh.
- Phát hiện khoảng giá trị bất thường và ngoại lai.
- Tô màu theo lớp để thấy thuộc tính nào phân biệt lớp.

Nhược điểm:

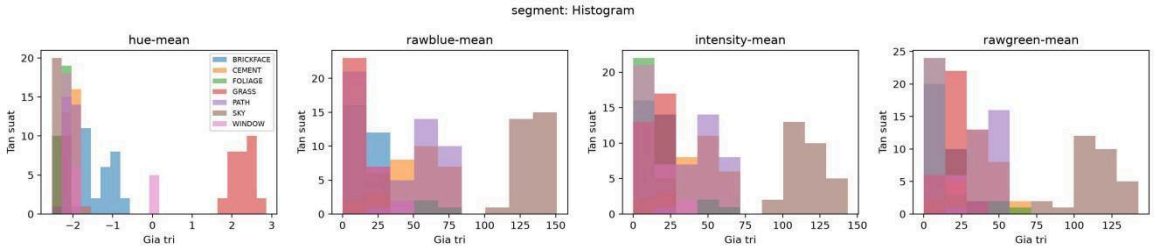
- Kết quả phụ thuộc số bin hoặc độ rộng bin.
- Chỉ một thuộc tính mỗi hình, không thấy quan hệ giữa các thuộc tính.
- Nhiều lớp chồng nhau thì khó đọc.

Thực hiện: Vẽ 4 thuộc tính (Iris: cả 4 thuộc tính; Segment và Satellite: 4 thuộc tính có thống kê F cao nhất), độ rộng bin chọn theo quy tắc Freedman–Diaconis; các lớp tô màu khác nhau và chồng lên nhau bằng độ trong suốt.

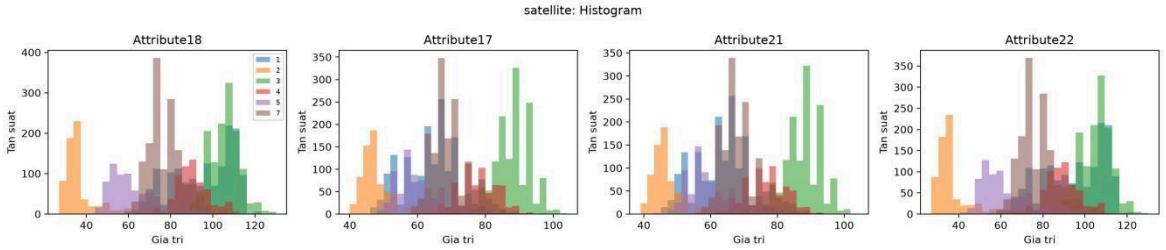
Kết quả trên ba tập dữ liệu Iris, Segment và Satellite Image lần lượt là Hình 2.4, Hình 2.5 và Hình 2.6.



Hình 2.4. *Histogram trên tập Iris*



Hình 2.5. *Histogram trên tập Segment*



Hình 2.6. *Histogram trên tập Satellite Image*

Nhận xét

Tập	**Quan sát được từ hình**	**Kết luận**
Iris	Hình 2.4: ở petal length và petal width, setosa nằm hoàn toàn ở vùng thấp (petal length ≈1–2 cm), tách khỏi hai lớp còn lại; versicolor và virginica chỉ chồng lấn một phần ở khoảng 4,5–5,5 cm (petal length). Ở sepal length và sepal width, ba lớp chồng lấn nhiều.	Thuộc tính cánh hoa phân biệt lớp tốt hơn thuộc tính đài hoa; histogram cho thấy rõ vùng chồng lấn giữa versicolor và virginica.

Tập	Quan sát được từ hình	Kết luận
Segment	Hình 2.5: hue-mean tách GRASS ở vùng dương (≈+1,7 đến +3), trong khi sáu lớp còn lại tập trung quanh −2,5 đến −0,5. Ở rawblue-mean, intensity-mean và rawgreen-mean, SKY nằm riêng ở giá trị cao (≈100–150), còn sáu lớp còn lại dồn vào vùng 0–80 và chồng lấn mạnh.	Mỗi thuộc tính chỉ tách được một đến hai lớp (GRASS nhờ hue-mean, SKY nhờ các thuộc tính độ sáng); các lớp còn lại cần phối hợp nhiều thuộc tính.
Satellite	Hình 2.6: bốn thuộc tính (Attribute18, 17, 21, 22) có hình dạng gần giống nhau. Lớp 2 nằm riêng ở vùng thấp (≈30–50), lớp 3 tập trung ở vùng cao (≈90–120); các lớp 1, 4, 5, 7 chồng lấn mạnh ở vùng ≈55–100.	Histogram cho thấy bốn thuộc tính mang thông tin gần như giống nhau (dư thừa) và chỉ tách tốt hai lớp 2 và 3.

2.4.3. Boxplot (biểu đồ hộp)

Nguyên lý: Tóm tắt phân bố bằng năm số: giá trị nhỏ nhất, tứ phân vị thứ nhất Q1, trung vị, tứ phân vị thứ ba Q3 và giá trị lớn nhất. Hộp kéo dài từ Q1 đến Q3 (độ rộng IQR), vạch trong hộp là trung vị. Râu thường kéo tới 1,5×IQR; điểm nằm ngoài râu được coi là ngoại lai và vẽ riêng.

Ưu điểm:

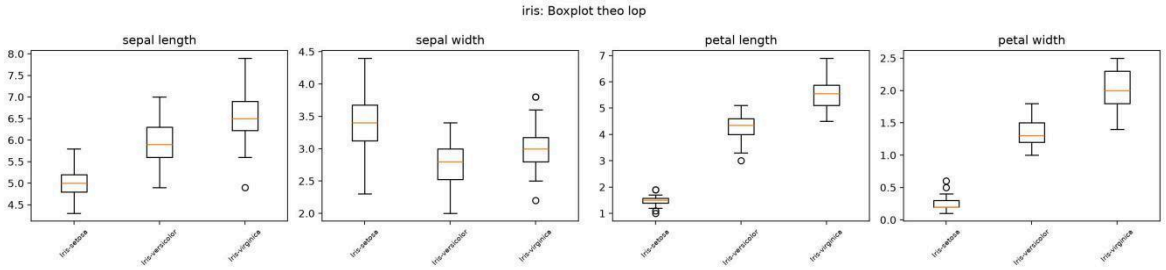
- Gọn, so sánh nhanh nhiều nhóm hoặc nhiều thuộc tính cạnh nhau.
- Thấy ngay trung vị, độ phân tán, độ lệch và ngoại lai.
- Ít bị ảnh hưởng bởi số lượng mẫu lớn.

Nhược điểm:

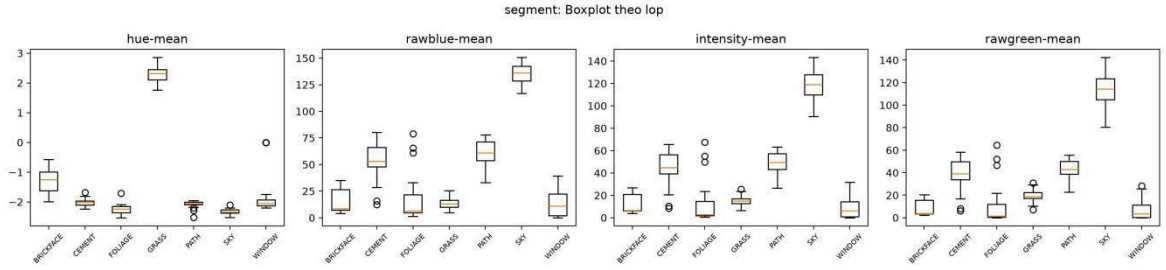
- Mất thông tin về hình dạng chi tiết (không thấy phân bố đa đỉnh).
- Không thể hiện số lượng mẫu của từng nhóm.
- Chỉ một thuộc tính cho mỗi hộp.

Thực hiện: Với 4 thuộc tính đầu tiên trong danh sách đã chọn, vẽ một hộp cho từng lớp để so sánh khả năng phân biệt lớp.

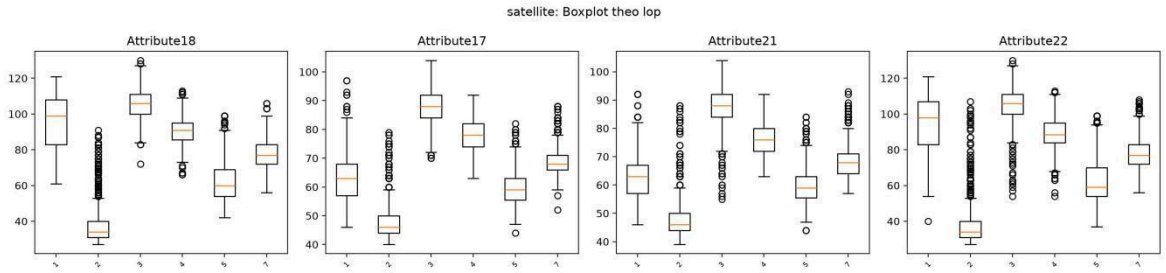
Kết quả trên ba tập dữ liệu Iris, Segment và Satellite Image lần lượt là Hình 2.7, Hình 2.8 và Hình 2.9.



Hình 2.7. *Boxplot trên tập Iris*



Hình 2.8. *Boxplot trên tập Segment*



Hình 2.9. *Boxplot trên tập Satellite Image*

Nhận xét

Tập	**Quan sát được từ hình**	**Kết luận**
Iris	Hình 2.7: ở petal length và petal width, ba hộp không chồng nhau; setosa có hộp rất nhỏ và thấp (kèm vài điểm ngoại lai), virginica cao nhất. Ở sepal length các hộp chồng một phần; ở sepal width setosa cao nhất, versicolor thấp nhất và hộp virginica chồng lên cả hai.	Petal length và petal width là hai thuộc tính phân biệt lớp tốt nhất; sepal width gần như không phân biệt được versicolor và virginica.

Tập	Quan sát được từ hình	Kết luận
Segment	Hình 2.8: hue-mean của GRASS (≈2,2) cách xa các lớp khác (≈−2 đến −1,5), riêng WINDOW có một điểm ngoại lai gần 0. Ở rawblue-mean, intensity-mean và rawgreen-mean, hộp SKY (≈115–135) vượt hẳn các lớp còn lại; trong nhóm còn lại, CEMENT và PATH (≈45–60) cao hơn BRICKFACE, FOLIAGE, GRASS, WINDOW (< 25). CEMENT và FOLIAGE có nhiều điểm ngoại lai.	Boxplot xác nhận GRASS và SKY là hai lớp tách rõ, và cho thấy hai nhóm còn lại (CEMENT/PATH và BRICKFACE/FOLIAGE/WINDOW) vẫn chồng lấn trong nội bộ nhóm.
Satellite	Hình 2.9: lớp 2 có hộp thấp nhất (Attribute18 ≈35) và lớp 3 cao nhất (≈105). Lớp 1 có hộp rộng nhất (≈60–120), tức độ phân tán lớn; các lớp 4, 5, 7 ở mức giữa với các hộp chồng lên nhau. Lớp 2 có rất nhiều điểm ngoại lai phía trên.	Boxplot cho thấy thứ tự các lớp theo cường độ phổ (gần đúng, theo Attribute18: 2 < 5 < 7 < 4 < 1 < 3) và xác nhận lớp 2, lớp 3 dễ tách trong khi lớp 1, 4, 5, 7 chồng nhau.

2.4.4. Pie (biểu đồ tròn)

Nguyên lý: Chia hình tròn thành các hình quạt có góc (và diện tích) tỉ lệ với phần đóng góp của mỗi hạng mục trong tổng thể; tổng các phần bằng 100%.

Ưu điểm:

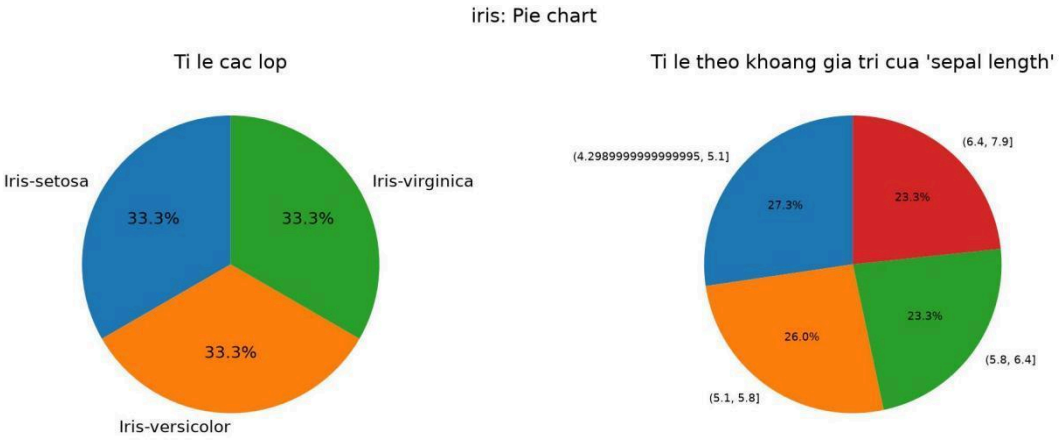
- Trực quan khi thể hiện cơ cấu, tỉ lệ thành phần.
- Dễ hiểu với người không chuyên.

Nhược điểm:

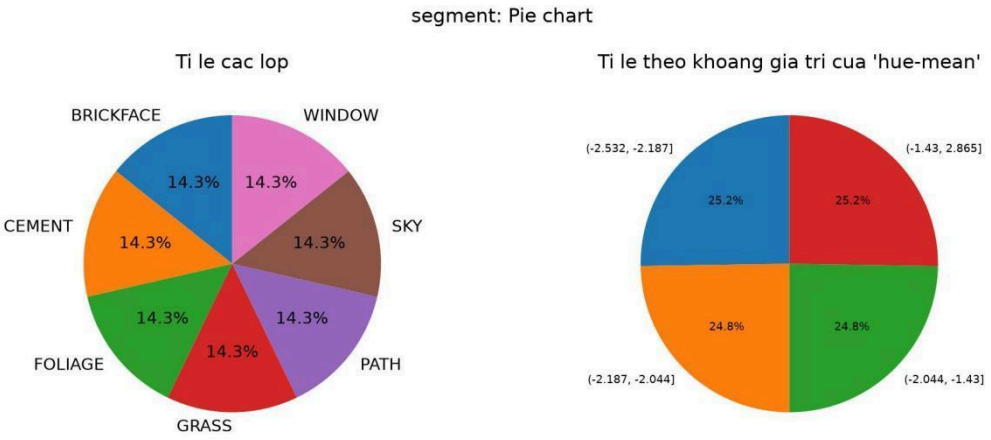
- Mắt người cảm nhận kém chính xác về góc và diện tích, nên khó so sánh các lát gần bằng nhau.
- Chỉ phù hợp với ít hạng mục (khoảng 5–7).
- Chỉ cho một biến phân loại hoặc tỉ lệ; không thể hiện giá trị âm hoặc quan hệ giữa thuộc tính.

Thực hiện: Hình trái là tỉ lệ các lớp; hình phải là tỉ lệ của bốn khoảng phân vị của thuộc tính đầu tiên (rời rạc hoá thành 4 khoảng).

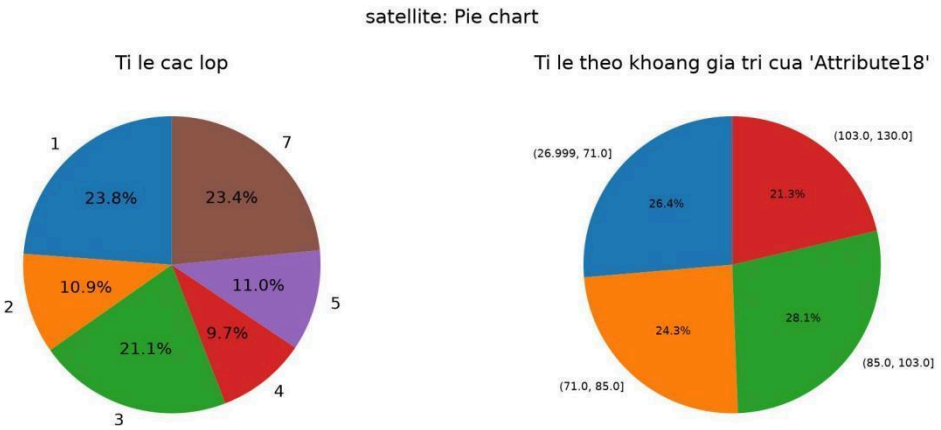
Kết quả trên ba tập dữ liệu Iris, Segment và Satellite Image lần lượt là Hình 2.10, Hình 2.11 và Hình 2.12.



Hình 2.10. *Pie trên tập Iris*



Hình 2.11. *Pie trên tập Segment*



Hình 2.12. *Pie trên tập Satellite Image*

Nhận xét

Tập	Quan sát được từ hình	Kết luận
Iris	Hình 2.10: ba lớp, mỗi lớp 33,3% (50 mẫu). Khi chia sepal length thành 4 khoảng phân vị, các phần là 27,3%; 26,0%; 23,3%; 23,3%.	Tập cân bằng hoàn toàn nên biểu đồ tròn không cho biết gì về khả năng tách lớp. Các phần phân vị chỉ gần 25% vì có nhiều giá trị trùng nhau.
Segment	Hình 2.11: bảy lớp, mỗi lớp 14,3% (330 mẫu); bốn khoảng phân vị của hue-mean xấp xỉ 25% mỗi khoảng.	Tập cân bằng; bảy lát gần như bằng nhau nên biểu đồ tròn không mang thêm thông tin. Khoảng phân vị chia đều theo định nghĩa nên cũng không có ý nghĩa phân tích.
Satellite	Hình 2.12: các lớp 1 (23,8%), 7 (23,4%) và 3 (21,1%) chiếm khoảng 68% dữ liệu; lớp 5 (11,0%), 2 (10,9%), 4 (9,7%) chiếm phần còn lại; lớp 6 không xuất hiện. Bốn khoảng giá trị của Attribute18 có tỉ lệ 26,4%; 24,3%; 28,1%; 21,3%.	Đây là tập mất cân bằng (lớp lớn nhất gấp ≈2,5 lần lớp nhỏ nhất: 23,8% so với 9,7%), cần lưu ý khi đánh giá độ chính xác phân lớp; biểu đồ tròn là phương pháp phù hợp để thể hiện điều này.

2.4.5. Scatter plot 2D (biểu đồ phân tán)

Nguyên lý: Mỗi mẫu là một điểm có hoành độ bằng giá trị thuộc tính A và tung độ bằng giá trị thuộc tính B. Màu hoặc hình dạng điểm mã hoá lớp; kích thước điểm có thể mã hoá thêm một thuộc tính thứ ba.

Ưu điểm:

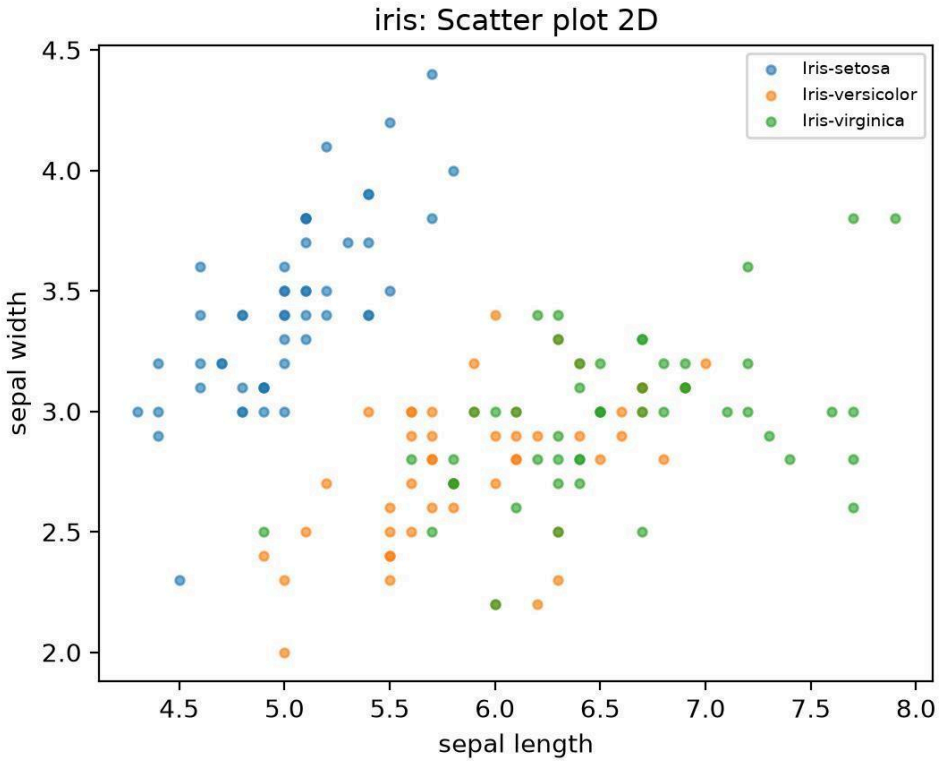
- Thấy rõ tương quan (dương, âm, phi tuyến), cụm, ngoại lai.
- Đánh giá khả năng tách lớp bằng ranh giới đơn giản giữa hai thuộc tính.

Nhược điểm:

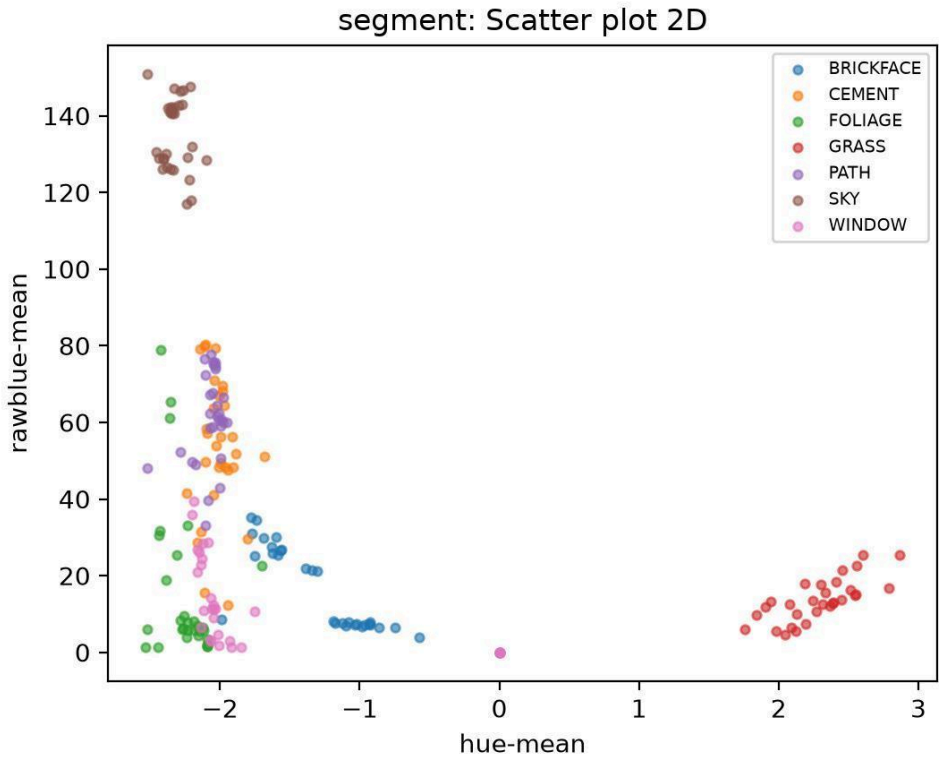
- Chỉ hai chiều mỗi hình; d thuộc tính cần $d(d-1)/2$ hình.
- Dữ liệu lớn dẫn đến chồng điểm (overplotting).
- Phải chọn cặp thuộc tính thích hợp.

Thực hiện: Dùng hai thuộc tính đầu tiên trong danh sách đã chọn, tô màu theo lớp, độ trong suốt 0,6.

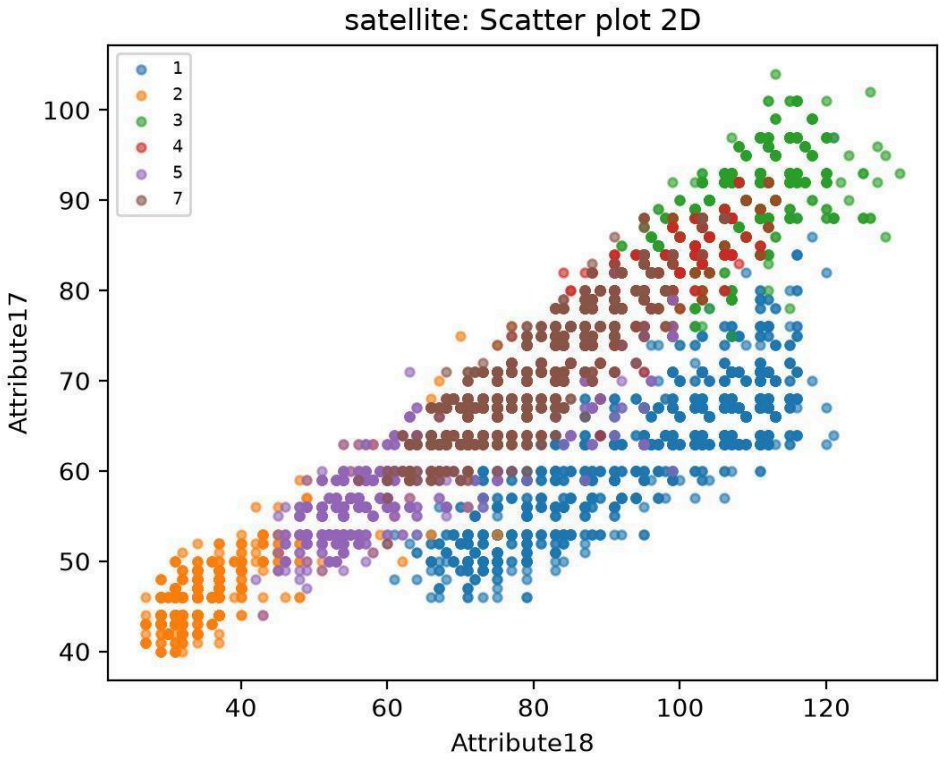
Kết quả trên ba tập dữ liệu Iris, Segment và Satellite Image lần lượt là Hình 2.13, Hình 2.14 và Hình 2.15.



Hình 2.13. *Scatter plot 2D trên tập Iris*



Hình 2.14. *Scatter plot 2D trên tập Segment*



Hình 2.15. *Scatter plot 2D trên tập Satellite Image*

Nhận xét

Tập	**Quan sát được từ hình**	**Kết luận**
Iris	Hình 2.13 (sepal length – sepal width): setosa tạo cụm riêng ở góc trên bên trái; versicolor và virginica chồng lấn mạnh ở vùng giữa. Đây là hai thuộc tính đầu tiên của tập, không phải cặp phân biệt tốt nhất.	Trong cặp này chỉ một lớp tách được; các cặp có thuộc tính cánh hoa (Hình 2.16) tách tốt hơn. Việc chọn cặp thuộc tính quyết định chất lượng của scatter plot.
Segment	Hình 2.14 (hue-mean – rawblue-mean): GRASS tách riêng ở bên phải (hue-mean > 1,7); SKY ở góc trên bên trái (rawblue-mean > 115); BRICKFACE tạo một dải hẹp (hue-mean từ −1,6 đến −0,6, rawblue-mean < 35). FOLIAGE, CEMENT, PATH và WINDOW dồn vào vùng hue-mean ≈ −2,2 và chồng lấn.	Cặp này tách được ba lớp (GRASS, SKY, BRICKFACE) và gộp bốn lớp còn lại thành một đám; cần thêm thuộc tính khác để phân biệt chúng.
Satellite	Hình 2.15 (Attribute18 – Attribute17): các điểm nằm dọc một dải chéo (tương quan dương mạnh); lớp 2 ở góc dưới trái, lớp 3 ở góc trên phải, lớp 4 ở phía trên giữa; lớp 1, 5, 7 chồng lên nhau. Các điểm xếp thành hàng vì giá trị là số nguyên.	Có hiện tượng chồng điểm (overplotting) rõ rệt, nhiều điểm trùng toạ độ. Scatter 2D chỉ tách được lớp 2 và 3, đồng thời cho thấy hai thuộc tính này dư thừa nhau.

2.4.6. Matrix of scatterplot (ma trận biểu đồ phân tán)

Nguyên lý: Sắp d thuộc tính thành lưới d×d. Ô (i, j) là biểu đồ phân tán của thuộc tính i theo thuộc tính j; đường chéo thường vẽ histogram hoặc tên thuộc tính. Ma trận đối xứng qua đường chéo. Toàn bộ các cặp thuộc tính được nhìn thấy trên một hình.

Ưu điểm:

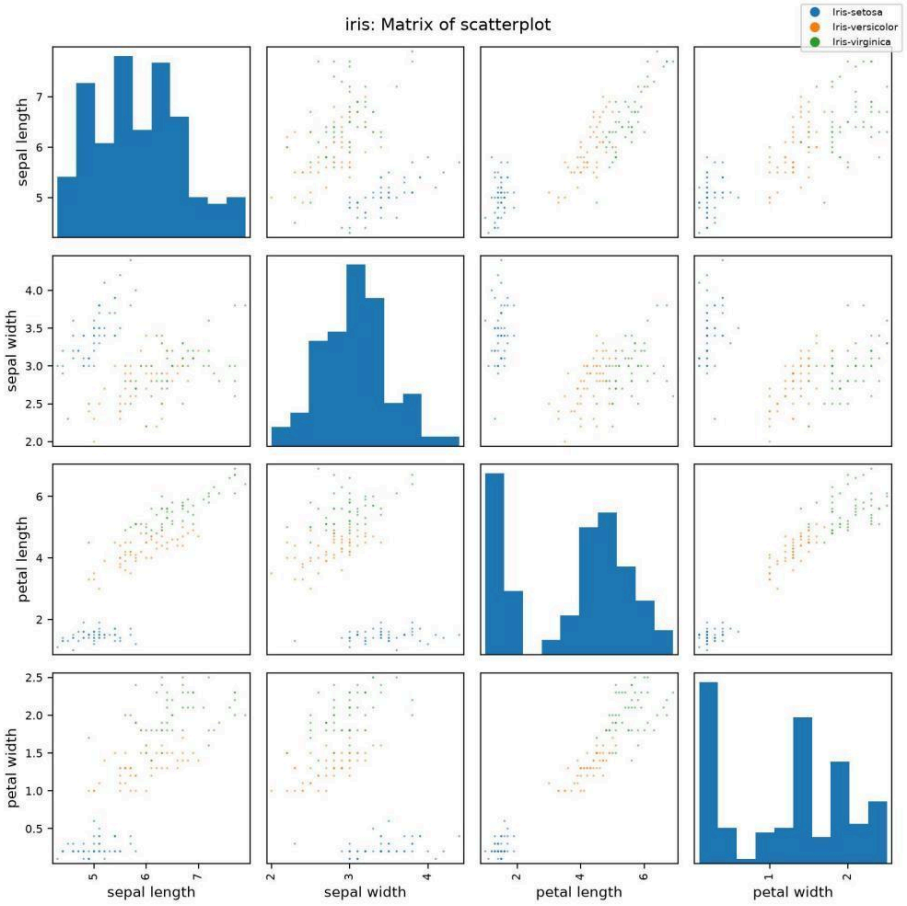
- Tổng quan mọi cặp thuộc tính cùng lúc, tìm được cặp phân tách tốt.
- Thấy tương quan và dư thừa giữa các thuộc tính.

Nhược điểm:

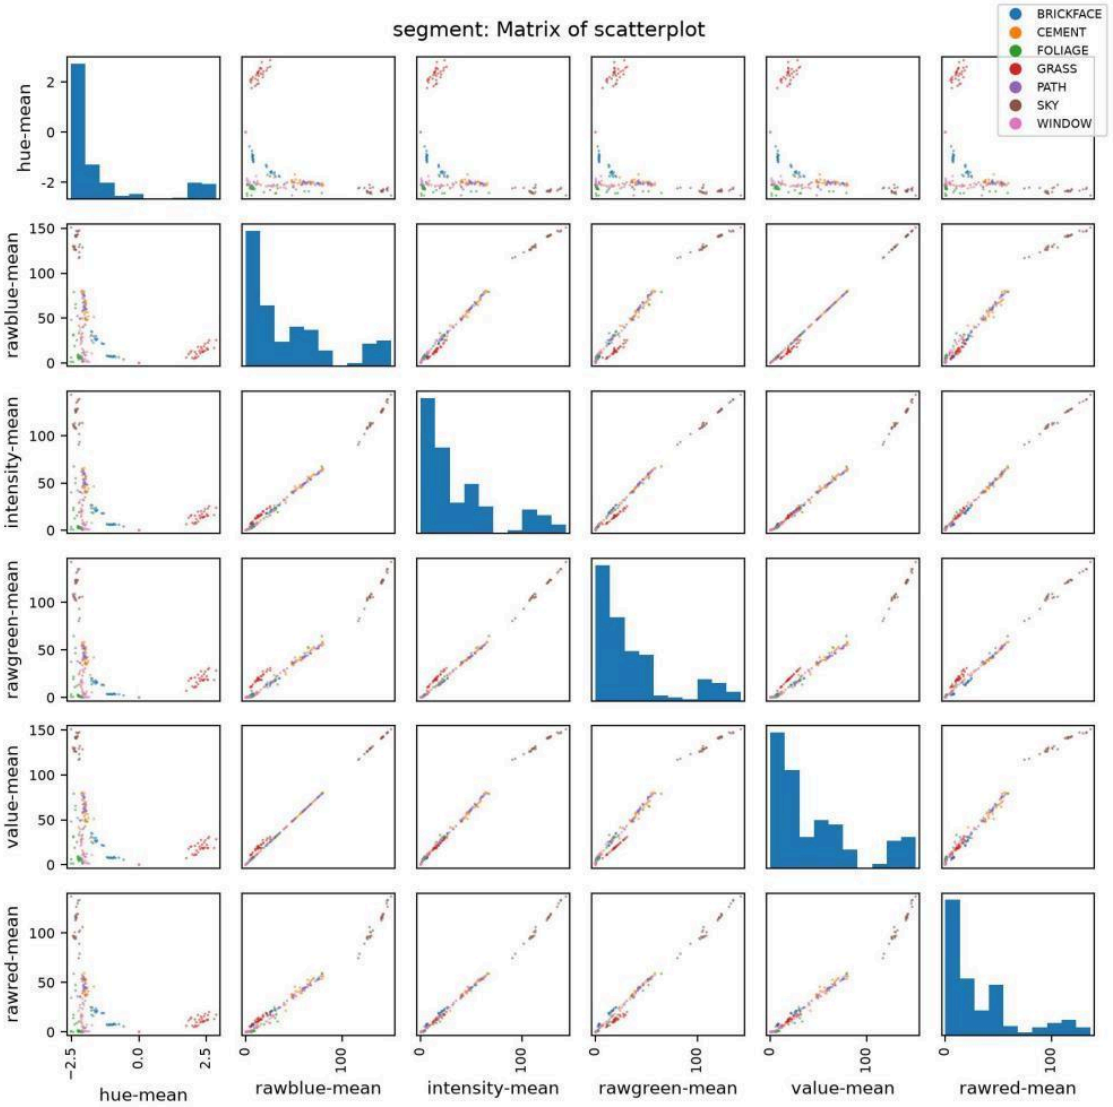
- Số ô tăng theo d^2, mỗi ô nhỏ; d lớn (Satellite có 36 thuộc tính, tức 1296 ô) thì không đọc được.
- Chỉ thể hiện quan hệ từng cặp, không phát hiện được quan hệ từ ba chiều trở lên.
- Vẫn chịu chồng điểm.

Thực hiện: Dùng 6 thuộc tính (Iris: cả 4), lấy tối đa 150 mẫu mỗi lớp; đường chéo là histogram của từng thuộc tính.

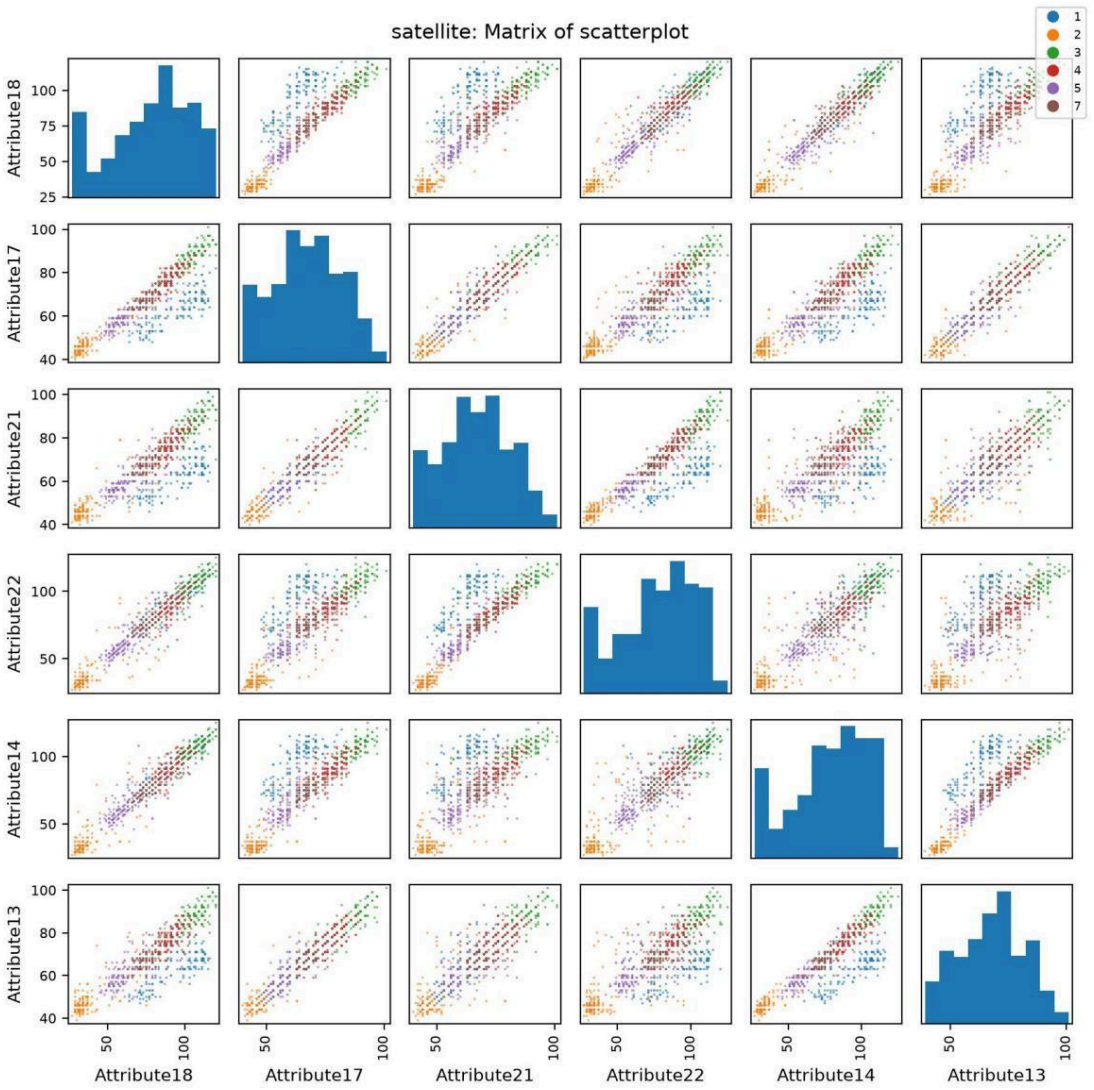
Kết quả trên ba tập dữ liệu Iris, Segment và Satellite Image lần lượt là Hình 2.16, Hình 2.17 và Hình 2.18.



Hình 2.16. *Matrix of scatterplot trên tập Iris*



Hình 2.17. *Matrix of scatterplot trên tập Segment*



Hình 2.18. *Matrix of scatterplot trên tập Satellite Image*

Nhận xét

Tập	**Quan sát được từ hình**	**Kết luận**
Iris	Hình 2.16: trong mọi ô có thuộc tính cánh hoa, setosa tách hẳn khỏi hai lớp kia; petal length và petal width tương quan dương rất mạnh; sepal width ít liên quan với các thuộc tính khác. Đường chéo petal length và petal width là histogram hai đỉnh.	Ma trận cho biết ngay cặp tách lớp tốt nhất (petal length – petal width) và vùng chồng lấn versicolor – virginica; nhanh hơn nhiều so với thử từng cặp bằng scatter plot 2D.
Segment	Hình 2.17: năm thuộc tính rawblue, intensity, rawgreen, value, rawred nằm gần như trên một đường thẳng khi vẽ theo cặp (tương quan ≈1), SKY nằm ở đầu trên của các đường này. Các ô có hue-mean tạo hình chữ L, trong đó GRASS nằm riêng ở hue-mean cao.	Năm thuộc tính màu thô dư thừa lẫn nhau, chỉ cần giữ một hai thuộc tính; hue-mean cung cấp thông tin độc lập.

Tập	Quan sát được từ hình	Kết luận
Satellite	Hình 2.18: cả sáu thuộc tính (Attribute18, 17, 21, 22, 14, 13) tương quan dương mạnh với nhau nên các ô trông gần giống nhau; lớp 2 ở góc dưới trái, lớp 3 ở góc trên phải, các lớp còn lại chồng lên nhau ở giữa.	Ma trận 6×6 gần như lặp lại cùng một thông tin. Với 36 thuộc tính nên giảm chiều (PCA) hoặc chọn thuộc tính đại diện thay vì vẽ toàn bộ.

2.4.7. Parallel coordinates (toạ độ song song)

Nguyên lý: Dùng d trục thẳng đứng song song, cách đều nhau, mỗi trục ứng với một thuộc tính (thường chuẩn hoá min–max). Mỗi mẫu là một đường gấp khúc đi qua các trục tại giá trị tương ứng của nó. Phương pháp do Inselberg đề xuất (1985).

Ưu điểm:

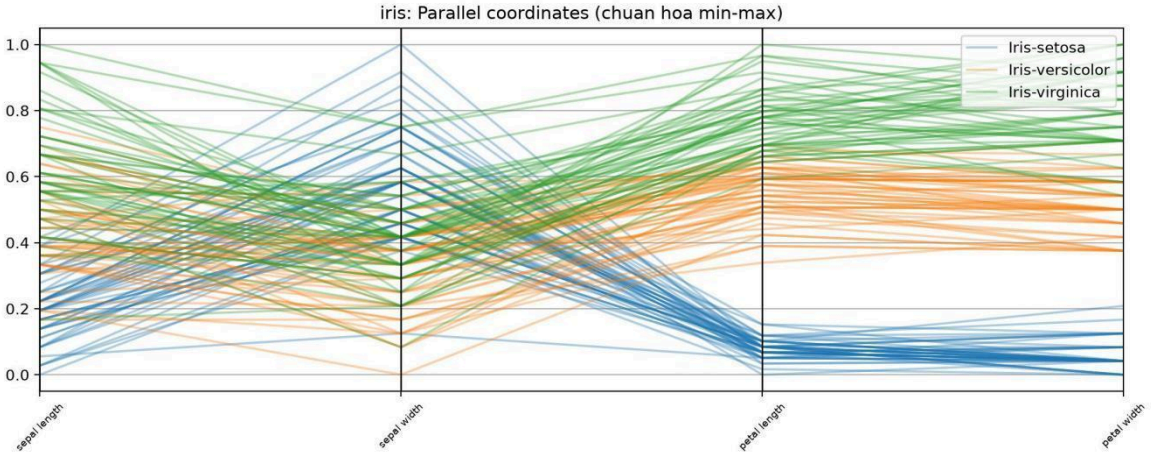
- Hiển thị được nhiều chiều (hàng chục thuộc tính) trên mặt phẳng 2D.
- Tô màu theo lớp cho thấy thuộc tính phân biệt lớp: các đường cùng lớp tụ lại, khác lớp tách rời.
- Quan hệ giữa hai trục kề nhau: đường song song là tương quan dương, đường cắt chéo là tương quan âm.

Nhược điểm:

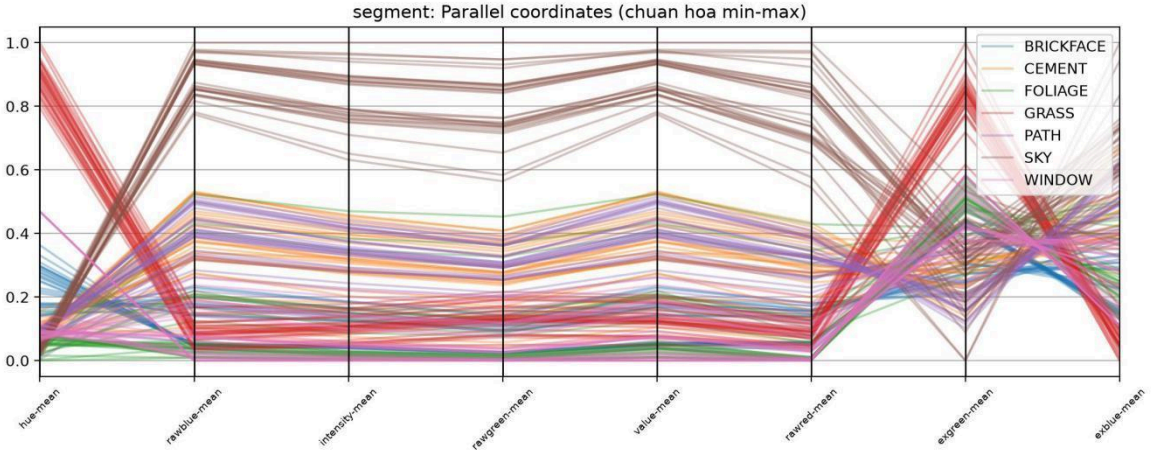
- Nhiều mẫu thì các đường chồng thành mảng đặc (cần alpha, lấy mẫu, brushing).
- Thứ tự sắp xếp các trục ảnh hưởng lớn đến những gì thấy được; chỉ nhìn ra quan hệ giữa trục kề nhau.
- Khó với thuộc tính danh nghĩa.

Thực hiện: Chuẩn hoá min–max, lấy tối đa 60 mẫu mỗi lớp, độ trong suốt 0,35; dùng toàn bộ các thuộc tính đã chọn (Iris 4, Segment 8, Satellite 8).

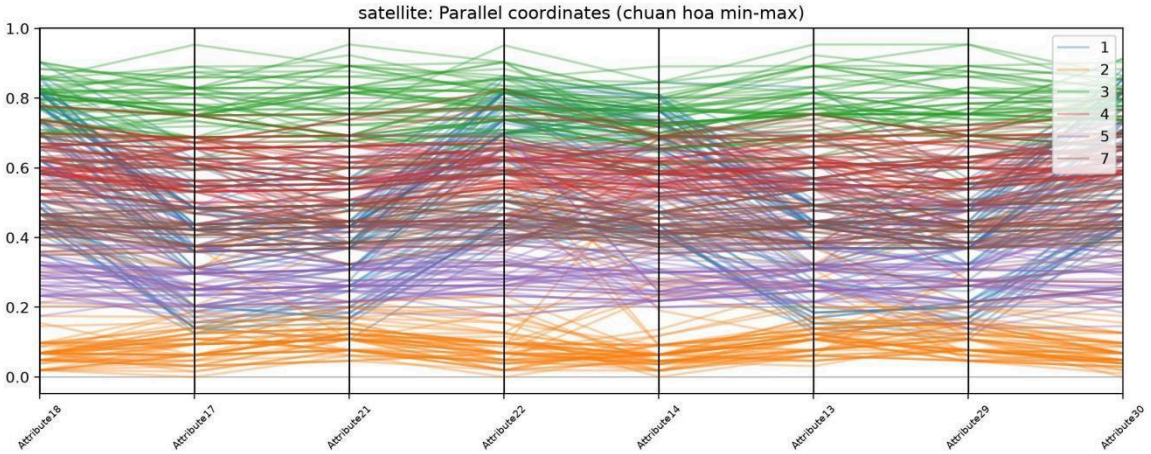
Kết quả trên ba tập dữ liệu Iris, Segment và Satellite Image lần lượt là Hình 2.19, Hình 2.20 và Hình 2.21.



Hình 2.19. *Parallel coordinates trên tập Iris*



Hình 2.20. *Parallel coordinates trên tập Segment*



Hình 2.21. *Parallel coordinates trên tập Satellite Image*

Nhận xét

Tập	Quan sát được từ hình	Kết luận
Iris	Hình 2.19: ở trục petal length và petal width, setosa nằm thấp và rất tập trung (≈0–0,15), virginica cao nhất (≈0,65–1,0), versicolor ở giữa (≈0,4–0,65). Các đường giữa sepal width và petal length cắt chéo (setosa có sepal width cao nhưng petal length thấp).	Toạ độ song song thể hiện đồng thời bốn thuộc tính và cho thấy thuộc tính nào phân biệt lớp (petal), thuộc tính nào chồng nhau (sepal width).
Segment	Hình 2.20: các đường GRASS xuất phát rất cao ở hue-mean, tụt về ≈0 ở các trục màu thô rồi lại lên cao ở exgreen-mean và xuống thấp ở exblue-mean; các đường SKY nằm trên cùng (≈0,8–0,95) ở năm trục màu thô. Các đường giữa năm trục này gần như song song nhau (tương quan dương mạnh). Năm lớp còn lại bị dồn vào nửa dưới và chồng lên nhau.	Toạ độ song song làm lộ cùng lúc nhóm thuộc tính dư thừa và hai lớp tách biệt GRASS, SKY; năm lớp còn lại vẫn chưa tách được.
Satellite	Hình 2.21: lớp 2 nằm ở dải thấp (≈0–0,2) trên mọi trục, lớp 3 ở dải cao (≈0,7–0,9); lớp 1 có dạng zig-zag giữa các trục; các lớp 4, 5, 7 đan xen ở vùng giữa. Các đường gần như song song giữa các trục kề nhau.	Phương pháp hiển thị cùng lúc 8 thuộc tính: hai lớp cực tách rõ, lớp 1 có dạng riêng, còn lớp 4, 5, 7 đan xen nên là nhóm khó phân lớp nhất. Cần lấy mẫu và độ trong suốt để tránh các đường chồng đặc.

2.4.8. Starglyph (biểu đồ ngôi sao)

Nguyên lý: Mỗi mẫu là một "ngôi sao": d tia toả ra từ một tâm với các góc bằng nhau (360°/d). Độ dài mỗi tia tỉ lệ với giá trị (đã chuẩn hoá) của một thuộc tính; nối đầu mút các tia thành đa giác. Hình dạng đa giác mã hoá toàn bộ véc-tơ thuộc tính của mẫu. Tham khảo: XmdvTool (WPI) theo đường dẫn trong đề bài.

Ưu điểm:

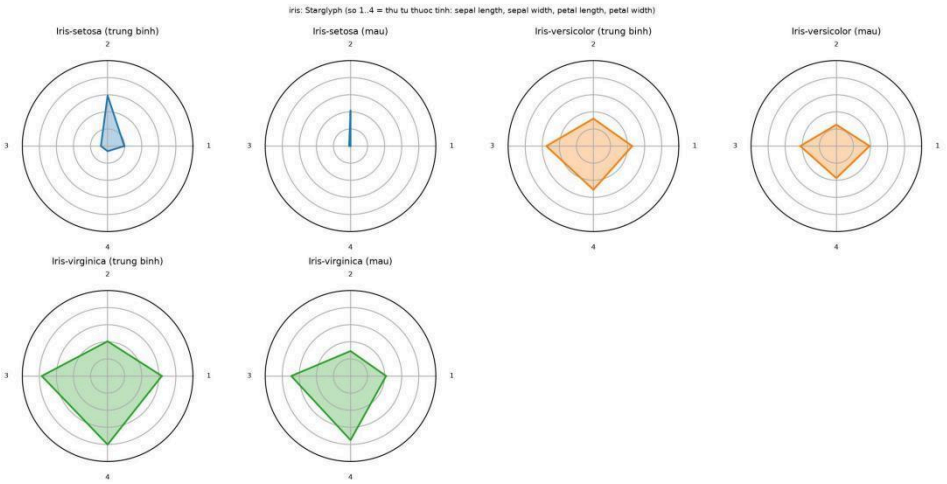
- So sánh hình dạng giữa các mẫu hoặc các lớp, nhìn nhanh mẫu giống nhau hoặc bất thường.
- Thể hiện nhiều chiều (khoảng 10–20 thuộc tính), nhỏ gọn để xếp thành lưới nhiều glyph.

Nhược điểm:

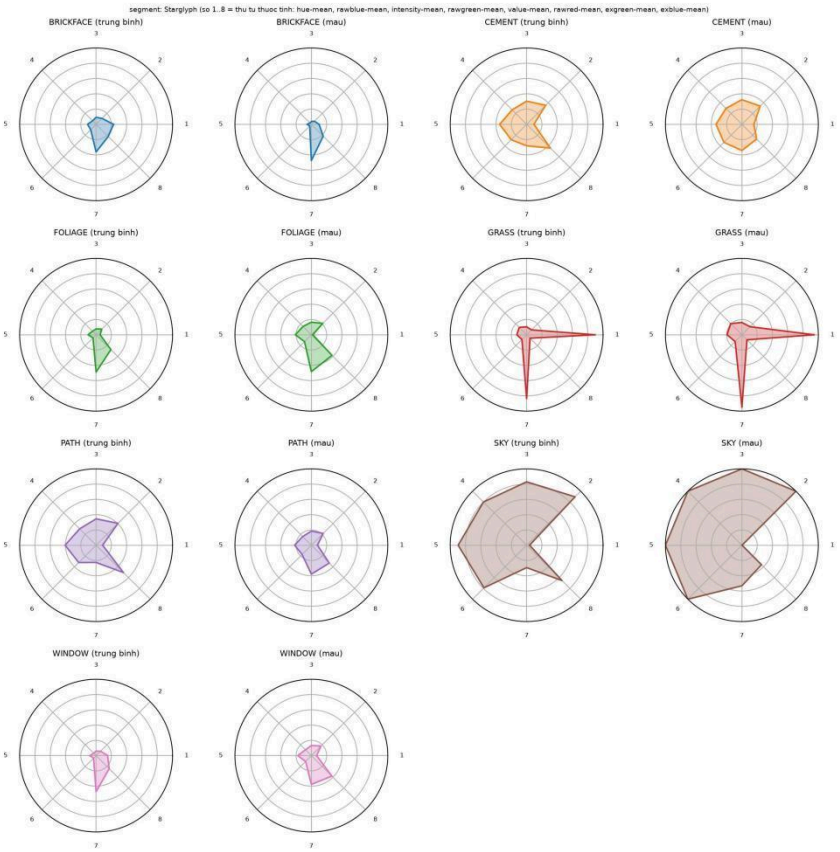
- Số mẫu hiển thị đồng thời bị giới hạn (hàng chục đến vài trăm).
- Thứ tự và hướng các trục làm hình dạng thay đổi; khó đọc giá trị chính xác.
- Nhiều thuộc tính thì ngôi sao rối.

Thực hiện: Mỗi lớp vẽ một ngôi sao trung bình và một ngôi sao của một mẫu ngẫu nhiên; tối đa 12 thuộc tính (Iris 4, Segment 8, Satellite 8), các tia đánh số theo thứ tự thuộc tính.

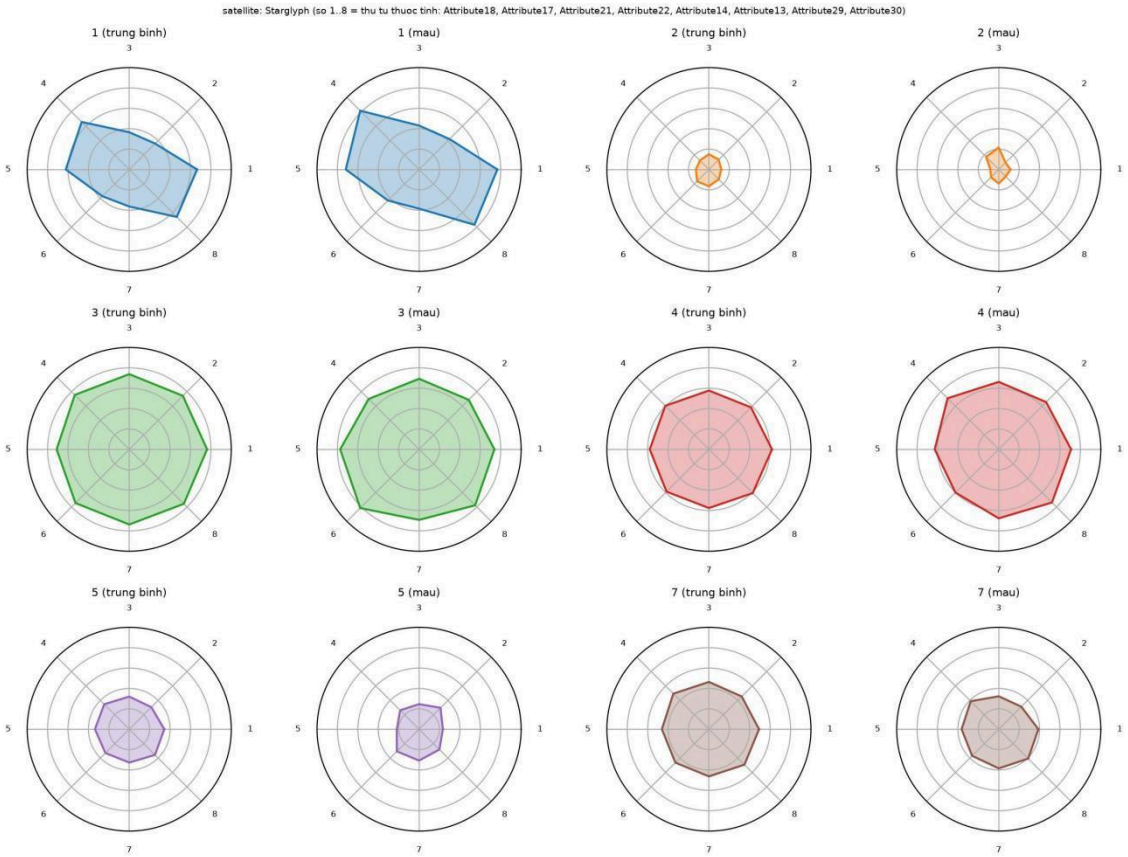
Kết quả trên ba tập dữ liệu Iris, Segment và Satellite Image lần lượt là Hình 2.22, Hình 2.23 và Hình 2.24.



Hình 2.22. *Starglyph trên tập Iris*



Hình 2.23. *Starglyph trên tập Segment*



Hình 2.24. *Starglyph trên tập Satellite Image*

Nhận xét

Tập	**Quan sát được từ hình**	**Kết luận**
Iris	Hình 2.22 (trục 1–4: sepal length, sepal width, petal length, petal width): ngôi sao setosa nhỏ và lệch về trục 2 (sepal width), versicolor có dạng hình thoi cỡ vừa, virginica là ngôi sao lớn nhất. Ngôi sao của mẫu ngẫu nhiên giống ngôi sao trung bình của lớp đó.	Hình dạng và kích thước ngôi sao đủ để phân biệt ba lớp bằng mắt; mẫu đại diện cho thấy các lớp khá đồng nhất bên trong.
Segment	Hình 2.23: ngôi sao SKY lớn nhất, phủ hầu hết các trục màu thô (2–6); GRASS có dạng gai nhọn, dài ở trục 1 (hue-mean) và trục 7 (exgreen-mean); BRICKFACE, FOLIAGE, WINDOW nhỏ sát tâm; CEMENT và PATH cỡ vừa và hình dạng gần giống nhau.	Starglyph cho thấy nhanh các lớp có "dấu vân tay" riêng (SKY, GRASS) và các lớp có hình dạng gần nhau (CEMENT/PATH và nhóm ba lớp nhỏ).

Tập	Quan sát được từ hình	Kết luận
Satellite	Hình 2.24: lớp 2 là ngôi sao rất nhỏ; lớp 3 và 4 là hai bát giác lớn, gần đều; lớp 5 và 7 cỡ vừa; lớp 1 có dạng không đều với các tia dài ngắn xen kẽ (giống kết quả zig-zag ở Hình 2.3).	Kích thước ngôi sao phản ánh cường độ phổ của từng lớp; hình dạng không đều của lớp 1 là dấu hiệu riêng, trong khi các lớp 3, 4 (và 5, 7) giống nhau về hình dạng và chỉ khác về kích thước.

2.5. Bảng so sánh tổng hợp các phương pháp

Phương pháp	Số chiều / hình	Số mẫu phù hợp	Thấy tốt	Hạn chế chính
Line	Vài thuộc tính	Ít–vừa	Xu hướng, biến động	Cần trục có thứ tự; rối khi nhiều đường
Histogram	1	Vừa–lớn	Phân bố một biến	Phụ thuộc bin; không thấy quan hệ
Boxplot	1 (nhiều nhóm)	Mọi cỡ	Phân tán, ngoại lai, so sánh nhóm	Mất hình dạng phân bố
Pie	1 (phân loại)	Mọi cỡ	Cơ cấu, tỉ lệ	Ít hạng mục; khó so sánh góc
Scatter plot 2D	2 (3 với kích thước/màu)	Vừa	Tương quan, cụm, tách lớp	Chồng điểm; $d(d-1)/2$ hình
Matrix of scatterplot	d (từng cặp)	Vừa	Mọi cặp thuộc tính	d^2 ô; không thấy quan hệ ≥3 chiều
Parallel coordinates	Hàng chục	Vừa (cần lấy mẫu)	Cụm, tương quan, thuộc tính phân biệt lớp	Chồng đường; phụ thuộc thứ tự trục
Starglyph	10–20	Ít (vài chục–trăm glyph)	So sánh hình dạng mẫu/lớp	Giới hạn số mẫu; khó đọc giá trị

2.6. Đánh giá và nhận xét chung theo từng tập dữ liệu

Tập dữ liệu	Phương pháp hiệu quả nhất	Vì sao	Phương pháp kém hiệu quả	Vì sao
Iris	Matrix of scatterplot ; Boxplot	Ma trận (Hình 2.16) cho thấy mọi cặp thuộc tính cùng lúc, chỉ ra ngay cặp cánh hoa tách setosa và vùng chồng lấn versicolor – virginica; Boxplot (Hình 2.7) xác nhận bằng ba hộp không chồng nhau ở petal length và petal width.	Pie; Line	Ba lớp bằng nhau nên Pie (Hình 2.10) không có thông tin tách lớp; Line (Hình 2.1) phụ thuộc thứ tự mẫu tự đặt.
Segment	Parallel coordinates; Boxplot	Toạ độ song song (Hình 2.20) thấy cùng lúc nhiều thuộc tính, lộ rõ GRASS, SKY và nhóm thuộc tính màu thô dư thừa; Boxplot (Hình 2.8) định lượng khoảng cách giữa các lớp.	Pie; Line	Bảy lớp bằng nhau nên Pie (Hình 2.11) không mang thông tin; Line (Hình 2.2) chỉ có giá trị ở hình trung bình theo lớp.
Satellite	Boxplot; Parallel coordinates	Boxplot (Hình 2.9) so sánh gọn sáu lớp, cho thấy lớp 2, 3 là hai cực và lớp 1, 4, 5, 7 chồng nhau; toạ độ song song (Hình 2.21) thể hiện 8 thuộc tính cùng lúc.	Scatter plot 2D; Histogram	Scatter (Hình 2.15) bị chồng điểm vì giá trị nguyên; Histogram (Hình 2.6) cho bốn thuộc tính gần như giống hệt nhau nên ít thông tin mới.

2.7. Nhận xét

Khả năng tách lớp của từng tập dữ liệu. Ở Iris, setosa tách tuyến tính khỏi hai lớp còn lại bằng các thuộc tính cánh hoa, còn versicolor và virginica chồng lấn một phần (Hình 2.7, 2.16, 2.19). Ở Segment, hai lớp GRASS và SKY tách rõ nhờ hue-mean và các thuộc tính độ sáng (Hình 2.5, 2.8, 2.14), trong khi năm lớp còn lại chồng lấn trên các thuộc tính này nên cần thêm thuộc tính khác. Ở Satellite Image, lớp 2 và lớp 3 là hai cực, còn lớp 1, 4, 5, 7 đan xen ở mọi phương pháp (Hình 2.9, 2.18, 2.21), đây là nhóm khó phân lớp nhất; kèm theo là mức độ dư thừa cao giữa các thuộc tính.

Khi số thuộc tính lớn (Satellite có 36 thuộc tính) phải chọn tập con thuộc tính theo thống kê F nên có thể bỏ sót các thuộc tính hữu ích về mặt tổ hợp; Parallel coordinates và Starglyph dùng mẫu con nên hình dạng phụ thuộc vào mẫu được chọn; các giá trị nguyên của Satellite gây chồng điểm. Những quan sát về việc các lớp chồng lấn trên nhiều thuộc tính là lý do để chuyển sang các phương pháp xây dựng mô hình phân lớp trực quan ở các bài tập sau.

CHƯƠNG 3. BÀI TẬP 2: GIẢI THUẬT HIỂN THỊ TREEMAP VÀ ỨNG DỤNG

3.1. Yêu cầu của đề

- Download bài viết của Ben Shneiderman về Treemap (trang HCIL, University of Maryland).
- Đọc và tìm hiểu phương pháp hiển thị Treemap, tập trung vào giải thuật.
- Download phần mềm Treemap; download dữ liệu từ Tổng cục Thống kê; tiền xử lý, chuyển định dạng dữ liệu cho chương trình.
- Hiển thị dữ liệu thống kê (một hoặc nhiều chủ đề như Dân số và Lao động; Công nghiệp, Đầu tư và Xây dựng; Nông, Lâm nghiệp và Thuỷ sản; Thương mại và Du lịch; Giáo dục; Y tế, Văn hoá, Thể thao và Mức sống dân cư…). Có thể hiển thị dữ liệu COVID-19.

3.2. Cơ sở lý thuyết về Treemap

3.2.1. Ý tưởng

Treemap do Johnson và Shneiderman đề xuất (1991) để hiển thị dữ liệu có cấu trúc phân cấp trong không gian hạn chế. Mỗi nút của cây là một hình chữ nhật; hình chữ nhật của nút cha được chia thành các hình chữ nhật con cho các nút con và các con nằm trọn bên trong cha. Diện tích hình chữ nhật tỉ lệ với một thuộc tính số (kích thước, ví dụ dân số). Màu sắc mã hoá thuộc tính thứ hai (ví dụ mật độ, tốc độ tăng); nhãn và độ dày đường viền thể hiện thêm cấp bậc. Toàn bộ không gian màn hình được tận dụng (space-filling), nên có thể hiển thị hàng nghìn nút, điều mà biểu diễn nút-liên kết (node-link) khó làm được.

3.2.2. Giải thuật chia: slice-and-dice

Ở mỗi cấp, hình chữ nhật của nút cha được cắt thành các dải theo một chiều, độ rộng mỗi dải tỉ lệ với giá trị của nút con; hướng cắt đổi luân phiên (ngang/dọc) theo độ sâu của cây.

Ưu điểm: rất đơn giản, giữ nguyên thứ tự các nút nên bố cục ổn định khi dữ liệu thay đổi, cấu trúc phân cấp thể hiện rõ. Nhược điểm: sinh ra nhiều hình chữ nhật rất dài và mảnh (tỉ lệ khung hình tệ) nên khó so sánh diện tích, khó chọn bằng chuột.

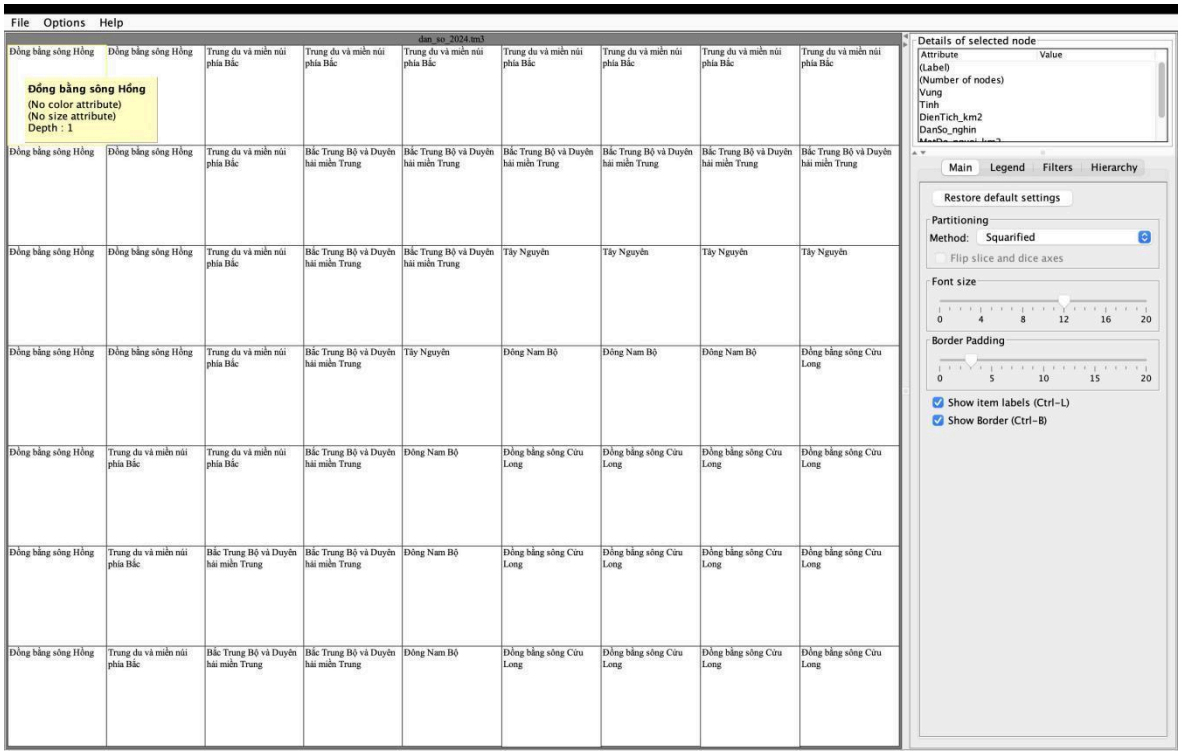
3.2.3. Ứng dụng, ưu và nhược điểm của Treemap

- **Ứng dụng:** quản lý ổ đĩa, danh mục chứng khoán và thị trường, dữ liệu thống kê theo vùng/tỉnh, cấu trúc ngân sách, phân tích bán hàng theo nhóm sản phẩm.

- **Ưu điểm:** dùng hết không gian; hiển thị được cây rất lớn; kích thước và màu cho phép so sánh đồng thời hai thuộc tính; tìm nhanh phần tử lớn hoặc bất thường.
- **Nhược điểm:** khó thấy cấu trúc phân cấp sâu so với node-link; diện tích khó so sánh chính xác bằng độ dài; giá trị âm hoặc bằng 0 không biểu diễn được trong thuộc tính kích thước; phụ thuộc thuật toán bố cục.

3.3. Cài đặt và làm quen phần mềm Treemap

Bài viết gốc về Treemap của Ben Shneiderman và các tài liệu liên quan được lấy từ trang của Human-Computer Interaction Lab (HCIL), University of Maryland theo đường dẫn trong đề: http://www.cs.umd.edu/projects/hcil/treemap/. Phần mềm sử dụng là Treemap 4.1 (gói Treemap-4.1.2.zip) của HCIL, chạy trên Java.



Hình 3.1. *Giao diện Treemap sau khi nạp dan_so_2024.tm3, chưa gán cấp bậc, Size và Color*

Giao diện gồm vùng hiển thị treemap ở giữa và bảng điều khiển bên phải. Phía trên bảng điều khiển là khung Details of selected node liệt kê các thuộc tính của nút đang chọn. Bên dưới là bốn tab: Main (phương pháp chia Partitioning Method, cỡ chữ, độ đệm viền, bật/tắt nhãn và viền); Legend (chọn thuộc tính cho Label, Size, Color, thang màu Linear/Square Root/Logarithmic, cách gộp Aggregate và chia mức màu Color Binning); Filters (ẩn hoặc hiện nút, tìm kiếm theo khoá, giới hạn độ sâu, các thanh lọc theo từng thuộc tính); Hierarchy (tạo và sắp xếp các cấp bậc từ các thuộc tính). Ngay sau khi nạp, phần mềm chưa có cấp bậc và thuộc tính kích thước, nên 63 nút lá có diện tích bằng nhau như Hình 3.1.

3.4. Dữ liệu từ Tổng cục Thống kê và tiền xử lý

3.4.1. Chọn và tải dữ liệu

Dữ liệu được tải từ trang Số liệu thống kê của Tổng cục Thống kê (https://www.nso.gov.vn/), dưới dạng file Excel. Hai bộ dữ liệu được chọn đều có cấu trúc phân cấp rõ (Vùng → Tỉnh/thành phố) với 6 vùng và 63 tỉnh, thành phố theo cách chia của bảng nguồn (chưa tính việc sắp xếp lại đơn vị hành chính cấp tỉnh năm 2025), và đều có đại lượng tuyệt đối để làm kích thước. Việc cùng cấu trúc cho phép dùng chung một quy trình tiền xử lý.

#	Chủ đề / tên bảng	Năm	Cấp bậc	Size	Color	Nguồn
1	Diện tích, dân số và mật độ dân số phân theo địa phương (bảng V02.01; chỉ tiêu: diện tích km², dân số trung bình nghìn người, mật độ người/km²; năm 2015–2025)	2024 (so sánh với 2015)	Vùng (6) → Tỉnh/thành phố (63)	DanSo_nghin (nghìn người)	MatDo_nguoi_km2; TangDanSo_2015_2024_pct	Tổng cục Thống kê, https://www.gso.gov.vn/, tải 02/11/2026
2	Sản lượng lương thực có hạt phân theo địa phương (bảng V06.10; nghìn tấn; năm 2015–2025, năm 2025 là số sơ bộ)	2024 (so sánh với 2015)	Vùng (6) → Tỉnh/thành phố (63)	SanLuong_nghin_tan (nghìn tấn)	LuongThuc_kg_nguoi; TangSanLuong_2015_2024_pct	Tổng cục Thống kê, https://www.gso.gov.vn/, tải 02/11/2026

Cặp Size/Color được chọn khác nhau về bản chất (một đại lượng tuyệt đối làm kích thước, một đại lượng tương đối làm màu): dân số với mật độ hoặc tốc độ tăng, sản lượng lương thực với lương thực bình quân đầu người hoặc tốc độ tăng. Nhờ đó mỗi treemap thể hiện đồng thời hai thông tin khác nhau.

3.4.2. Tiền xử lý và chuyển định dạng

Dữ liệu Tổng cục Thống kê được trình bày để đọc chứ không để xử lý: tiêu đề nhiều tầng, dòng tổng "CẢ NƯỚC" và các dòng tổng vùng xen giữa các tỉnh, mối quan hệ vùng – tỉnh chỉ thể hiện qua vị trí dòng, ký hiệu thiếu dữ liệu "..". Treemap cần file văn bản phân cách bằng ký tự Tab, dòng đầu là tên cột, dòng thứ hai là kiểu dữ liệu, từ dòng thứ ba là dữ liệu, mỗi dòng ứng với một nút lá (một tỉnh). Việc chuyển đổi được tự động hoá bằng chương trình chuyen_tm3.py; các bước xử lý như sau.

Bước tiền xử lý	Vấn đề gặp phải	Cách xử lý	Số dòng trước → sau
Loại dòng tổng	Bảng có dòng "CẢ NƯỚC" và 6 dòng tổng vùng xen giữa các tỉnh; nếu giữ sẽ tính trùng diện tích và dân số	Loại bỏ; tổng 63 tỉnh đã kiểm tra khớp với "Cả nước" (101.343,75 nghìn người năm 2024)	70 → 63 (bảng 1)
Gán vùng cho từng tỉnh	Phân cấp chỉ thể hiện qua vị trí dòng (dòng vùng, rồi các tỉnh của vùng)	Đọc lần lượt, ghi nhớ tên vùng gần nhất, gán vào cột Vung của mỗi tỉnh	63 tỉnh / 6 vùng
Tách bảng nhiều năm	Bảng 1 có tiêu đề hai tầng (năm × chỉ tiêu), 11 năm × 3 chỉ tiêu	Chọn năm 2024; lấy thêm 2015 để tính tốc độ tăng	99 cột → 6 cột
Dòng thiếu dữ liệu	Dòng "Hà Tây" (đã sáp nhập Hà Nội từ 2008) toàn ký hiệu ".."	Loại bỏ dòng này	64 → 63 (bảng 2)
Cột năm 2025	Cột "Sơ bộ 2025" của bảng 2 là số sơ bộ	Không dùng; chọn 2024 là năm có số liệu chính thức	—
Tính lại mật độ	Từ năm 2020, mật độ trong bảng gốc đã làm tròn đến số nguyên	Tính lại = dân số × 1000 / diện tích để thống nhất	—
Tạo thuộc tính phái sinh	Cần đại lượng tương đối để làm Color	LuongThuc_kg_nguoi = sản lượng / dân số × 1000 (dân số lấy từ bảng 1); tốc độ tăng 2015–2024 (%)	+2 cột (bảng 2), +1 cột (bảng 1)
Định dạng file	Treemap đọc file văn bản phân cách bằng Tab, dòng 2 là kiểu dữ liệu	Xuất .tm3 (có bản không dấu phòng lỗi font); kiểm tra mở được trong Treemap (Hình 3.1)	63 dòng dữ liệu mỗi file

Nội dung đầu file dan_so_2024.tm3 sau khi chuyển đổi:

```
Vung                Tinh       DienTich_km2  DanSo_nghin  MatDo_nguoi_km2  TangDanSo_2015_2024_pct
STRING              STRING     FLOAT         FLOAT        FLOAT            FLOAT
Đồng bằng sông Hồng  Hà Nội     3359.84       8717.63      2594.7           17.27
Đồng bằng sông Hồng  Vĩnh Phúc  1236.0        1225.29      991.3            12.37
Đồng bằng sông Hồng  Bắc Ninh   822.71        1546.59      1879.9           26.93
```

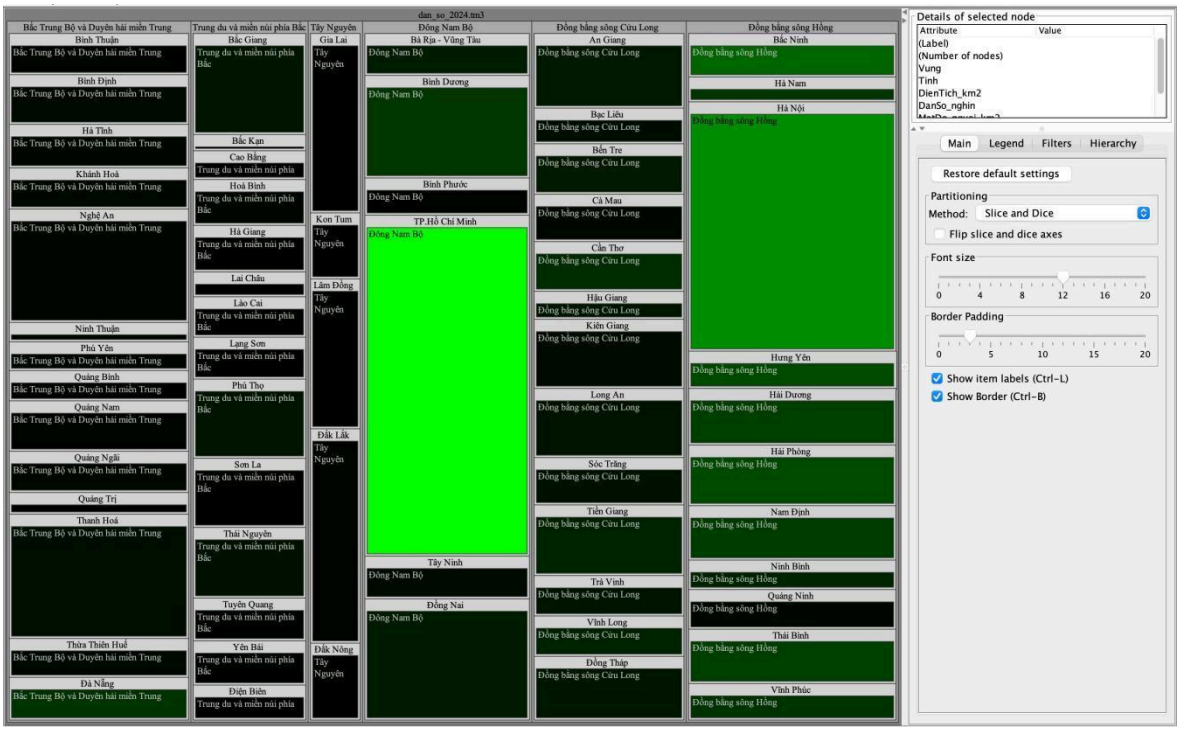
Kết quả gồm hai file dữ liệu chính dan_so_2024.tm3 (63 dòng; cột Vung, Tinh, DienTich_km2, DanSo_nghin, MatDo_nguoi_km2, TangDanSo_2015_2024_pct) và luong_thuc_2024.tm3 (63 dòng; cột Vung, Tinh, SanLuong_nghin_tan, LuongThuc_kg_nguoi, TangSanLuong_2015_2024_pct), cùng hai bản không dấu tương ứng.

3.5. Kết quả hiển thị

Mọi treemap dùng cấp bậc Vung → Tinh (6 vùng, 63 tỉnh), nhãn Label là tên nút. Các hình 3.2, 3.3 và 3.4 giữ nguyên dữ liệu và ánh xạ, chỉ đổi giải thuật chia, nhằm so sánh trực tiếp ba giải thuật; Hình 3.5 đổi ánh xạ màu; Hình 3.6 dùng bộ dữ liệu thứ hai.

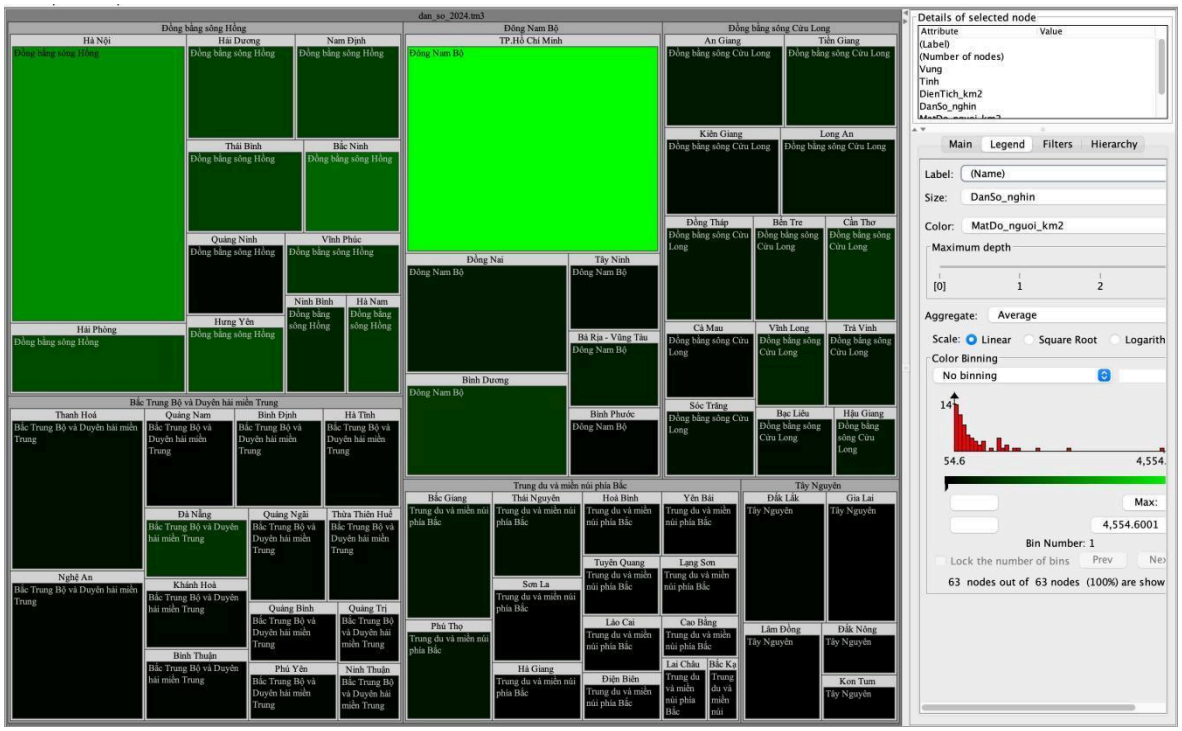
Hình	Dữ liệu	Giải thuật (Method)	Size	Color (thang, chia mức)
3.2	dan_so_2024.tm3	Slice and Dice	DanSo_nghin	MatDo_nguoi_km2 (Linear, No binning)
3.3	dan_so_2024.tm3	Squarified	DanSo_nghin	MatDo_nguoi_km2 (Linear, No binning)
3.4	dan_so_2024.tm3	Strip	DanSo_nghin	MatDo_nguoi_km2 (Linear, No binning)
3.5	dan_so_2024.tm3	Strip	DanSo_nghin	TangDanSo_2015_2024_pct (Linear, User defined bins, mốc chia tại 0: đỏ là giảm, xanh là tăng)
3.6	luong_thuc_2024.tm3	Bố cục của phần mềm	SanLuong_nghin_tan	TangSanLuong_2015_2024_pct (Linear, User defined bins, mốc chia tại 0)

3.5.1. Ba giải thuật trên cùng dữ liệu dân số



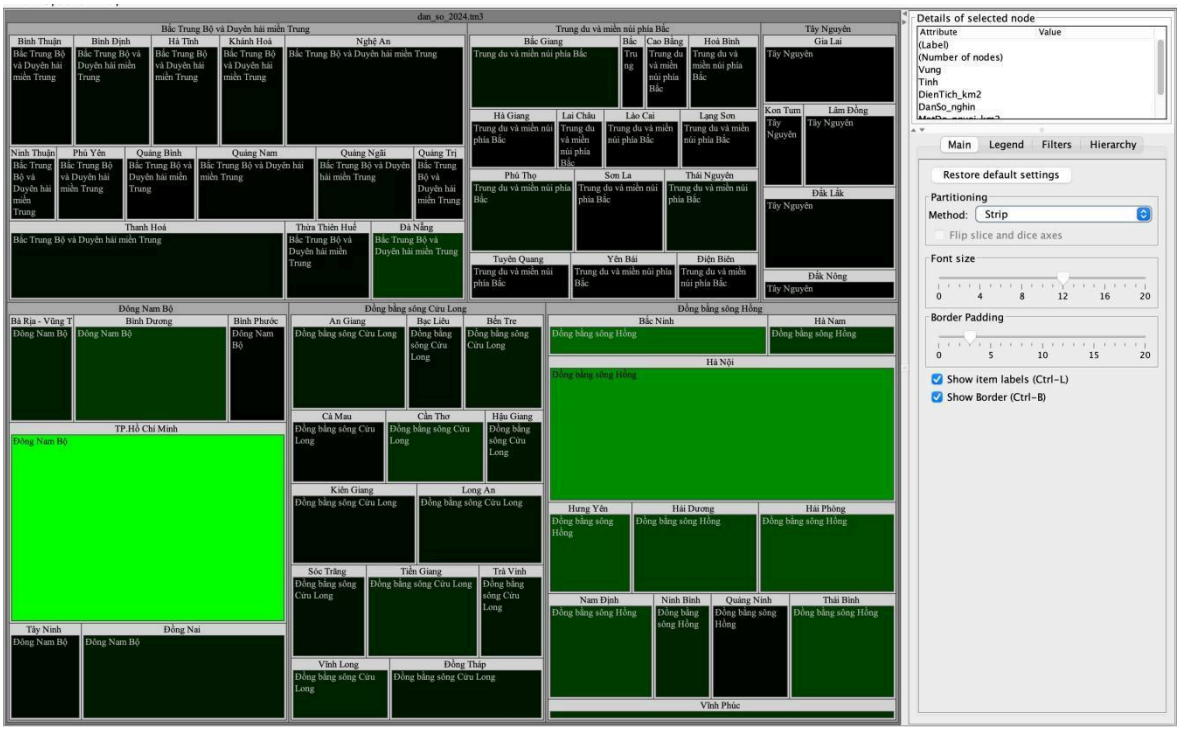
Hình 3.2. *Treemap dân số 2024 dùng Slice-and-dice*

Ở Hình 3.2, các vùng là những cột dọc xếp từ trái sang phải theo tên, các tỉnh xếp chồng trong cột theo thứ tự tên từ trên xuống. Cách chia này làm nhiều tỉnh nhỏ (Bắc Kạn, Lai Châu, Ninh Thuận, Quảng Trị, Hà Nam) chỉ còn là những dải mỏng, rất khó đọc nhãn và khó rê chuột chọn; trong khi TP. Hồ Chí Minh và Hà Nội là các hình chữ nhật dài, hẹp.



Hình 3.3. *Treemap dân số 2024 dùng Squarified*

Ở Hình 3.3, mỗi vùng là một khối chữ nhật gọn (Đồng bằng sông Hồng, Đông Nam Bộ, Đồng bằng sông Cửu Long ở hàng trên; Bắc Trung Bộ và Duyên hải miền Trung, Trung du và miền núi phía Bắc, Tây Nguyên ở hàng dưới) và các tỉnh gần như vuông, nên so sánh diện tích và chọn từng tỉnh dễ hơn nhiều so với Hình 3.2. Đổi lại, thứ tự tên không còn: trong mỗi vùng các tỉnh xếp theo kích thước giảm dần (Hà Nội đứng đầu vùng Đồng bằng sông Hồng, là ô dài nhất).



Hình 3.4. *Treemap dân số 2024 dùng Strip*

Ở Hình 3.4, các vùng xếp thành hai hàng và các tỉnh xếp thành những dải ngang trong từng vùng, giữ được thứ tự tên theo từng dải (ví dụ Bắc Ninh, Hà Nam / Hà Nội / Hưng Yên, Hải Dương, Hải Phòng…). Hình dạng nằm giữa hai giải thuật trước: phần lớn ô khá vuông nhưng vẫn còn những dải dẹt ở cuối hàng (Vĩnh Phúc, Đồng Tháp).

So sánh các giải thuật.

Tiêu chí	**Slice-and-dice (Hình 3.2)**	**Squarified (Hình 3.3)**	**Strip (Hình 3.4)**
Tỉ lệ khung hình (hình gần vuông)	Kém nhất: nhiều dải rất dài và mảnh, các vùng là cột dọc hẹp	Tốt nhất: hầu hết ô gần vuông; ngoại lệ là ô Hà Nội hình chữ nhật cao	Trung bình: ô dạng dải ngang, vài ô rất dẹt ở cuối hàng
Dễ so sánh diện tích hai vùng	Khó: dễ so sánh chiều rộng cột nhưng các ô tỉnh quá mảnh	Dễ: hình gần vuông nên mắt so sánh diện tích chính xác hơn	Khá: dễ so sánh trong cùng một dải
Dễ chọn nút nhỏ bằng chuột	Khó: nút chỉ cao vài điểm ảnh	Dễ: nút nhỏ vẫn đủ diện tích để rê chuột	Khá: nút nhỏ có bề ngang nhưng một số quá dẹt
Thể hiện cấu trúc phân cấp	Rõ: vùng là cột, tỉnh xếp chồng trong cột	Rõ: mỗi vùng là một khối gọn, nhưng vị trí các khối khó đoán	Rõ vừa phải: vùng xếp thành hai hàng
Giữ thứ tự (tên, giá trị)	Tốt: vùng và tỉnh đều xếp theo tên	Không: tỉnh xếp theo kích thước giảm dần, vị trí phụ thuộc dữ liệu	Một phần: tỉnh xếp theo tên trong từng dải

Tiêu chí	Slice-and-dice (Hình 3.2)	Squarified (Hình 3.3)	Strip (Hình 3.4)
Kết luận / chọn dùng	Dùng khi cần tra cứu theo tên hoặc bố cục ổn định; không hợp để đọc diện tích	Phù hợp nhất để đọc và so sánh kích thước; được chọn cho dữ liệu này	Lựa chọn trung gian, cân bằng hình dạng và thứ tự

Thang màu. Cả ba hình dùng thang màu tuyến tính, nên TP. Hồ Chí Minh (4.554,6 người/km²) là ô sáng duy nhất còn hầu hết tỉnh còn lại có màu rất tối: 42 trong 63 tỉnh có mật độ dưới 500 người/km² và mật độ của TP. Hồ Chí Minh gấp 16,4 lần trung vị (278,1 người/km²). Biểu đồ phân bố trong tab Legend của Hình 3.3 lệch mạnh về phía giá trị nhỏ cho thấy điều đó. Phần mềm cho phép đổi sang thang Square Root hoặc Logarithmic, hoặc chia mức màu tự đặt (như ở Hình 3.5), để phân biệt tốt hơn các tỉnh có mật độ thấp.

3.5.2. Thay đổi ánh xạ: tốc độ tăng dân số 2015–2024



Hình 3.5. *Treemap dân số 2024 với màu là tốc độ tăng dân số 2015–2024 (bố cục Strip)*

Ở Hình 3.5, kích thước vẫn là dân số nhưng màu thể hiện tốc độ tăng dân số giai đoạn 2015–2024 với mốc chia tại 0: màu đỏ là dân số giảm, đen là gần như không đổi, xanh là tăng và càng sáng càng tăng nhanh. Cách này làm lộ ra thông tin mà thang mật độ không có: các ô đỏ là An Giang, Sóc Trăng, Hậu Giang và Đồng Tháp; các ô xanh sáng là Bình Dương, Bắc Ninh, Kon Tum, Đà Nẵng, Đắk Nông.

3.5.3. Bộ dữ liệu thứ hai: sản lượng lương thực có hạt



Hình 3.6. *Treemap sản lượng lương thực có hạt 2024 với màu là tốc độ tăng 2015–2024*

Hình 3.6 cho thấy ngay khối lớn nhất là Đồng bằng sông Cửu Long, chiếm hơn một nửa diện tích, với các ô tỉnh lớn có màu rất tối (biến động nhỏ). Ở các vùng còn lại, nhiều ô nhỏ có màu đỏ hoặc xanh sáng. Phân tích chi tiết ở Mục 3.6.2.

3.6. Phân tích kết quả

3.6.1. Dữ liệu dân số (Hình 3.2 đến 3.5)

1. **Quy mô và phân bố:** TP. Hồ Chí Minh (9.543,6 nghìn người) và Hà Nội (8.717,6) là hai ô lớn nhất, cộng lại chiếm 18,0% dân số của 63 tỉnh (101.343,8 nghìn người); tiếp theo là Thanh Hoá (3.764,2), Nghệ An (3.472,3) và Đồng Nai (3.365,5). Theo vùng, Đồng bằng sông Hồng chiếm 23,7% (24.016,0 nghìn người), Bắc Trung Bộ và Duyên hải miền Trung 20,7%, Đông Nam Bộ 19,0%, Đồng bằng sông Cửu Long 17,3%, Trung du và miền núi phía Bắc 13,2%, Tây Nguyên 6,2%.
2. **Kích thước lớn nhưng mật độ thấp:** Nghệ An có diện tích lớn nhất cả nước (16.486,5 km²) và đông dân thứ tư nhưng mật độ chỉ 210,6 người/km², nên là ô lớn với màu tối ở Hình 3.2 đến 3.4; ngược lại Bắc Ninh có ô nhỏ nhưng mật độ 1.879,9 người/km², sáng hơn hẳn. Đây là điều bảng số khó cho thấy ngay mà treemap thể hiện trực quan.
3. **Tập trung dân cư:** Có 10 tỉnh mật độ trên 1.000 người/km²: tám tỉnh thuộc Đồng bằng sông Hồng (Hà Nội, Bắc Ninh, Hải Dương, Hải Phòng, Hưng Yên, Thái Bình, Hà Nam, Nam Định) cùng Bình Dương và TP. Hồ Chí Minh

(4.554,6, cao nhất). Mật độ thấp nhất là Lai Châu (54,6), Kon Tum (62,2), Bắc Kạn (67,9), Điện Biên (68,8). Theo vùng, mật độ là 1.129 (Đồng bằng sông Hồng), 817 (Đông Nam Bộ), 429 (Đồng bằng sông Cửu Long), 219 (Bắc Trung Bộ và Duyên hải miền Trung), 140 (Trung du và miền núi phía Bắc) và 114 người/km² (Tây Nguyên).

4. **Biến động 2015–2024 (Hình 3.5):** Dân số 63 tỉnh tăng 9,9% (từ 92.229,1 lên 101.343,8 nghìn người). Tăng nhanh nhất là Bình Dương (+38,7%), Bắc Ninh (+26,9%), Kon Tum (+21,4%), Đà Nẵng (+20,8%) và Đắk Nông (+19,8%). Bốn tỉnh giảm đều thuộc Đồng bằng sông Cửu Long: An Giang (−4,4%), Sóc Trăng (−2,5%), Hậu Giang (−1,7%), Đồng Tháp (−1,5%). Theo vùng, Đông Nam Bộ tăng 17,0%, Đồng bằng sông Hồng 12,4%, Trung du và miền núi phía Bắc 12,0%, Tây Nguyên 11,8%, Bắc Trung Bộ và Duyên hải miền Trung 6,6% và Đồng bằng sông Cửu Long chỉ 1,6%.
5. **Điều đáng chú ý:** Đồng bằng sông Cửu Long là vùng đông thứ tư nhưng gần như không tăng dân số và có bốn tỉnh giảm; Bình Dương có mật độ đã vượt 1.000 người/km² vẫn là tỉnh tăng nhanh nhất; Kon Tum và Đắk Nông tăng nhanh nhưng vẫn thuộc nhóm mật độ thấp.

3.6.2. Dữ liệu sản lượng lương thực (Hình 3.6)

1. **Tập trung theo vùng và tỉnh:** Sản lượng 2024 của 63 tỉnh là 47.854,6 nghìn tấn. Đồng bằng sông Cửu Long chiếm 51,6% (24.681,1 nghìn tấn), tiếp theo là Bắc Trung Bộ và Duyên hải miền Trung 17,1%, Đồng bằng sông Hồng 11,8%, Trung du và miền núi phía Bắc 10,3%, Tây Nguyên 5,5%, Đông Nam Bộ 3,8%. Năm tỉnh đứng đầu đều thuộc Đồng bằng sông Cửu Long: Kiên Giang (4.717,4), An Giang (4.110,4), Đồng Tháp (3.375,4), Long An (3.222,6), Sóc Trăng (2.193,8); mười tỉnh lớn nhất chiếm 51,0% tổng sản lượng.
2. **Lương thực bình quân đầu người:** Kiên Giang đạt 2.670 kg/người, An Giang 2.149, Đồng Tháp 2.108, Long An 1.835, Sóc Trăng 1.820. Ngược lại, các đô thị lớn rất thấp: Bình Dương 8,6 kg, TP. Hồ Chí Minh 10,4 kg, Đà Nẵng 25,0 kg. Hà Nội sản xuất 923,9 nghìn tấn (ô tương đối lớn) nhưng chỉ tương đương 106 kg/người do dân số đông.
3. **Biến động 2015–2024:** Tổng sản lượng giảm 5,0% (từ 50.379,3 xuống 47.854,6 nghìn tấn); 35 trong 63 tỉnh giảm. Đồng bằng sông Hồng giảm mạnh nhất (−21,4%, giảm ở cả 11 tỉnh), về giá trị tuyệt đối còn lớn hơn mức giảm 1.122,2 nghìn tấn (−4,3%) của Đồng bằng sông Cửu Long. Bắc Trung Bộ và Duyên hải miền Trung tăng 5,1% (+395,4 nghìn tấn), Tây Nguyên tăng 4,3%. Giảm mạnh nhất là Bến Tre (−76,9%), Hưng Yên (−47,8%), Tiền Giang (−44,5%), Hải Phòng (−41,7%), Vĩnh Long (−37,8%); tăng mạnh nhất là

Khánh Hoà (+32,9%), Ninh Thuận (+27,3%), Quảng Trị (+24,0%), Cà Mau (+23,6%).

4. **Quan sát trên hình:** Các ô lớn nhất ở Hình 3.6 (Kiên Giang +1,6%, An Giang −0,7%, Đồng Tháp −1,3%) có màu tối vì biến động gần 0, trong khi các màu đỏ và xanh sáng tập trung ở các tỉnh nhỏ. Nghĩa là mức giảm chung đến từ nhiều tỉnh vừa và nhỏ (đặc biệt Đồng bằng sông Hồng) chứ không phải từ sự sụt giảm của các tỉnh sản xuất lớn nhất; sản lượng của vùng lớn nhất khá ổn định.
5. **Điều đáng chú ý:** Mức giảm của một số tỉnh rất lớn (Bến Tre giảm hơn ba phần tư) và có sự khác biệt lớn giữa các tỉnh liền kề trong cùng vùng (Cà Mau +23,6% trong khi Bến Tre, Tiền Giang, Vĩnh Long giảm mạnh). Nguyên nhân cần các dữ liệu bổ sung (diện tích gieo trồng, chuyển đổi mục đích sử dụng đất, thời tiết…) nằm ngoài phạm vi của bài tập này.

3.7. Đánh giá

- **Điểm mạnh của Treemap:** thể hiện đồng thời hai thuộc tính (kích thước và màu) cùng cấu trúc phân cấp Vùng → Tỉnh trong một hình; nhìn thấy ngay các nút lớn, mức độ tập trung (hai đô thị chiếm 18,0% dân số; một vùng chiếm hơn một nửa sản lượng lương thực) và các nút bất thường về màu; phần mềm có khung chi tiết nút, bộ lọc và tìm kiếm để xem chi tiết theo yêu cầu.
- **Hạn chế:** (1) thang màu tuyến tính bị chi phối bởi giá trị ngoại lệ (TP. Hồ Chí Minh), làm phần lớn ô có màu rất tối ở Hình 3.2 đến 3.4; (2) nhãn của các nút nhỏ bị cắt hoặc không hiện, đặc biệt với Slice-and-dice; (3) nhãn của nút lá lấy theo cột đầu tiên của file (Vung) nên tên vùng lặp lại bên trong ô của từng tỉnh; (4) diện tích khó so sánh chính xác bằng độ dài, ví dụ giữa các tỉnh có diện tích gần nhau; (5) mỗi hình chỉ biểu diễn một năm và một thuộc tính màu nên phải dùng tốc độ tăng để thể hiện thay đổi theo thời gian; (6) dữ liệu nguồn phải tiền xử lý khá nhiều mới nạp được.
- **Giải thuật đề xuất cho dữ liệu này và lý do:** Squarified, vì các ô gần vuông giúp so sánh kích thước và chọn từng tỉnh dễ nhất (Hình 3.3); có thể dùng Slice-and-dice khi cần tra cứu theo thứ tự tên hoặc cần bố cục ổn định, và Strip khi cần cân bằng giữa hình dạng và thứ tự. Khi dữ liệu có giá trị ngoại lệ lớn nên đổi thang màu (Square Root, Logarithmic) hoặc chia mức màu.

CHƯƠNG 4. BÀI TẬP 3: XÂY DỰNG TRỰC QUAN CÂY QUYẾT ĐỊNH THEO PBC

4.1. Yêu cầu của đề

- Tải phần mềm tại địa chỉ: http://www.cit.ctu.edu.vn/~dtnghi/dataminingR/VisualDT.zip
- Đọc về giải thuật PBC (xây dựng trực quan cây quyết định) từ bài báo: Mihael Ankerst, Martin Ester, Hans-Peter Kriegel. Towards an effective cooperation of the user and the computer for classification. KDD 2000: 179–188.
- Trình bày ý tưởng của bài viết, xây dựng trực quan cây quyết định.
- Xây dựng cây quyết định cho phân lớp các tập dữ liệu Iris, Segment, Satellite Image.

4.2. Cơ sở lý thuyết: ý tưởng của bài báo PBC

4.2.1. Đặt vấn đề và hạn chế của các phương pháp truyền thống

- **Bản chất "hộp đen":** Các thuật toán xây dựng cây quyết định tự động truyền thống (như C4.5, CART, SLIQ) hoạt động bằng cách tự động tính toán các độ đo toán học thuần túy (chẳng hạn như *Information Gain* hay *Gini Index*) để chọn thuộc tính phân tách (*split attribute*) và điểm chia (*split point*) mà không có sự can thiệp của người dùng.
- **Các hạn chế chính:**
    - Cây quyết định cồng kềnh: Thường sinh ra các cây quá sâu, chứa nhiều nút thừa, dẫn đến hiện tượng khớp quá mức (*overfitting*).
    - Thiếu tri thức chuyên gia: Hoàn toàn bỏ qua tri thức thực tế (*domain knowledge*) của người dùng – những kinh nghiệm nghiệp vụ quý báu không thể đưa vào các công thức toán học cứng nhắc.
    - Thiếu sự tin tưởng: Người dùng không nhận được kết quả trung gian và không hiểu rõ lý do tại sao cây lại đưa ra quyết định phân lớp như vậy.

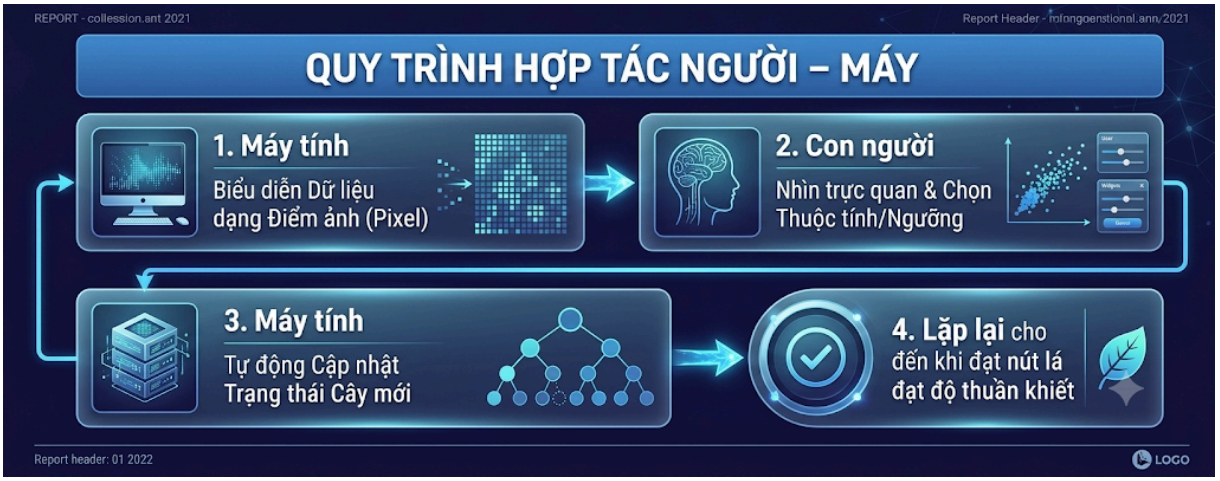
4.2.2. Giải pháp: Hợp tác hiệu quả giữa con người và máy tính (*Human-Computer Cooperation*)

Bài báo nghiên cứu đề xuất mô hình phân lớp lấy người dùng làm trung tâm (*user-centered approach*), kết hợp hài hòa thế mạnh của cả hai phía:

- Thế mạnh của máy tính: Xử lý tính toán khối lượng dữ liệu lớn, hỗ trợ thuật toán tính toán nhanh các gợi ý phân đoạn, mở rộng cây (*look-ahead*) và cập nhật trạng thái trực quan hóa theo thời gian thực.
- Thế mạnh của con người: Sử dụng khả năng nhận dạng mẫu hình ảnh (*pattern recognition*) xuất sắc của thị giác để nhận biết cấu trúc dữ liệu, kết hợp với tri thức chuyên gia để định hướng quá trình tìm kiếm, chọn ngưỡng cắt hợp lý và tránh hiện tượng *overfitting*.

4.2.3. Kỹ thuật xây dựng trực quan cây quyết định (PBC)

Phần cốt lõi của nghiên cứu là kỹ thuật PBC (*Perception-Based Classifier*), hệ thống cho phép trực quan hoá đồng thời dữ liệu và cấu trúc cây quyết định, trong đó dữ liệu được vẽ theo kiểu hướng điểm ảnh.



Hình 4.1. *Quy trình hợp tác Người - Máy*

1. Trực quan hóa Dữ liệu hướng Điểm ảnh (Data Visualization)

- **Ánh xạ Pixel:** Mỗi bản ghi (đối tượng) dữ liệu được biểu diễn bằng một điểm ảnh (*pixel*) trên màn hình.
- **Mã hóa màu sắc:** Lớp (*Class*) của đối tượng được ánh xạ thành các màu sắc trực quan khác nhau.
- **Xử lý thuộc tính:**
    - *Thuộc tính số (Numerical):* Các pixel được sắp xếp theo thứ tự tăng dần từ trái qua phải hoặc từ trên xuống dưới. Nếu các khối màu bị phân tách rõ rệt, đó là thuộc tính phân tách tốt.
    - *Thuộc tính phân loại (Categorical):* Các giá trị rời rạc được gom nhóm và hiển thị sao cho người dùng nhận biết ngay mức độ hỗn loạn (*impurity*) của từng nhóm giá trị.

2. Kỹ thuật Trực quan hóa Tri thức & Cấu trúc Cây (Knowledge Visualization)

Thay vì hiển thị sơ đồ cây dạng nút tròn hoặc hình vuông thông thường, bài báo đề xuất tích hợp trực tiếp biểu đồ pixel vào ngay tại các nút của cây quyết định:

- **Tại mỗi nút (*Node*):** Người dùng quan sát biểu đồ pixel đại diện cho tập dữ liệu con tại nút đó.
- **Độ thuần khiết (*Impurity*):** Được thể hiện qua sự đồng nhất màu sắc. Nút càng đơn sắc thì độ thuần khiết càng cao (đã phân lớp xong, trở thành nút lá). Nút càng nhiều màu xen kẽ thì độ hỗn loạn càng cao (cần tiếp tục chia nhỏ).

3. Các Cơ chế Hỗ trợ Tương tác (Interactive Mechanisms)

- **Chủ động phân tách (*Manual Splitting*):** Người dùng dùng chuột nhấp chọn trực tiếp điểm cắt ngay trên thanh trực quan pixel của thuộc tính được chọn làm nút cha.
- **Tính năng nhìn trước (*Look-ahead*):** Máy tính tự động tính toán trước kết quả của các bước chia tiếp theo và hiển thị trực quan cho người dùng xem thử. Việc này giúp người dùng đưa ra quyết định chọn nhánh tốt nhất mà không cần phải quay lui thủ công (*backtracking*).
- **Đa dạng phong cách hợp tác (*Styles of Cooperation*):**
    - *Hoàn toàn thủ công:* Người dùng tự chọn thuộc tính và điểm chia cho toàn bộ cây.
    - *Mô hình kết hợp (Hybrid):* Người dùng trực tiếp xây dựng 2–3 cấp đầu tiên (những cấp quan trọng nhất ở gốc cây) dựa trên trực quan và tri thức chuyên gia, sau đó bật tính năng tự động để máy tính hoàn thành các nhánh nhỏ phía dưới.
    - *Hoàn toàn tự động:* Chạy thuật toán tự động hoàn toàn khi cần so sánh đối chứng.

4.2.4. Đánh giá hiệu quả và giá trị ứng dụng

1. **Hiệu quả thực nghiệm:** Kết quả thử nghiệm trong bài báo chỉ ra rằng việc xây dựng trực quan cây quyết định có sự can thiệp của con người tạo ra các cấu trúc cây có kích thước nhỏ gọn hơn rất nhiều (ít nút hơn, cấu trúc nông hơn) nhưng độ chính xác phân lớp vẫn tương đương hoặc cao hơn so với phương pháp chạy tự động hoàn toàn.
2. **Giá trị ứng dụng:** Giúp người dùng kinh doanh hoặc các chuyên gia ngành hiểu rõ bản chất dữ liệu, gia tăng độ tin cậy đối với mô hình phân lớp và loại bỏ được các luật thừa không có ý nghĩa thực tế.

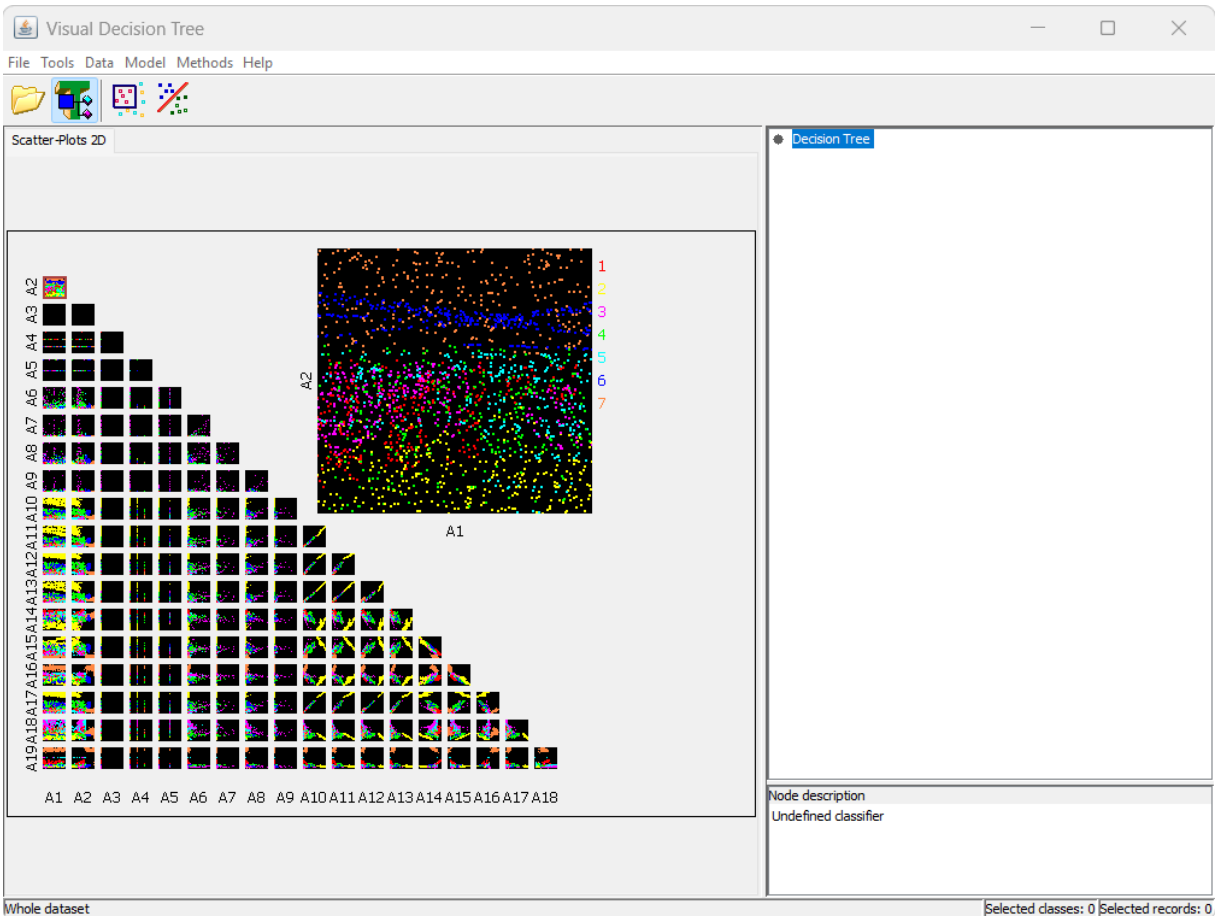
4.3. Quy trình và kết quả xây dựng cây quyết định bằng VisualDT

4.3.1. Phần mềm VisualDT

VisualDT là phần mềm xây dựng cây quyết định trực quan do giảng viên cung cấp (Đỗ Thanh Nghị, Trường Công nghệ thông tin và Truyền Thông, Đại học Cần Thơ), viết bằng Java, theo cùng ý tưởng hợp tác người dùng – máy tính của PBC nhưng sử dụng nhiều góc nhìn được liên kết. Theo bài báo mô tả công cụ, phần mềm có ba phương pháp hiển thị dữ liệu: ma trận biểu đồ phân tán 2D (*scatter-plot matrices*), tọa độ song song (*parallel coordinates*) và biểu diễn dạng thanh (*bar visualization*) như PBC. Các góc nhìn được liên kết (*linking*) và hỗ trợ chọn vùng (*brushing*), thu phóng (*zoom*). Điểm khác biệt chính so với PBC gốc là đường cắt xiên (*oblique cut*) trong ma trận *scatter*: một đường thẳng $a \cdot A_i + b \cdot A_j + c = 0$ trên hai thuộc tính cho phép tách một lớp mà phép chia theo một thuộc tính đơn lẻ không tách được; còn trên thanh và

tọa độ song song, người dùng chọn một thuộc tính và một số tùy ý điểm chia, giống như PBC.

Phần mềm được tải từ địa chỉ trong đề (VisualDT.zip), cần cài đặt Java để chạy; trang giới thiệu của giảng viên là cit.ctu.edu.vn/~dtnghi/vizdt/. Giao diện gồm thanh menu (File, Tools, Data, Model, Methods, Help), thanh công cụ (mở file và các phương pháp hiển thị), khung bên trái hiển thị dữ liệu (tab *Scatter-Plots 2D*), khung bên phải hiển thị cây quyết định và ô *Node Description* bên dưới cây cho biết số nút quyết định, số lá, số phần chưa gán nhãn và số lỗi trên tập huấn luyện.



Hình 4.2. *Giao diện phần mềm VisualDT*

4.3.2. Quy trình thực hiện tổng quát

Quy trình xây dựng mô hình cây quyết định tương tác trên phần mềm VisualDT được thực hiện tuần tự qua các bước sau:

1. **Khởi tạo dữ liệu:** Mở tệp dữ liệu cần khảo sát thông qua chức năng.
2. **Khảo sát góc nhìn tối ưu:** Quan sát ma trận *Scatter-plots*, lựa chọn ô biểu đồ cặp thuộc tính có khoảng trống hoặc ranh giới phân tách rõ rệt nhất giữa các lớp màu.
3. **Vẽ đường ranh giới (Nhát cắt):** Sử dụng chuột để vẽ đường thẳng ranh giới phân tách lớp (đường cắt đơn biến hoặc đường cắt xiên dạng

$a \cdot A_i + b \cdot A_j + c = 0$) trên ô biểu đồ phóng to; hệ thống sẽ tự động cập nhật các nhánh con (Pos part / Neg part) tương ứng vào khung cây bên phải.

4. **Gán nhãn phân lớp (*Set to class*):**
    - Nhấp chọn vào các nút lá mới được sinh ra (Pos part hoặc Neg part) trong khung *Decision Tree*.
    - Quan sát màu sắc chủ đạo của các điểm dữ liệu trong vùng phân chia, đối chiếu với bảng mã màu (*legend*) ở góc trên bên phải biểu đồ.
    - Nhấp chuột phải vào vùng biểu đồ tương ứng, chọn lệnh **Set to class...** và chỉ định đúng số thứ tự hoặc nhãn lớp (ví dụ: 0, 1, 2 đối với tập Iris; TB, K, G đối với tập điểm số học tập) để định danh dứt khoát cho nút lá, giúp đưa trạng thái Undefined về 0.
5. **Tinh chỉnh đa tầng:** Lặp lại các bước 3 và 4 cho các nhánh con chưa thuần khiết (có thể thay đổi linh hoạt sang các cặp thuộc tính khác trong ma trận để tìm khoảng trống phân tách tốt hơn nhằm giảm thiểu số lỗi).
6. **Lưu trữ mô hình:** Kiểm tra lại các thông số tổng quan tại nút gốc (*Leaves, Errors*) và xuất lưu cấu trúc cây hoàn chỉnh thông qua chức năng (Model → Save tree model).

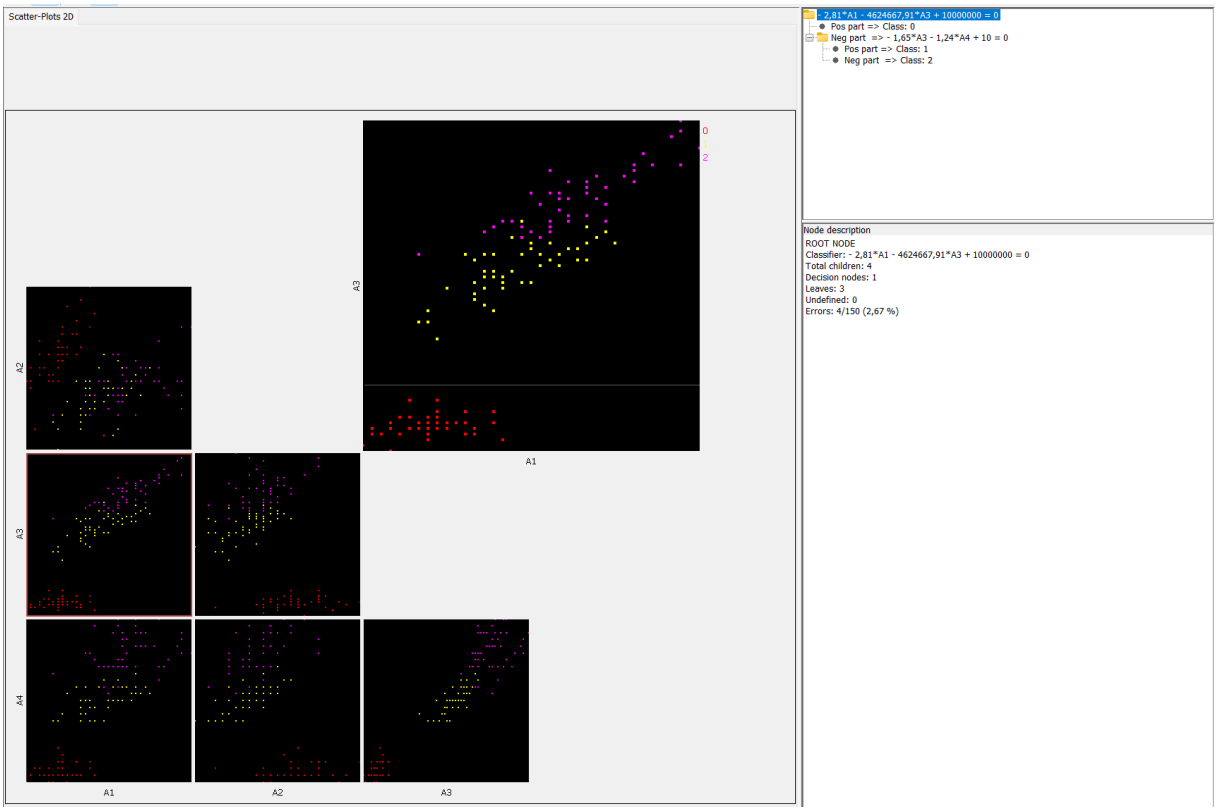
4.3.3. Kết quả trên từng tập dữ liệu

A. Bộ dữ liệu Iris

- **Đặc điểm:** Dữ liệu mẫu nhỏ, các lớp phân tách tốt chỉ với một vài nhát cắt đơn giản.
- **Chiến lược phân tách:**
    - *Lần cắt 1:* Bóc tách hoàn toàn lớp màu đỏ ra khỏi nhóm màu vàng và tím bằng cặp thuộc tính (A_1, A_3).
    - *Lần cắt 2:* Chọn nhánh con Neg part, tiếp tục vẽ đường cắt thứ hai để phân tách hoàn toàn lớp màu vàng và lớp màu tím.
- **Phương trình ranh giới thu được:**
    - Đường 1 (Nút gốc):
      $-2.83 \cdot A_1 - 4624667,91 \cdot A_3 + 10000000 = 0$
    - Đường 2 (Nhánh âm):

      $$-1,65 \cdot A_3 - 1,24 \cdot A_4 + 10 = 0$$

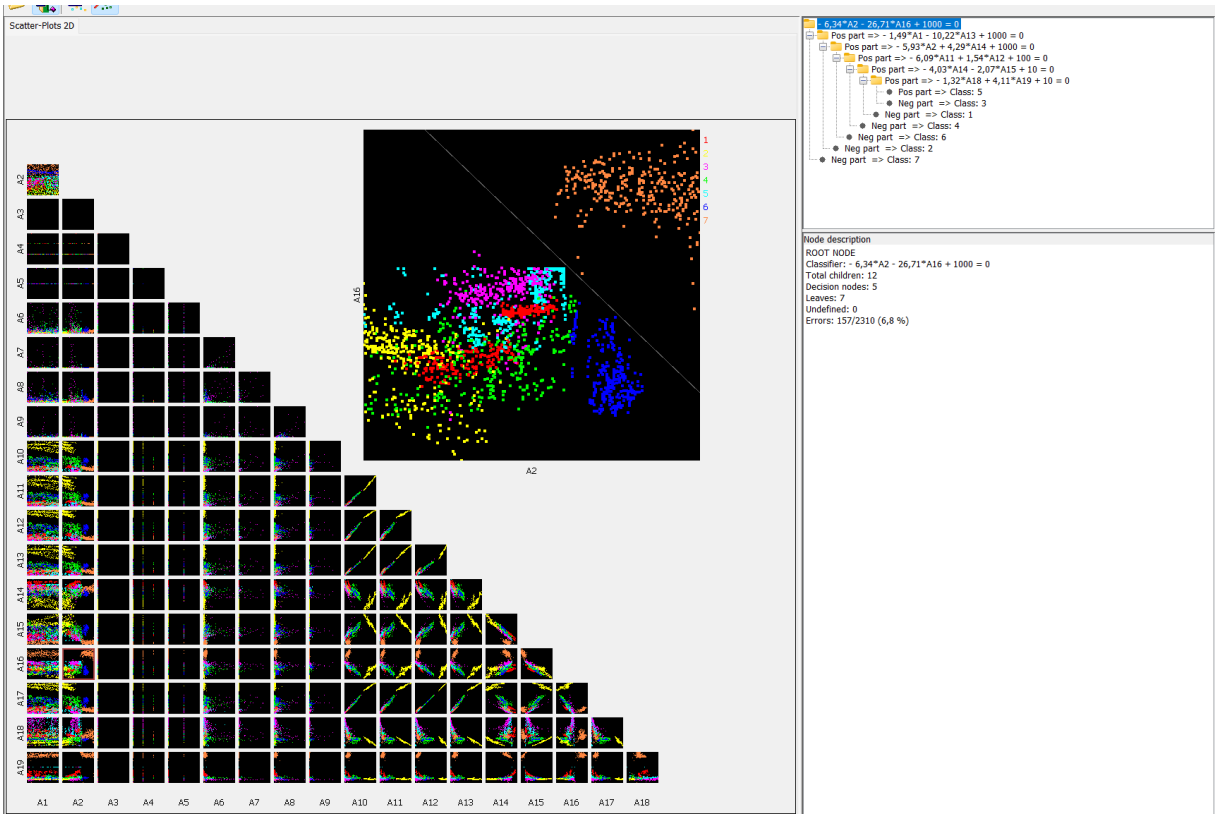
- **Kết quả thống kê:**
    - Số nút quyết định (*Decision nodes*): 1
    - Số nút lá (*Leaves*): 3
    - Tỷ lệ lỗi (*Errors*): 4/150 (2,67 %).



Hình 4.3. *Giao diện phần mềm VisualDT và kết quả xây dựng cây quyết định trên tập Iris*

B. Bộ dữ liệu Segment

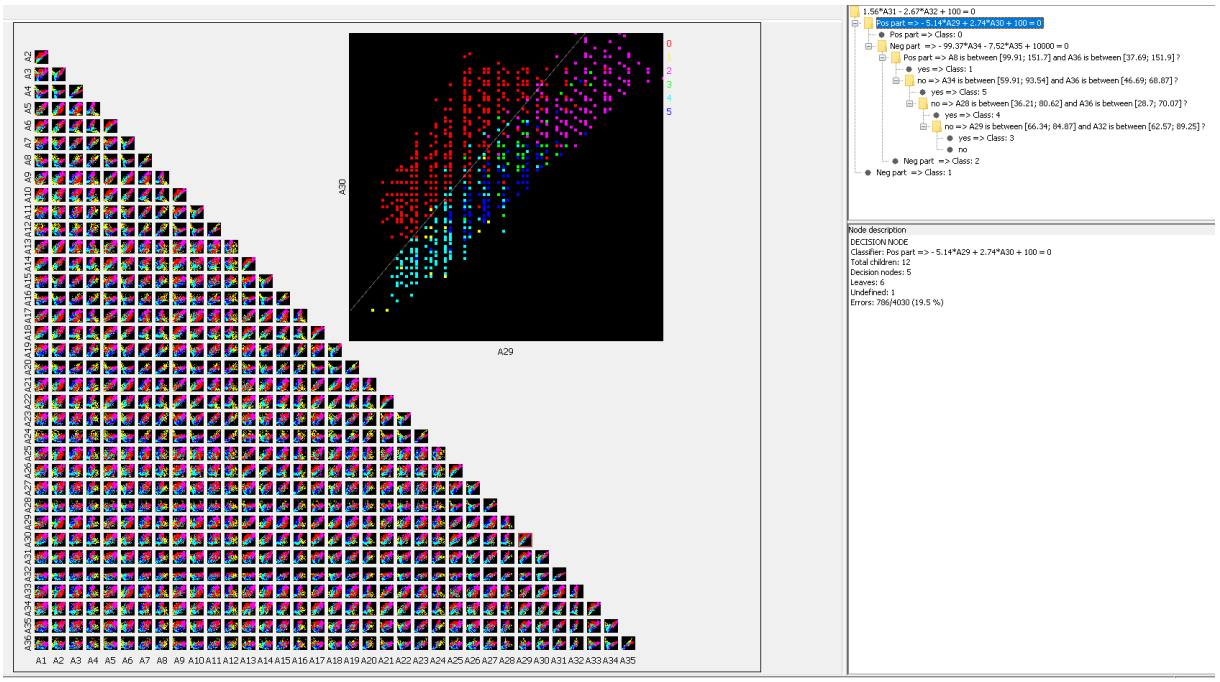
- **Đặc điểm:** Gồm 7 lớp màu chồng chéo phức tạp, không thể sử dụng một ô thuộc tính đơn lẻ cho toàn bộ cấu trúc cây.
- **Chiến lược phân tách tầng:**
  - *Nút gốc (Tầng 1):* Chọn ô thuộc tính (A_2, A_{16}) do ô này xuất hiện khoảng trống rất rộng, giúp bóc tách sạch 100% lớp màu cam ở phía trên đỉnh ra khỏi các lớp còn lại bên dưới.
  - *Các tầng tiếp theo:* Lần lượt chọn các nhánh con chứa các màu hỗn hợp, chuyển sang quan sát các ô cặp thuộc tính khác (như $A_1 - A_{13}$, $A_2 - A_{14}$,...) để bóc tách dần các lớp màu vàng, xanh lá, xanh dương và hồng,...
- **Kết quả thống kê:**
  - Số nút quyết định (*Decision nodes*): 5
  - Số nút lá (*Leaves*): 7
  - Tỷ lệ lỗi tổng thể (*Errors*): 157/2310 (6.8%)

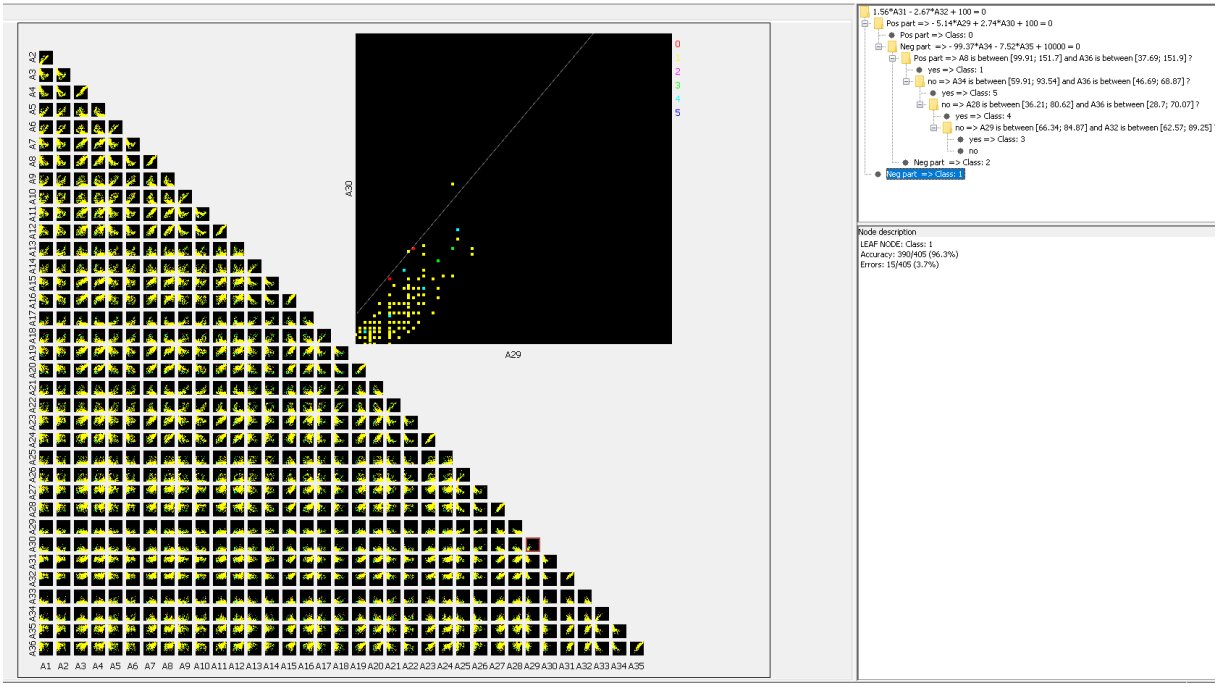


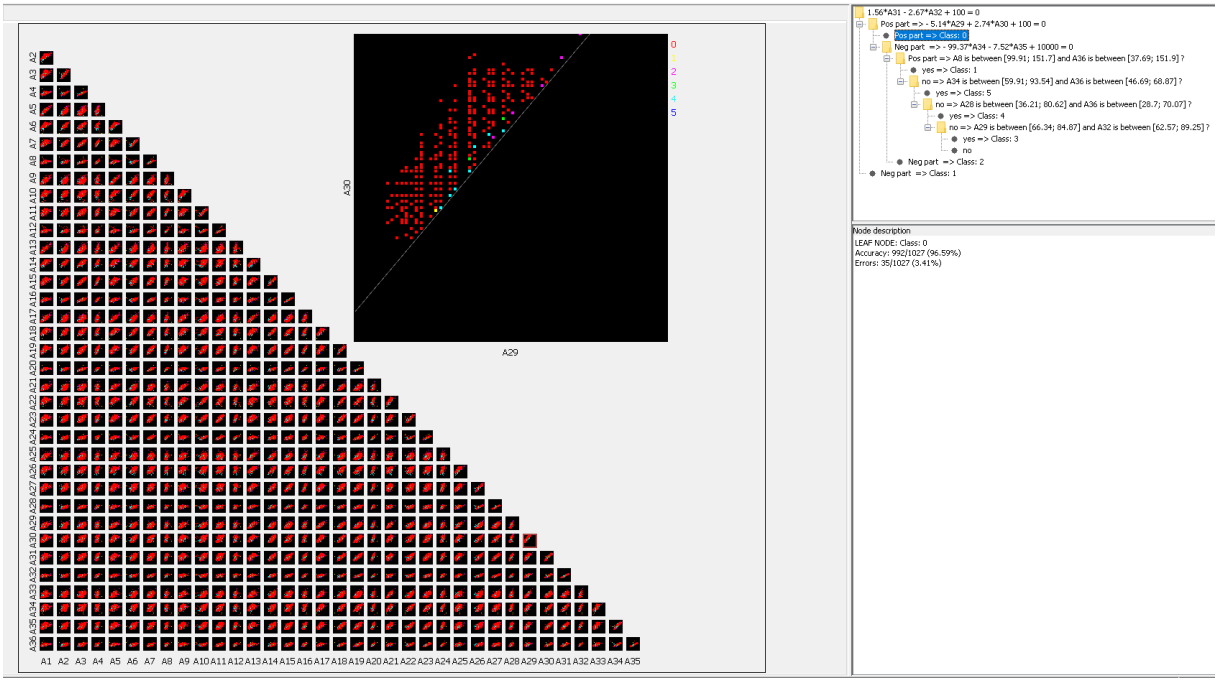
Hình 4.4. *Giao diện phần mềm VisualDT và kết quả xây dựng cây quyết định trên tập Segment*

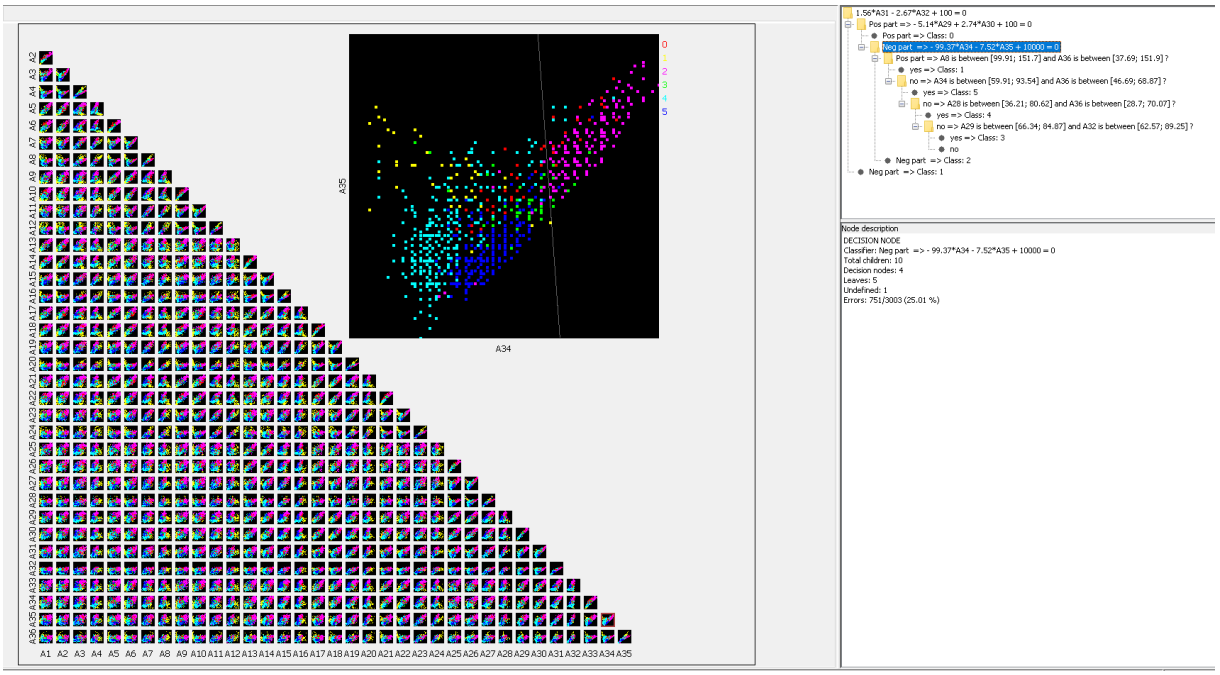
C. Bộ dữ liệu Satellite Image

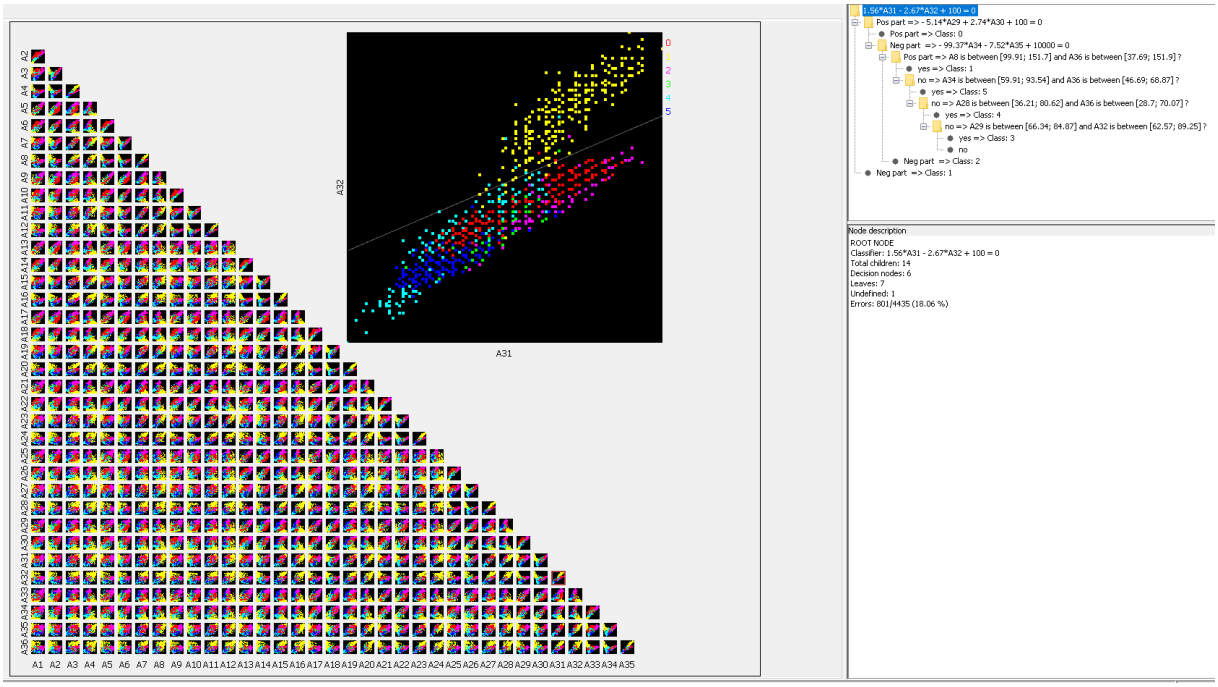
- **Đặc điểm:** Tập dữ liệu viễn thám có quy mô lớn, bao gồm 36 thuộc tính (từ A_1 đến A_36) và 6 lớp phân loại, đặc trưng bởi mật độ phân bố điểm dữ liệu rất dày đặc và mức độ đan xen phức tạp giữa các lớp.
- **Chiến lược thực hiện:** Áp dụng linh hoạt việc lựa chọn các cặp thuộc tính trên ma trận biểu đồ 2D cho từng nhánh con (ví dụ: khảo sát cặp thuộc tính (A_{31}, A_{32}) tại nút gốc), sử dụng nhát cắt xiên ($1.56 \cdot A_{31} - 2.67 \cdot A_{32} + 100 = 0$) để bóc tách các không gian dữ liệu đa chiều, tập trung xử lý các cụm lớn trước nhằm hạ nhanh tỷ lệ lỗi tổng thể, đồng thời kiểm soát cấu trúc để tránh hiện tượng quá khớp.
- **Kết quả tổng hợp:**
  - Số nút quyết định (*Decision nodes*): 6
  - Số nút lá (*Leaves*): 7
  - Tỷ lệ lỗi (*Errors*): 801 / 4435 (18.06 %)


1.56*A31 - 2.67*A32 + 100 = 0
Pos part => - 5.14*A29 + 2.74*A30 + 100 = 0
Pos part => Class: 0
Neg part => - 99.37*A34 - 7.52*A35 + 10000 = 0
Pos part => A8 is between [99.91; 151.7] and A36 is between [37.69; 151.9] ?
yes => Class: 1
no => A34 is between [59.91; 93.54] and A36 is between [46.69; 68.87] ?
yes => Class: 5
no => A28 is between [36.21; 80.62] and A36 is between [28.7; 70.07] ?
yes => Class: 4
no => A29 is between [66.34; 84.87] and A32 is between [62.57; 89.25] ?
yes => Class: 3
no
Neg part => Class: 2
Neg part => Class: 1
Node description
DECISION NODE
Classifier: Pos part => - 5.14*A29 + 2.74*A30 + 100 = 0
Total children: 12
Decision nodes: 5
Leaves: 6
Undefined: 1
Errors: 786/4030 (19.5 %)
A30
A29
A1 A2 A3 A4 A5 A6 A7 A8 A9 A10 A11 A12 A13 A14 A15 A16 A17 A18 A19 A20 A21 A22 A23 A24 A25 A26 A27 A28 A29 A30 A31 A32 A33 A34 A35
A2 A3 A4 A5 A6 A7 A8 A9 A10 A11 A12 A13 A14 A15 A16 A17 A18 A19 A20 A21 A22 A23 A24 A25 A26 A27 A28 A29 A30 A31 A32 A33 A34 A35 A36
0 1 2 3 4 5


1.56*A31 - 2.67*A32 + 100 = 0
Pos part => - 5.14*A29 + 2.74*A30 + 100 = 0
Pos part => Class: 0
Neg part => - 99.37*A34 - 7.52*A35 + 10000 = 0
Pos part => A8 is between [99.91; 151.7] and A36 is between [37.69; 151.9] ?
yes => Class: 1
no => A34 is between [59.91; 93.54] and A36 is between [46.69; 68.87] ?
yes => Class: 5
no => A28 is between [36.21; 80.62] and A36 is between [28.7; 70.07] ?
yes => Class: 4
no => A29 is between [66.34; 84.87] and A32 is between [62.57; 89.25] ?
yes => Class: 3
no
Neg part => Class: 2
Neg part => Class: 1
Node description
LEAF NODE: Class: 1
Accuracy: 390/405 (96.3%)
Errors: 15/405 (3.7%)
A30
A29
A1 A2 A3 A4 A5 A6 A7 A8 A9 A10 A11 A12 A13 A14 A15 A16 A17 A18 A19 A20 A21 A22 A23 A24 A25 A26 A27 A28 A29 A30 A31 A32 A33 A34 A35
A2 A3 A4 A5 A6 A7 A8 A9 A10 A11 A12 A13 A14 A15 A16 A17 A18 A19 A20 A21 A22 A23 A24 A25 A26 A27 A28 A29 A30 A31 A32 A33 A34 A35 A36
0 1 2 3 4 5


1.56*A31 - 2.67*A32 + 100 = 0
Pos part => - 5.14*A29 + 2.74*A30 + 100 = 0
Pos part => Class: 0
Neg part => - 99.37*A34 - 7.52*A35 + 10000 = 0
Pos part => A8 is between [99.91; 151.7] and A36 is between [37.69; 151.9] ?
yes => Class: 1
no => A34 is between [59.91; 93.54] and A36 is between [46.69; 68.87] ?
yes => Class: 5
no => A28 is between [36.21; 80.62] and A36 is between [28.7; 70.07] ?
yes => Class: 4
no => A29 is between [66.34; 84.87] and A32 is between [62.57; 89.25] ?
yes => Class: 3
no
Neg part => Class: 2
Neg part => Class: 1
Node description
LEAF NODE: Class: 0
Accuracy: 992/1027 (96.59%)
Errors: 35/1027 (3.41%)
A30
A29
0
1
2
3
4
5


1.56*A31 - 2.67*A32 + 100 = 0
Pos part => - 5.14*A29 + 2.74*A30 + 100 = 0
Pos part => Class: 0
Neg part => - 99.37*A34 - 7.52*A35 + 10000 = 0
Pos part => A8 is between [99.91; 151.7] and A36 is between [37.69; 151.9] ?
yes => Class: 1
no => A34 is between [59.91; 93.54] and A36 is between [46.69; 68.87] ?
yes => Class: 5
no => A28 is between [36.21; 80.62] and A36 is between [28.7; 70.07] ?
yes => Class: 4
no => A29 is between [66.34; 84.87] and A32 is between [62.57; 89.25] ?
yes => Class: 3
no
Neg part => Class: 2
Neg part => Class: 1
Node description
DECISION NODE
Classifier: Neg part => - 99.37*A34 - 7.52*A35 + 10000 = 0
Total children: 10
Decision nodes: 4
Leaves: 5
Undefined: 1
Errors: 751/3003 (25.01 %)
A35
A34
0
1
2
3
4
5



Hình 4.5. *Giao diện phần mềm VisualDT và kết quả xây dựng cây quyết định trên tập dữ liệu Satellite Image*

4.4. Nhận xét và đánh giá

4.4.1. Hiểu dữ liệu qua phương pháp Trực quan hóa Tương tác

Quá trình trực tiếp quan sát và xây dựng cây quyết định trên giao diện VisualDT mang lại những góc nhìn sâu sắc mà các thuật toán tự động truyền thống (như C4.5, CART) thường che khuất:

- **Phát hiện sự phân tách dứt khoát giữa các lớp:**
  - Ở tập Iris, lớp màu đỏ (Setosa) hoàn toàn tách biệt khỏi hai lớp còn lại ngay từ góc nhìn 2D (A_1, A_3).
  - Ở tập Segment, ma trận tán xạ cho thấy lớp màu cam ($Class\ 5$) và lớp màu xanh dương ($Class\ 3$) nằm tách biệt rõ rệt ở các khoảng không gian góc, cho phép bóc tách 100% các lớp này chỉ bằng 1 nhát cắt xiên mà không bị lẫn lộn.
  - Ở tập Satellite (36 thuộc tính, 6 lớp), dữ liệu có độ mật độ phân bố cực kỳ dày đặc và đan xen phức tạp trên ma trận 36x36. Việc trực quan hóa giúp người dùng nhận diện được các không gian phân vùng cục bộ mà mắt thường có thể khoanh vùng.
- **Đường cắt xiên (*Oblique Cut*) vượt trội so với chia đơn biến (*Axis-parallel Split*):**
  - Các thuật toán tự động thông thường chỉ thực hiện các đường cắt vuông góc với trục tọa độ ($A_i \leq \theta$).

- VisualDT cho phép vẽ đường cắt xiên $a \cdot A_i + b \cdot A_j + c = 0$. Ví dụ trong tập Segment, đường cắt xiên $-6.34 \cdot A_2 - 26.71 \cdot A_{16} + 1000 = 0$ tại nút gốc đã phân tách dứt khoát nhóm lớn màu cam ra khỏi cụm màu hỗn hợp bên dưới. Điều này giúp bóc tách các vùng dữ liệu bị phân tách theo đường chéo mà nếu dùng đường chia đơn biến sẽ phải mất rất nhiều nhát cắt bậc thang (gây phình to cây).

4.4.2. Kích thước Cây và Độ chính xác (So sánh với Bài báo PBC)

Kết quả thực nghiệm hoàn toàn phù hợp và minh chứng cho khẳng định của bài báo lý thuyết PBC: Cây quyết định tương tác thủ công có kích thước nhỏ gọn hơn rất nhiều nhưng vẫn đảm bảo độ chính xác cao.

- **Bảng tổng hợp kết quả thực nghiệm:**

Tập dữ liệu	Số thuộc tính / Nhãn	Số nút quyết định	Số nút lá	Tỷ lệ lỗi
Iris	4 thuộc tính / 3 lớp	1	3	2.67% (4/150)
Segment	19 thuộc tính / 7 lớp	5	7	6.8% (157/2310)
Satellite	36 thuộc tính / 6 lớp	6	7	18.06% (801/4435)

Đánh giá:

- Kích thước tối giản: Với tập dữ liệu lớn và phức tạp như Satellite (hơn 4.400 mẫu, 36 thuộc tính), mô hình cây tương tác thủ công vẫn duy trì cấu trúc cực kỳ gọn gàng với chỉ 6 nút quyết định và 7 nút lá.
- **Sai số chấp nhận được:** Tỷ lệ lỗi 18.06% trên tập Satellite quy mô lớn thể hiện sự cân bằng tốt giữa kích thước cây nhỏ gọn và khả năng khái quát hóa, tránh hiện tượng phình to cây hoặc học vẹt thường gặp ở các thuật toán tự động hoàn toàn.

4.4.3. Đánh giá chi phí và phạm vi ứng dụng

- **Chi phí thao tác và thời gian:**
  - *Tập dữ liệu nhỏ/vừa (Iris):* Thao tác thủ công cực kỳ nhanh chóng (chỉ mất 1–2 phút cho mỗi tập), người dùng chỉ cần 1–2 lần kéo chuột vẽ đường ranh giới là hoàn thành mô hình.

- *Tập dữ liệu nhiều lớp (Segment):* Mất nhiều thời gian hơn để rà soát ma trận 2D tìm góc chiếu tối ưu và chọn các cặp thuộc tính cho từng nhánh con.
- *Tập dữ liệu lớn, nhiều chiều (Satellite - 36 thuộc tính):* Đòi hỏi chi phí thời gian và công sức lớn hơn đáng kể từ phía người dùng. Do số lượng thuộc tính lên tới 36, ma trận 2D trở nên đồ sộ, việc tìm kiếm cặp thuộc tính có không gian phân tách tối ưu đòi hỏi nhiều bước rà soát (*brushing*, *linking*) và tinh chỉnh đa tầng.

- **Phạm vi ứng dụng phù hợp:** Phương pháp trực quan tương tác thích hợp nhất với các bài toán quy mô nhỏ và vừa, hoặc các bài toán đòi hỏi tính diễn giải cao (*Explainable AI - XAI*).
- **Hạn chế:** Đối với các tập dữ liệu có số chiều cực lớn (như Satellite với 36 biến) và các lớp dữ liệu chồng chéo cao, việc thao tác hoàn toàn thủ công sẽ gặp khó khăn, dễ dẫn đến tỷ lệ lỗi cao hơn hoặc tốn thời gian dò tìm đường cắt.

4.4.4. Phong cách hợp tác người - máy trong VisualDT

Theo nguyên lý của bài báo PBC, mô hình hợp tác Hybrid là giải pháp cân bằng tốt nhất giữa độ chính xác, kích thước cây và thời gian thực hiện.

- **Mức độ hỗ trợ của VisualDT:**
  - VisualDT hỗ trợ xuất sắc vai trò người dùng làm trung tâm: máy tính xử lý trực quan hóa tức thì ma trận 2D, cập nhật phương trình đường thẳng và tính toán chính xác số lượng lỗi/nút lá theo thời gian thực ngay khi người dùng kéo chuột.
  - Tuy nhiên, VisualDT hiện tại vẫn nghiêng nhiều về thao tác thủ công tương tác (người dùng tự chọn ô và vẽ đường cắt). Để đạt tới mô hình Hybrid lý tưởng như bài báo PBC đề xuất, công cụ có thể nâng cấp thêm tính năng tự động gợi ý nhát cắt tối ưu (*Look-ahead recommendation*) tại các nhánh con ở tầng sâu để giảm tải cho người dùng.

4.4.5. Kết luận Chương

Thực nghiệm trên phần mềm VisualDT với 3 tập dữ liệu thực tế đã khẳng định tính hiệu quả vượt trội của phương pháp Khai phá dữ liệu trực quan tương tác (PBC). Việc kết hợp thị giác con người với sức mạnh tính toán của máy tính giúp tạo ra những cây quyết định có cấu trúc cực kỳ gọn nhẹ, khả năng diễn giải minh bạch và kiểm soát tỷ lệ lỗi ở mức tối ưu. Đây là minh chứng rõ nét cho thấy sự can thiệp của tri thức người dùng có thể giải quyết dứt điểm điểm yếu "hộp đen" và hiện tượng phình to cây của các thuật toán phân lớp tự động truyền thống.

CHƯƠNG 5. BÀI TẬP 4: SỬ DỤNG TREEVIEW

5.1. Yêu cầu của đề

- Download TreeView: bản Windows (TreeView-Win.zip), macOS x86 (TreeView.app.zip) hoặc macOS M-series (TreeView-m4.app.zip) từ địa chỉ trong đề.
- Xây dựng và hiển thị cây quyết định cho phân lớp dữ liệu spambase và kddcup 1999 (tải spambase.zip, kdd.zip).
- Trả lời ba câu hỏi: (1) Có bao nhiêu luật quyết định? (2) Liệt kê các luật theo bạn là quan trọng và giải thích lý do. (3) Chọn một view theo bạn hiệu quả cho hiển thị cây quyết định và giải thích lý do.

5.2. Cơ sở lý thuyết

5.2.1. Luật quyết định từ cây

Mỗi đường đi từ gốc đến một nút lá của cây quyết định tương ứng với đúng một luật dạng IF–THEN: phần điều kiện là hội (AND) của các kiểm tra dọc đường đi, phần kết luận là lớp của lá. Vì vậy số luật bằng số nút lá của cây, và các luật loại trừ lẫn nhau, bao phủ toàn bộ không gian dữ liệu. Ví dụ minh hoạ định dạng (không phải kết quả thật): IF char_freq_$ > 0,055 AND word_freq_remove > 0,01 THEN lớp = spam.

5.2.2. Độ đo đánh giá luật

Độ đo	**Ý nghĩa**	**Công thức**
Support (độ phủ)	Số mẫu (hoặc tỉ lệ) thoả điều kiện của luật	n(điều kiện) hoặc n/N
Confidence (độ tin cậy / độ thuần)	Trong các mẫu thoả điều kiện, tỉ lệ mẫu đúng lớp kết luận	n(điều kiện ∧ lớp) / n(điều kiện)
Độ dài luật	Số điều kiện trong phần IF; càng ngắn càng dễ hiểu, càng tổng quát	Độ sâu của lá
Độ chính xác tổng thể	Tỉ lệ mẫu kiểm tra phân lớp đúng bởi toàn bộ cây	Số đúng / tổng số

5.2.3. Các kiểu hiển thị (view) cho cây quyết định

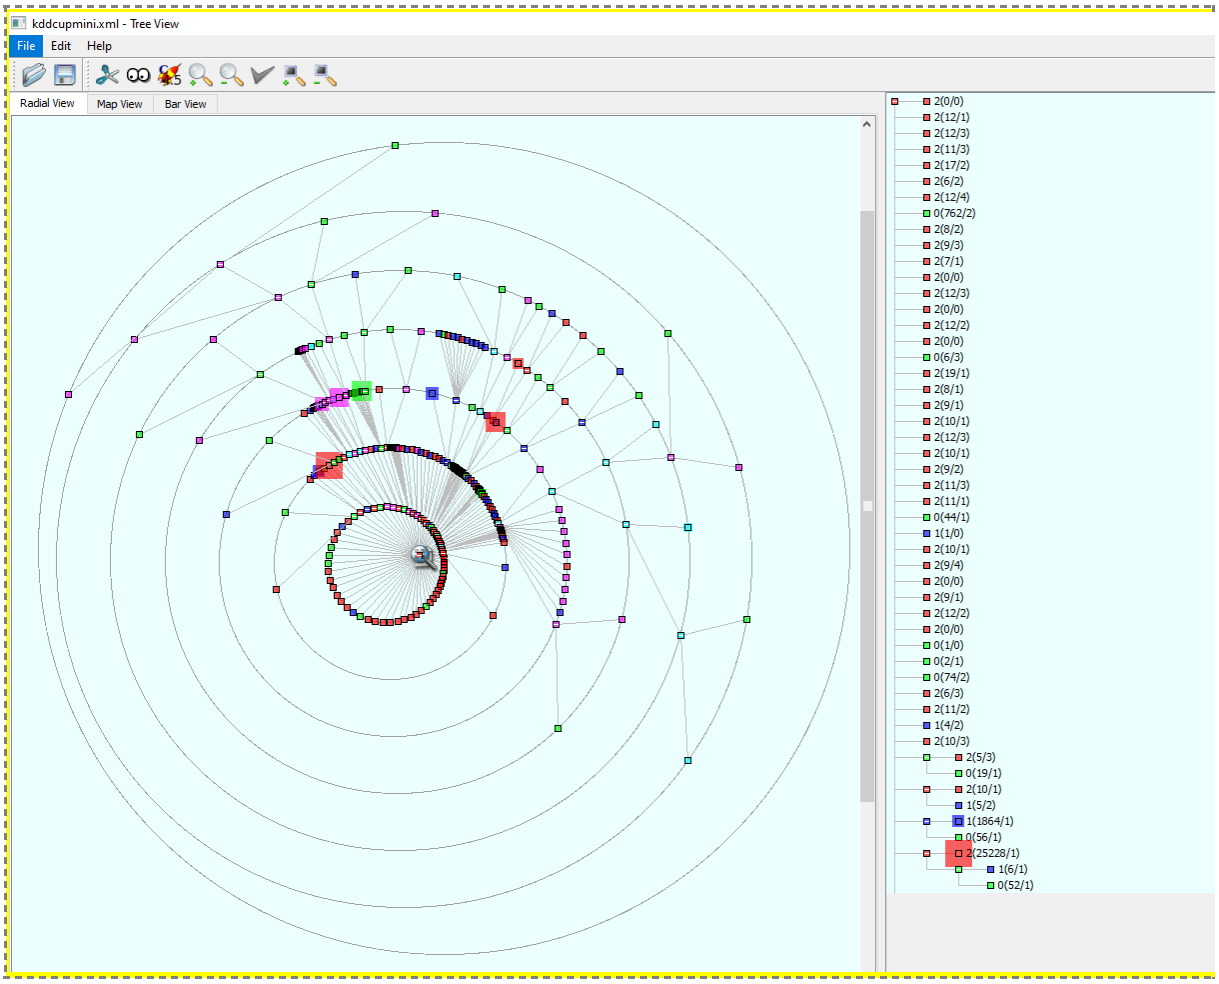
Một cây lớn có thể được thể hiện theo nhiều cách: sơ đồ nút-liên kết (node-link) cổ điển; hiển thị không gian đầy (treemap, icicle, sunburst) và các biến thể khác. Mỗi kiểu có đánh đổi giữa khả năng đọc cấu trúc, đọc điều kiện chia, thấy phân bố lớp tại nút, và khả năng mở rộng khi cây có hàng trăm nút lá. Danh sách view thực tế do phần mềm TreeView cung cấp được ghi ở mục 5.4.

5.3. Dữ liệu

Tập dữ liệu	Số mẫu	Thuộc tính	Lớp	Nguồn
spambase	4.601 mẫu trong tập gốc; cây được xây trên 3.601 mẫu (tổng items của các lá)	57 thuộc tính số: 48 tần suất từ (word_freq_…), 6 tần suất ký tự (char_freq_…), 3 độ dài chuỗi chữ hoa (capital_run_length_…)	2: spam, non_spam (spam khoảng 39,4% tập gốc)	UCI Spambase
kddcup 1999	67.746 mẫu (tổng items của các lá cây kddcupmini)	41 thuộc tính (cơ bản, nội dung, lưu lượng theo thời gian, theo máy chủ); gồm cả thuộc tính danh nghĩa (protocol_type, service, flag)	5 mã lớp 0–4: Normal và 4 nhóm tấn công (DoS, Probe, R2L, U2R)	KDD Cup 1999 (UCI)

Với spambase, vì chỉ có hai lớp nên từ số mẫu và số lỗi ở các lá có thể suy ra thành phần thật của 3.601 mẫu: 1.443 thư spam (40,1%) và 2.158 thư hợp lệ (59,9%), gần với tỉ lệ 39,4% của toàn tập. Với kddcup, tệp XML chỉ lưu mã lớp 0–4 mà không lưu tên lớp. Căn cứ vào dịch vụ mà các lá tập trung, có thể hiểu lớp 0 là kết nối bình thường (http, smtp, domain_u), lớp 1 là thăm dò/quét (eco_i, other với src_bytes rất nhỏ) và lớp 2 là từ chối dịch vụ (ecr_i, private); lớp 3 và 4 tập trung ở các dịch vụ ftp, ftp_data và telnet. Đây là diễn giải của nhóm; tên lớp chính thức cần đối chiếu với tệp dữ liệu trong kdd.zip, và trong báo cáo các luật được ghi theo mã lớp.

5.4. Cài đặt và xây dựng cây bằng TreeView



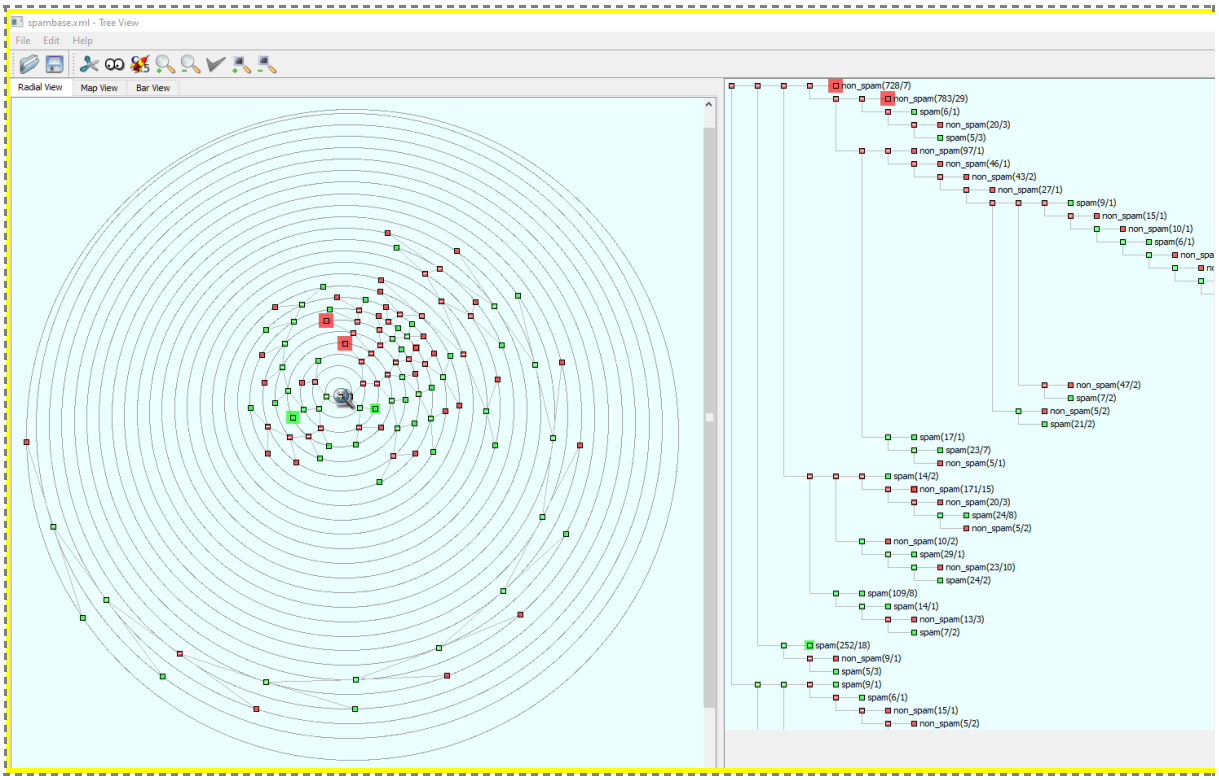
Hình 5.1. *Giao diện phần mềm TreeView*

Cửa sổ TreeView gồm thanh công cụ (mở/lưu tệp, thu phóng, mở rộng/thu gọn nút…), ba thẻ view ở phía trên vùng vẽ là Radial View, Map View và Bar View, và cột bên phải liệt kê cây dưới dạng danh sách thụt lề. Mỗi nút lá trong cột này có nhãn lớp(items/errors). Màu của nút mã hoá lớp (ví dụ spambase: đỏ là non_spam, xanh lá là spam) và kích thước nút phản ánh số mẫu. Cây được lưu thành tệp XML gồm các phần tử Node lồng nhau: nút trong chứa điều kiện chia (op), nút lá có thêm class, items và errors.

Các cây được ghi nhận ở trạng thái cuối cùng đã lưu như bảng dưới. Thuộc tính số được chia nhị phân (≤ / >) tại một ngưỡng, thuộc tính danh nghĩa được chia nhiều nhánh, mỗi giá trị một nhánh (service có 70 nhánh, flag có 11 nhánh).

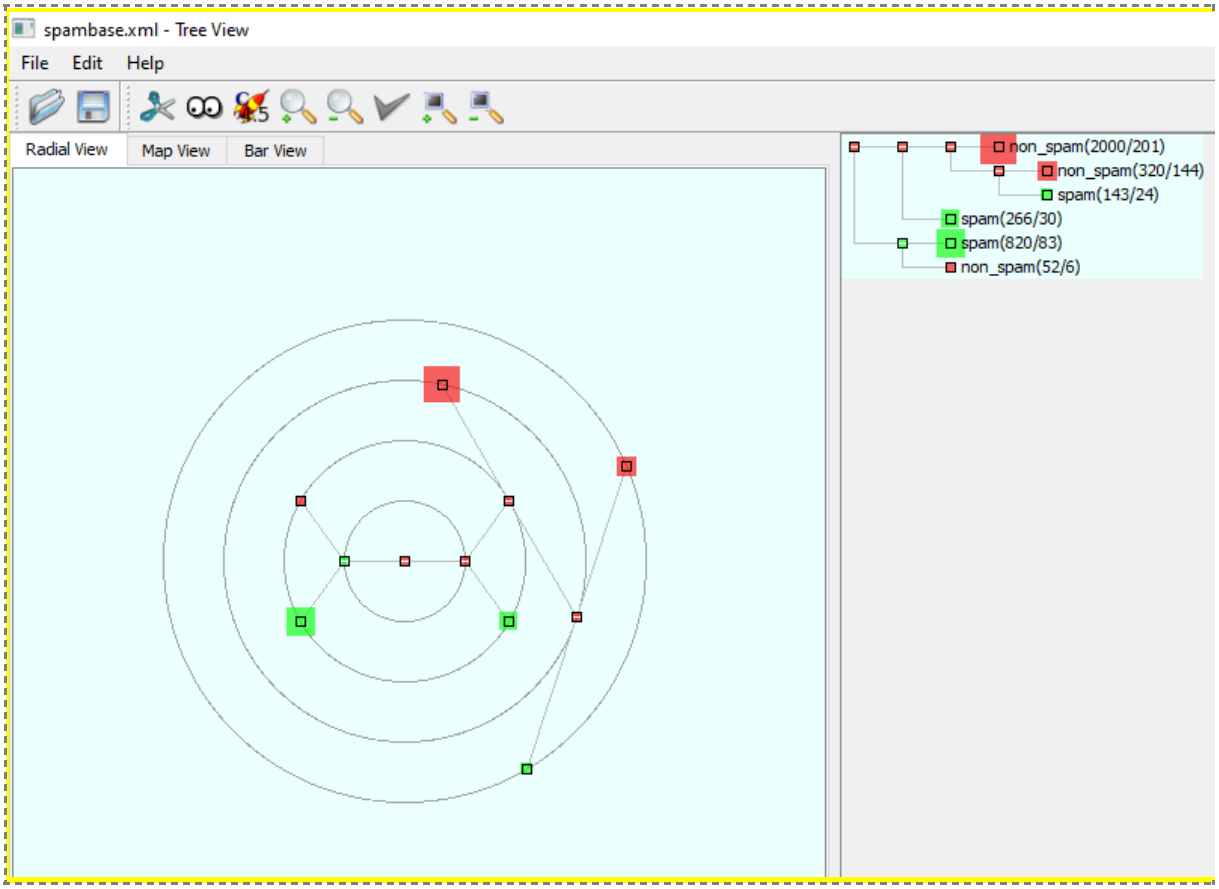
Tệp	**Tập dữ liệu**	**Số mẫu ở các lá**	**Ghi chú**
spambase_1.xml	spambase	3.601	Cây nhỏ, 6 lá, gốc chia theo char_freq_$; chỉ dùng 5/57 thuộc tính

Tệp	Tập dữ liệu	Số mẫu ở các lá	Ghi chú
kddcupmini1.xml	kddcup 1999	67.746	130 lá; gốc chia theo service thành 70 nhánh; 23 dịch vụ được chia tiếp (src_bytes, flag, srv_count…)
kddcupmini2.xml	kddcup 1999	67.746	108 lá; không chia tiếp 4 dịch vụ eco_i, finger, pop_3, smtp so với kddcupmini1, nhưng chia thêm ecr_i theo src_bytes



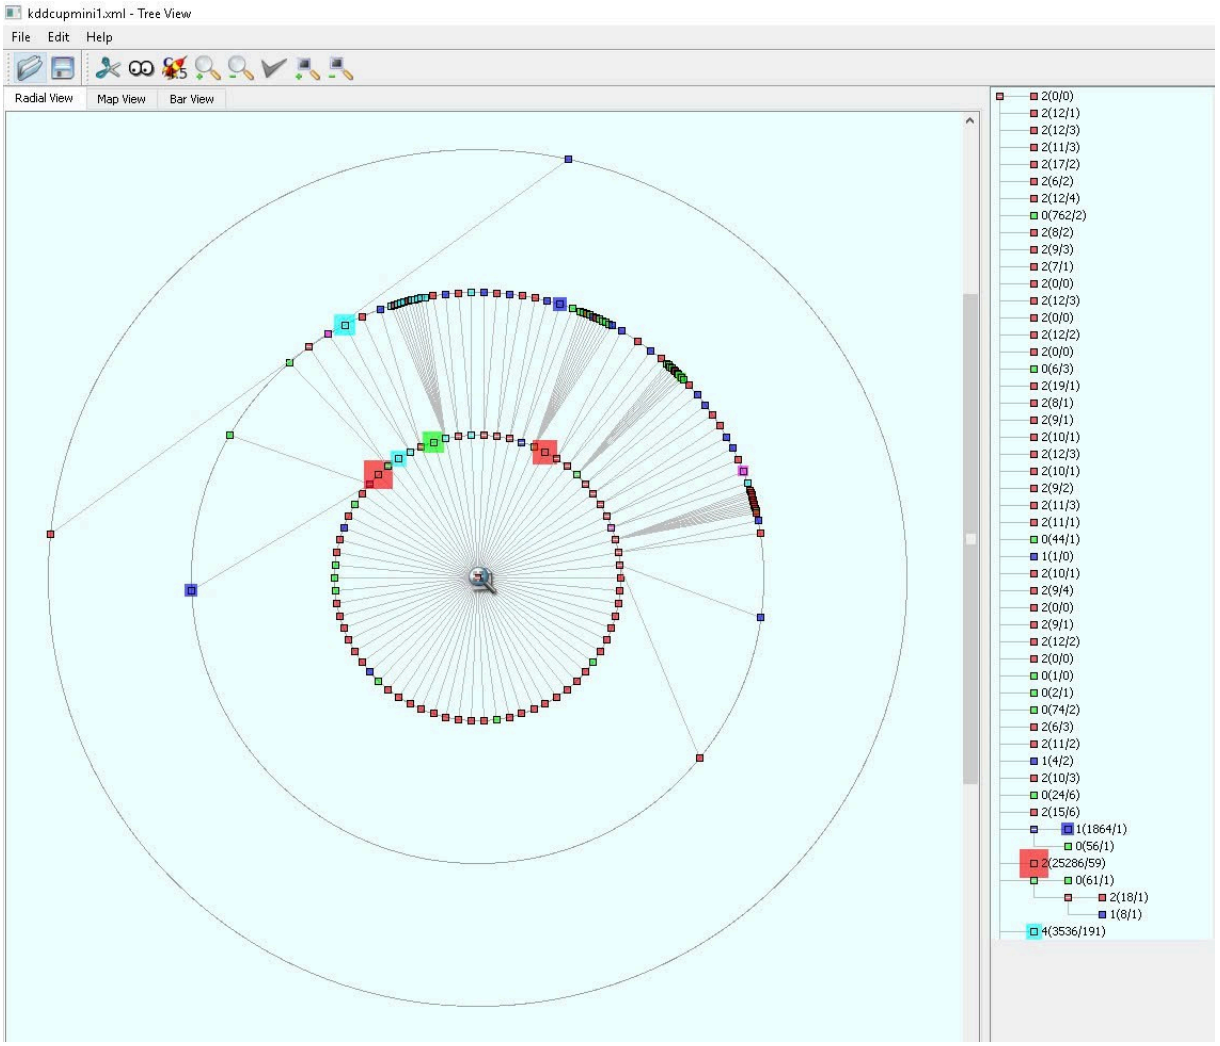
Hình 5.2. *Cây quyết định spambase ở view Radial View*

Hình 5.2 là cây spambase ở mức mở rộng nhiều: các nút trải trên hơn mười vòng đồng tâm, mỗi vòng ứng với một mức sâu. Nút đỏ là non_spam, nút xanh là spam; các nút lớn nổi bật như non_spam(728/7), non_spam(783/29) và spam(252/18) là những lá phủ nhiều mẫu.

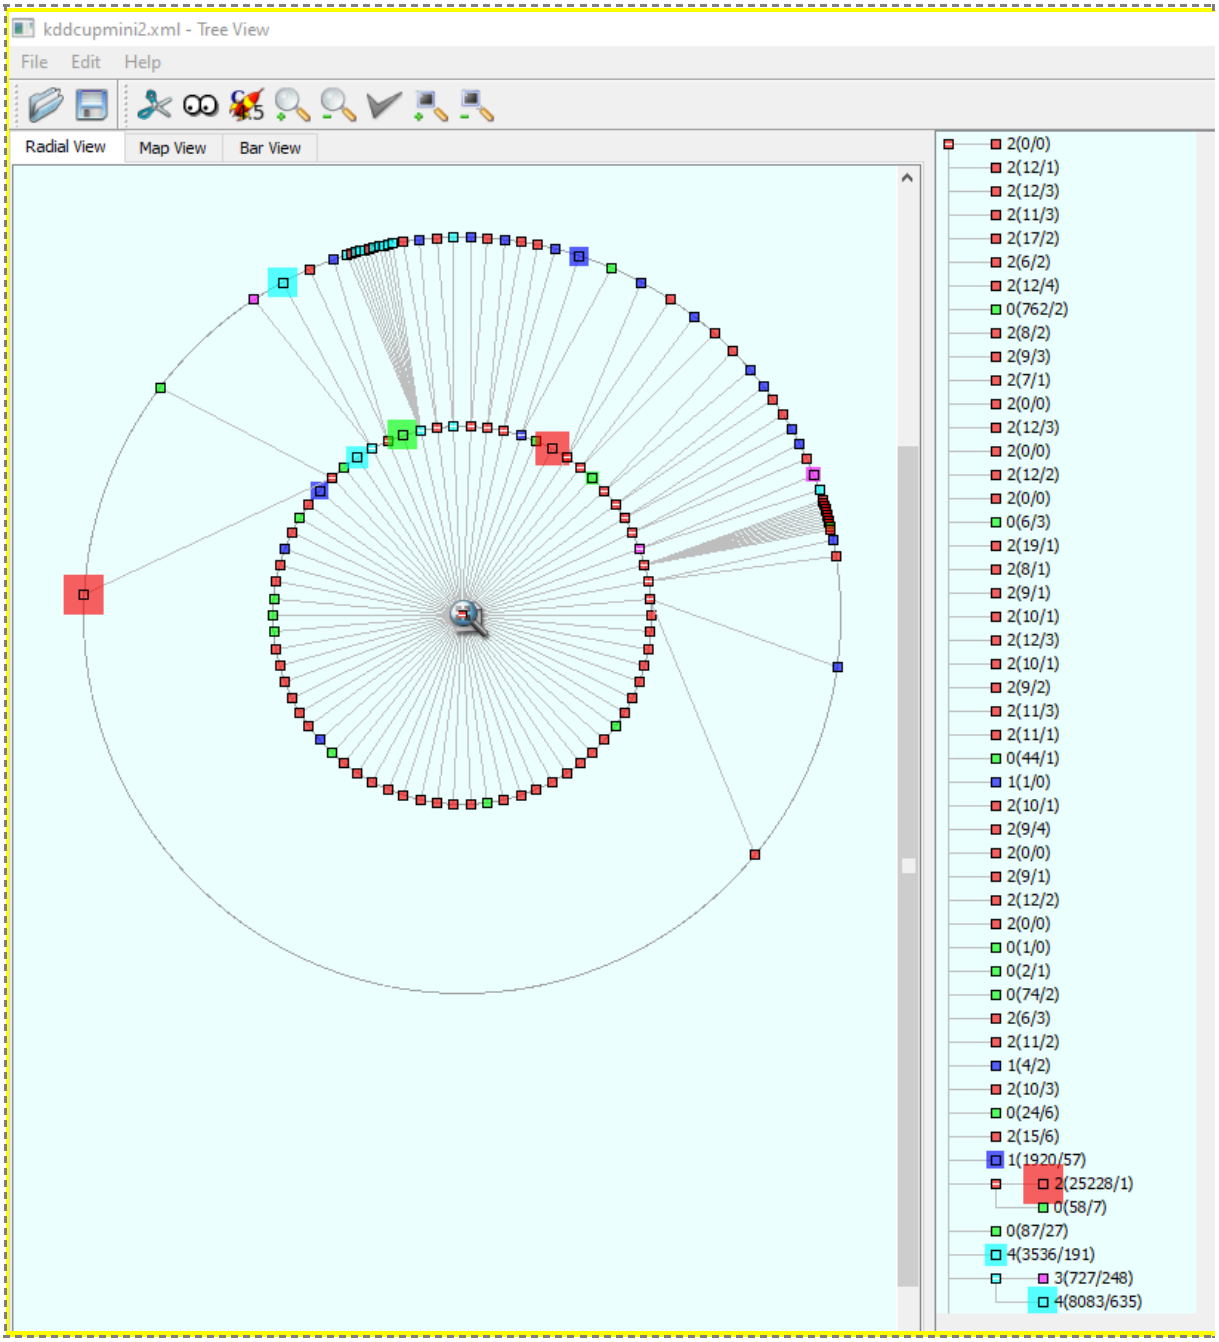


Hình 5.3. *Cây quyết định spambase_1 ở view Radial View*

Hình 5.3 là cây spambase_1 chỉ có 6 lá trên ba vòng. Có thể thấy ngay hai lá lớn nhất là non_spam(2000/201) (nút đỏ lớn) và spam(820/83) (nút xanh lớn).

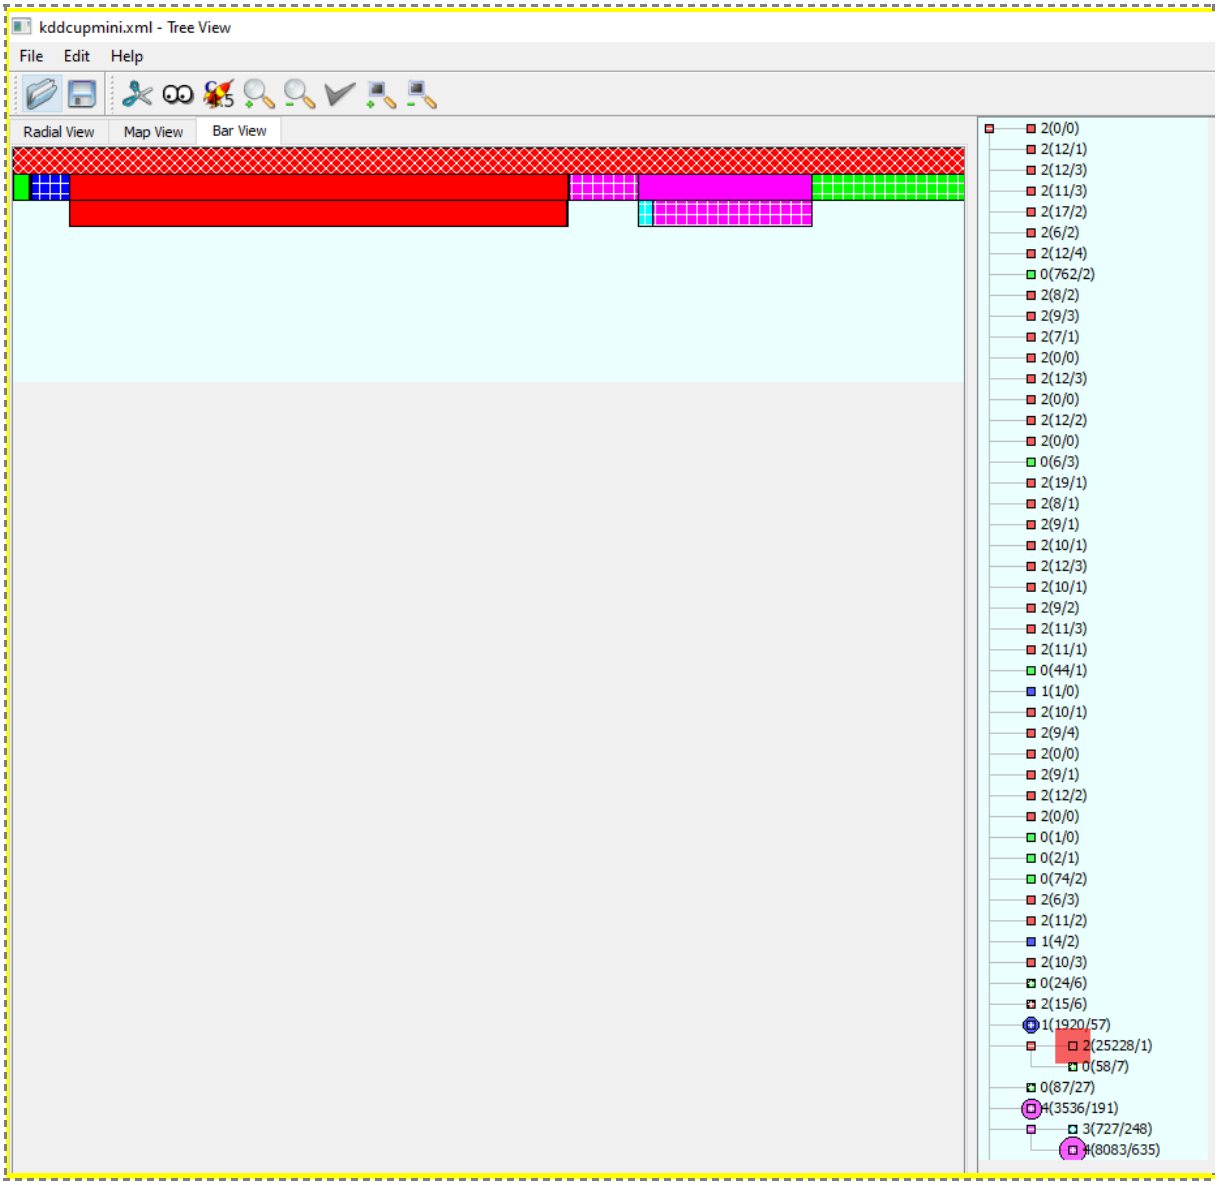


Hình 5.4. *Cây quyết định kddcup_1 1999 ở view Radial View*



Hình 5.5. *Cây quyết định kddcup_2 1999 ở view Radial View*

Hình 5.4 cho thấy 70 nhánh theo service toả ra từ gốc thành vòng đầu tiên; chỉ một số nhánh được chia tiếp ra vòng thứ hai. Các nút lớn như 2(25228/1), 1(1920/57), 4(3536/191) và 4(8083/635) tương ứng những lá phủ nhiều mẫu nhất.



Hình 5.6. *Cây quyết định kddcup_1 1999 ở view Bar View*

Hình 5.5 xếp cây thành các hàng ngang theo mức sâu; bề rộng mỗi khối tỉ lệ với số mẫu và màu mã hoá lớp. Khối đỏ (lớp 2) chiếm khoảng một nửa chiều ngang, phù hợp với việc lớp 2 chiếm 55,5% số mẫu của cây.

5.5. Trả lời các câu hỏi của đề

5.5.1. Có bao nhiêu luật quyết định?

Cây	Số nút (gồm gốc)	Số lá (= số luật)	Lá có mẫu > 0	Độ sâu	Độ chính xác	Thuộc tính được dùng
spambase_1	11	6	6	4	86,45% (3.113/3.601)	5/57

Cây	Số nút (gồm gốc)	Số lá (= số luật)	Lá có mẫu > 0	Độ sâu	Độ chính xác	Thuộc tính được dùng
kddcupmini1	155	130	98	3	93,12% (63.087/67.746)	15/41
kddcupmini2	129	108	88	2	93,05% (63.039/67.746)	13/41

Độ sâu là số điều kiện tối đa trên một đường đi từ gốc đến lá. Độ chính xác tính từ tổng items và errors của các lá (spambase_1: 488 lỗi; kddcupmini1: 4.659 lỗi; kddcupmini2: 4.707 lỗi).

Cây spambase_1 có 6 luật và cây kddcup 1999 có 130 luật (kddcupmini1) hoặc 108 luật (kddcupmini2), vì mỗi nút lá tương ứng một luật. Trong kddcup có nhiều lá rỗng (32 lá ở kddcupmini1, 20 lá ở kddcupmini2) do chia theo các giá trị danh nghĩa như flag mà không có mẫu nào rơi vào; nếu chỉ tính luật có mẫu thì còn 98 và 88 luật. Số luật phụ thuộc vào mức mở rộng hoặc tỉa của cây: cây spambase mở rộng ở Hình 5.2 có nhiều lá hơn hẳn cây 6 lá của spambase_1. Với kddcup, kddcupmini2 ít hơn kddcupmini1 khoảng 22 luật (bỏ 28 lá của eco_i, ecr_i, finger, pop_3 và smtp ở kddcupmini1, rồi thêm 6 lá gồm 2 lá của ecr_i và 4 lá đơn của eco_i, finger, pop_3, smtp) nhưng độ chính xác gần như không đổi (93,05% so với 93,12%). Điều này cho thấy phần lớn các luật bổ sung chỉ phủ rất ít mẫu: ở kddcupmini2, 66 lá có dưới 20 mẫu chỉ phủ 558 mẫu (0,8% dữ liệu).

5.5.2. Các luật quan trọng và lý do

Tiêu chí chọn luật quan trọng: (a) support lớn, phủ nhiều mẫu; (b) confidence cao, kết luận đáng tin; (c) ngắn gọn, ít điều kiện; (d) liên quan đến lớp có chi phí sai sót cao (ví dụ bỏ sót tấn công U2R/R2L, hoặc chặn nhầm thư hợp lệ); (e) có ý nghĩa nghiệp vụ, giải thích được.

Spambase: Gốc chia theo char_freq_$: 2.729 mẫu (75,8%) đi nhánh ≤ 0,055 và 872 mẫu (24,2%) đi nhánh > 0,055. Cây dùng năm thuộc tính: char_freq_$, word_freq_remove, char_freq_!, word_freq_free và word_freq_hp. Cây sai 488 mẫu, trong đó 351 thư spam bị cho là hợp lệ và 137 thư hợp lệ bị đánh dấu spam; độ chính xác của lớp spam là 88,9% (1.092/1.229) và độ phủ spam là 75,7% (1.092/1.443).

Bảng 5.1. *Các luật quan trọng của spambase*

#	**Luật (IF … THEN …)**	**Lớp**	**Support**	**Confidence**	**Độ dài**	**Lý do quan trọng**
1	IF char_freq_$ ≤ 0,055 AND word_freq_remove ≤ 0,05 AND char_freq_! ≤ 0,191 THEN …	non_spam	2.000 (55,5%)	89,95%	3	Phủ hơn một nửa dữ liệu: thư không có ký tự $, không có từ "remove" và ít dấu "!" thường hợp lệ. Cũng là lá sinh 201 lỗi (41,2% tổng lỗi), nên là nơi spam lọt lưới nhiều nhất.
2	IF char_freq_$ > 0,055 AND word_freq_hp ≤ 0,4 THEN …	spam	820 (22,8%)	89,88%	2	Luật spam lớn nhất, chỉ 2 điều kiện: nhiều ký tự $ gắn với thư quảng cáo tiền bạc.
3	IF char_freq_$ ≤ 0,055 AND word_freq_remove > 0,05 THEN …	spam	266 (7,4%)	88,72%	2	Bắt các thư spam không chứa $: từ "remove" thường xuất hiện trong lời mời gỡ khỏi danh sách của thư quảng cáo hàng loạt.
4	IF char_freq_$ ≤ 0,055 AND word_freq_remove ≤ 0,05 AND char_freq_! > 0,191 AND word_freq_free > 0,04 THEN …	spam	143 (4,0%)	83,22%	4	Kết hợp hai dấu hiệu (dấu "!" và từ "free") để bắt spam mà các luật ngắn bỏ sót; dài nhất và support nhỏ nên độ tin cậy thấp hơn.
5	IF char_freq_$ > 0,055 AND word_freq_hp > 0,4 THEN …	non_spam	52 (1,4%)	88,46%	2	Luật ngoại lệ bảo vệ thư hợp lệ: "hp" nhiều khả năng là từ đặc trưng của hộp thư công việc nơi thu thập thư hợp lệ của tập dữ liệu. Support nhỏ nhưng giúp giảm chặn nhầm thư thật, vốn tốn kém hơn bỏ sót spam.

Luật còn lại, IF char_freq_$ ≤ 0,055 AND word_freq_remove ≤ 0,05 AND char_freq_! > 0,191 AND word_freq_free ≤ 0,04 THEN non_spam (320 mẫu, 8,9%), chỉ có confidence 55,00% với 144 lỗi (29,5% tổng lỗi). Đây là luật yếu nhất: kết luận gần như ngẫu nhiên, nên là nhánh cần chia thêm bằng một thuộc tính khác. Ba luật đầu phủ 85,7% dữ liệu, cho thấy một cây rất nhỏ đã giải thích được phần lớn thư.

Kddcup 1999: Các luật dưới đây lấy từ kddcupmini2 (cây ở Hình 5.4 và 5.5). Lớp được ghi theo mã.

Bảng 5.2. *Các luật quan trọng của kddcup 1999*

#	Luật	Lớp	Support	Confidence	Độ dài	Lý do quan trọng
1	IF service = ecr_i AND src_bytes > 292 THEN …	2	25.228 (37,2%)	99,996%	2	Lá lớn nhất và gần như thuần: lưu lượng ICMP echo-reply có nhiều byte là dạng flood điển hình của tấn công từ chối dịch vụ; chỉ 1 lỗi.
2	IF service = private THEN …	2	11.936 (17,6%)	76,68%	1	Phủ lớn nhưng sai 2.783 mẫu, tức 59,1% tổng lỗi của cây. Quan trọng vì chỉ ra nơi cần chia thêm thuộc tính.
3	IF service = http THEN …	0	8.191 (12,1%)	96,25%	1	Luật "bình thường" lớn nhất; 307 lỗi (6,5% tổng lỗi) là tấn công ẩn trong lưu lượng web, loại sai sót có chi phí cao.
4	IF service = ftp_data AND src_bytes > 6 THEN …	4	8.083 (11,9%)	92,14%	2	Lá lớn thứ hai của nhóm ftp/telnet; 635 lỗi (13,5% tổng lỗi) cho thấy nhóm này còn lẫn lớp.
5	IF service = other AND src_bytes ≤ 1 THEN …	1	2.240 (3,3%)	99,60%	2	Luật thăm dò (probe) ngắn gọn và rất chính xác (gói gần như rỗng), đại diện cho lớp thiểu số cần phát hiện sớm.

Năm luật trên phủ 82,2% số mẫu. Ngoài ra có ba luật đáng chú ý. Thứ nhất, IF service = ftp_data AND src_bytes ≤ 6 THEN lớp 3 có confidence chỉ 65,89% (727 mẫu, 248 lỗi). Thứ hai, IF service = telnet AND dst_host_serror_rate ≤ 0 THEN lớp 3 có confidence 95,37% (1.339 mẫu). Hai luật này gộp lại tạo toàn bộ 310 lỗi của lớp 3, nên lớp 3 có tỉ lệ lỗi cao nhất (15,00%, Bảng 5.3). Thứ ba, ở kddcupmini1, luật IF service = eco_i AND src_bytes ≤ 24 THEN lớp 1 đạt confidence 99,95% (1.864 mẫu), tốt hơn lá eco_i chưa chia của kddcupmini2 (1.920 mẫu, 97,03%); nhờ đó lớp 1 chỉ có 41 lỗi (0,98%) so với 94 lỗi (2,22%).

Bảng 5.3. *Số mẫu và tỉ lệ lỗi theo lớp dự đoán của kddcupmini2*

Lớp	Số mẫu	Số lỗi	Tỉ lệ lỗi
0	11.444	573	5,01%
1	4.235	94	2,22%
2	37.618	2.864	7,61%
3	2.066	310	15,00%
4	12.383	866	6,99%

Nhìn chung, sáu lá có nhiều lỗi nhất (private, ftp_data > 6, http, ftp_data ≤ 6, ftp, other > 1) chiếm 92,2% tổng lỗi của kddcupmini2. Vì vậy muốn cải thiện cây cần tập trung chia thêm các lá này, không cần chia thêm các lá nhỏ.

5.5.3. View hiệu quả nhất để hiển thị cây quyết định

Đánh giá từng view theo các tiêu chí dưới đây (thang 1–5, 5 là tốt nhất), dựa trên chính các hình đã chụp (Hình 5.2 đến 5.5) và cột danh sách phân cấp ở bên phải mọi hình. Map View không có hình chụp trong báo cáo nên không được chấm điểm.

Tiêu chí	Radial View	Bar View	Danh sách phân cấp
Đọc được điều kiện chia ở từng nút	1	1	2
Thấy phân bố lớp tại nút / lá	3	4	3
Thấy kích thước nút (số mẫu)	4	5	3
Mở rộng khi cây lớn (kddcup)	3	4	2
Thấy cấu trúc phân cấp	5	3	4
Truy ra luật từ gốc đến lá	2	2	3
Tương tác (zoom, chọn, lọc)	4	4	3
Tổng điểm	22	23	20

Lựa chọn: Bar View là hiệu quả nhất, dù chênh lệch điểm nhỏ (23 so với 22 của Radial View). Lý do là các tiêu chí gắn với mục tiêu phân lớp: bề rộng khối tỉ lệ với số mẫu và màu cho biết lớp, nên chỉ nhìn một lần đã thấy lớp 2 chiếm khoảng một nửa dữ liệu kddcup và những khối nhỏ gần như không đáng xét; bố cục theo hàng ngang dùng hết chiều rộng nên cây 108 lá vẫn nằm gọn trong ba hàng, trong khi Radial View phải trải 70 nhánh quanh gốc với các nút nhỏ khó phân biệt. Hạn chế của Bar View là không hiện điều kiện chia trên khối và quan hệ cha–con khó theo dõi ở các nhánh sâu,

nên phải kết hợp với cột danh sách để đọc luật. Radial View tốt hơn khi cần nhìn hình dạng và độ sâu của cây có ít nút như spambase_1 (Hình 5.3), còn cột danh sách phù hợp khi cần đọc chính xác items/errors của từng lá. Vì không view nào hiện điều kiện chia trực tiếp, cách dùng hiệu quả nhất là Bar View để tìm lá quan trọng, sau đó tra luật trong cột danh sách.

CHƯƠNG 6. TỔNG KẾT

6.1. Tóm tắt kết quả

Bài tập	Nội dung đã thực hiện	Kết quả / phát hiện chính
Bài 1	Tám phương pháp hiển thị trên Iris, Segment, Satellite	Không có phương pháp nào tốt nhất cho mọi dữ liệu: Iris hiệu quả nhất với Matrix of scatterplot và Boxplot (setosa tách rõ, versicolor và virginica chồng lấn); Segment với Parallel coordinates và Boxplot (GRASS và SKY tách rõ, năm lớp còn lại chồng lấn); Satellite với Boxplot và Parallel coordinates có lấy mẫu (lớp 2, 3 là hai cực, lớp 1, 4, 5, 7 đan xen). Pie kém hiệu quả ở cả ba tập vì các lớp cân bằng.
Bài 2	Treemap trên dữ liệu thống kê Việt Nam	Treemap thể hiện đồng thời cấu trúc Vùng → Tỉnh, kích thước và màu trong một hình: TP. Hồ Chí Minh và Hà Nội chiếm 18,0% dân số 63 tỉnh; Đồng bằng sông Cửu Long chiếm 51,6% sản lượng lương thực. Squarified là giải thuật phù hợp nhất để đọc kích thước, Slice-and-dice cho các ô tỉnh quá mảnh; thang màu tuyến tính bị chi phối bởi giá trị ngoại lệ nên cần đổi thang hoặc chia mức màu.
Bài 3	Xây dựng trực quan cây quyết định (PBC / VisualDT)	Xây cây tương tác bằng đường cắt xiên trên ma trận scatter. Ở Iris, hai đường cắt xiên trên cặp (A1, A3) tách hoàn toàn ba lớp (lỗi 0%). Ở Segment, ô (A18, A19) tách sạch một lớp ở nút gốc, các lớp còn lại tách dần qua các cặp thuộc tính khác. Ở Satellite, mật độ điểm dày và các lớp đan xen nên chỉ cắt các cụm lớn trước và dừng ở các điểm nhiễu để tránh cây quá lớn.
Bài 4	Cây quyết định, luật và view bằng TreeView	spambase_1 có 6 luật (độ chính xác 86,45%), kddcupmini1 có 130 luật (93,12%) và kddcupmini2 có 108 luật (93,05%). Số luật giảm khoảng 22 mà độ chính xác gần như không đổi. Nhánh service = private gây 59,1% tổng lỗi của kddcupmini2, lớp 3 có tỉ lệ lỗi cao nhất (15,00%). Bar View được

		chọn là view hiệu quả nhất (23 điểm, Radial View 22) nhưng phải kết hợp với cột danh sách để đọc điều kiện chia.

6.2. Lựa chọn phương pháp trực quan theo nhiệm vụ

Nhiệm vụ phân tích	**Phương pháp đề xuất**	**Lý do**
Xem phân bố một thuộc tính	Histogram, Boxplot	Thấy hình dạng, độ phân tán, ngoại lai
Xem cơ cấu / tỉ lệ	Pie (ít hạng mục), Treemap	Biểu diễn phần trong tổng thể
Tìm quan hệ giữa hai thuộc tính	Scatter plot 2D	Thấy tương quan, cụm, tách lớp
Rà soát mọi cặp thuộc tính	Matrix of scatterplot	Tổng quan nhanh; hạn chế khi d lớn
Nhiều chiều, tìm thuộc tính phân biệt lớp	Parallel coordinates	Thấy mẫu lớp trên nhiều trục
So sánh hình dạng mẫu/lớp	Starglyph	Mã hoá toàn bộ véc-tơ vào một biểu tượng
Dữ liệu phân cấp, lớn	Treemap (Squarified để so sánh kích thước)	Dùng hết không gian, hai thuộc tính cùng lúc
Giải thích mô hình phân lớp	Cây quyết định + luật (PBC, TreeView)	Người dùng hiểu, kiểm chứng và điều khiển
Tách các lớp chồng lấn trên từng thuộc tính đơn	Ma trận scatter với đường cắt xiên (VisualDT)	Một đường thẳng trên hai thuộc tính tách được lớp mà phép chia đơn biến không tách được
Xem cây lớn nhiều lá, tìm lá quan trọng	Bar View kết hợp danh sách phân cấp (TreeView)	Bề rộng khối tỉ lệ số mẫu, màu cho biết lớp; danh sách cho điều kiện và số lỗi

6.3. Hạn chế

• Chỉ thử trên một số tập dữ liệu nhỏ và vừa: Iris, Segment và Satellite ở Bài 1 và 3, dữ liệu thống kê của 63 tỉnh ở Bài 2, hai tập spambase và kddcup ở Bài 4. Kết luận về phương pháp hiệu quả nhất chưa chắc đúng với dữ liệu có đặc điểm khác.

• Với Satellite (36 thuộc tính), Bài 1 phải chọn 8 thuộc tính theo thống kê F, nên có thể bỏ sót thuộc tính hữu ích về mặt tổ hợp; Parallel coordinates và

Starglyph dùng mẫu con nên hình dạng phụ thuộc mẫu được chọn; giá trị nguyên của Satellite gây chồng điểm.

• Treemap: thang màu tuyến tính bị chi phối bởi giá trị ngoại lệ (TP. Hồ Chí Minh) nên phần lớn ô có màu rất tối; nhãn của nút nhỏ bị cắt hoặc không hiện; nhãn lá lấy theo cột đầu của file nên tên vùng lặp lại; mỗi hình chỉ thể hiện một năm và một thuộc tính màu; dữ liệu nguồn phải tiền xử lý nhiều.

• Xây cây bằng VisualDT phụ thuộc vào người thực hiện (chọn ô thuộc tính, vẽ đường cắt) và tốn công hơn với dữ liệu dày đặc như Satellite, nên kết quả khó lặp lại chính xác và khó mở rộng cho dữ liệu rất lớn.

• Bài 4: độ chính xác của các cây tính trên chính các mẫu dùng để xây cây (spambase_1: 3.601 mẫu; kddcup: 67.746 mẫu) nên có thể lạc quan hơn trên dữ liệu kiểm tra độc lập; tệp XML của kddcup chỉ lưu mã lớp 0–4 nên tên lớp chỉ được diễn giải theo dịch vụ; Map View chưa được khảo sát bằng hình nên không được chấm điểm; thang điểm so sánh các view mang tính chủ quan của nhóm.

6.4. Hướng phát triển

• Kết hợp giảm chiều (PCA, t-SNE) trước khi trực quan để xử lý dữ liệu nhiều thuộc tính như Satellite và kddcup, thay cho việc chọn tập con thuộc tính theo thống kê F.

• Dùng tương tác brushing và linking giữa các view, ví dụ chọn một lá trong Bar View của TreeView thì đồng thời hiện điều kiện chia, số mẫu và các mẫu bị sai, để khắc phục việc không view nào hiện trực tiếp điều kiện chia.

TÀI LIỆU THAM KHẢO

1. Ankerst, M., Elsen, C., Ester, M., & Kriegel, H.-P. (1999). Visual classification: An interactive approach to decision tree construction. In *Proceedings of the 5th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '99)* (pp. 392–396). ACM.

2. Ankerst, M., Ester, M., & Kriegel, H.-P. (2000). Towards an effective cooperation of the user and the computer for classification. In *Proceedings of the 6th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD 2000)* (pp. 179–188). ACM.

3. Ankerst, M., Keim, D. A., & Kriegel, H.-P. (1996). Circle segments: A technique for visually exploring large multidimensional data sets. *Proceedings of Visualization '96, Hot Topic Session*.

4. Bederson, B. B., Shneiderman, B., & Wattenberg, M. (2002). Ordered and quantized treemaps: Making effective use of 2D space to display hierarchies. *ACM Transactions on Graphics, 21*(4), 833–854.

5. Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). *Classification and regression trees*. Wadsworth.

6. Bruls, M., Huizing, K., & van Wijk, J. J. (2000). Squarified treemaps. In *Proceedings of the Joint Eurographics and IEEE TCVG Symposium on Visualization (VisSym 2000)* (pp. 33–42).

7. Chambers, J. M., Cleveland, W. S., Kleiner, B., & Tukey, P. A. (1983). *Graphical methods for data analysis*. Wadsworth.

8. Coppersmith, D., Hong, S. J., & Hosking, J. R. M. (1999). Partitioning nominal attributes in decision trees. *Data Mining and Knowledge Discovery, 3*, 197–217.

9. Do, T.-N. (n.d.-a). *Towards simple, easy to understand, an interactive decision tree algorithm*. College of Information Technology, Can Tho University. VisualDT: http://cit.ctu.edu.vn/~dtnghi/vizdt/

10. Do, T.-N. (n.d.-b). *Tài liệu và phần mềm VisualDT, TreeView, dữ liệu spambase, kdd* [Tài liệu lớp học, Visual Data Mining]. Google Classroom.

11. Dua, D., & Graff, C. (2019). *UCI machine learning repository*. University of California, Irvine. https://archive.ics.uci.edu

12. Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics, 7*(2), 179–188.

13. Inselberg, A. (1985). The plane with parallel coordinates. *The Visual Computer, 1*(2), 69–91.

14. Johnson, B., & Shneiderman, B. (1991). Tree-maps: A space-filling approach to the visualization of hierarchical information structures. In *Proceedings of IEEE Visualization '91* (pp. 284–291).

15. Keim, D. A. (2002). Information visualization and visual data mining. *IEEE Transactions on Visualization and Computer Graphics, 8*(1), 1–8.

16. Mehta, M., Agrawal, R., & Rissanen, J. (1996). SLIQ: A fast scalable classifier for data mining. In *Proceedings of the 5th International Conference on Extending Database Technology (EDBT '96)*.

17. Michie, D., Spiegelhalter, D. J., & Taylor, C. C. (Eds.). (1994). *Machine learning, neural and statistical classification*. Ellis Horwood.

18. Shneiderman, B. (1992). Tree visualization with tree-maps: 2-d space-filling approach. *ACM Transactions on Graphics, 11*(1), 92–99.

19. Tổng cục Thống kê. (n.d.). *Số liệu thống kê*. Truy cập ngày [dd/mm/yyyy], từ https://www.gso.gov.vn/

20. Treemap, Human-Computer Interaction Lab, University of Maryland. (n.d.). http://www.cs.umd.edu/projects/hcil/treemap/

21. Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

22. XmdvTool, Worcester Polytechnic Institute. (n.d.). https://davis.wpi.edu/xmdv/vis_starglyph.shtml