CHƯƠNG 1: GIỚI THIỆU (MỤC 1.4)

Câu 1: Tại sao cuộc cách mạng kỹ thuật số những năm 1990 được xem là động lực chính dẫn đến sự ra đời và phát triển mạnh mẽ của công nghệ khai thác dữ liệu?

- Trong những năm 1990, cuộc cách mạng kỹ thuật số cho phép số hóa thông tin dễ dàng với chi phí thấp. Cùng với sự phát triển của công nghệ thông tin (phần cứng, phần mềm, công nghệ truyền thông, web, internet), máy tính đã thâm nhập sâu rộng vào các sinh hoạt thường nhật như kinh doanh, giải trí, nghiên cứu khoa học, giáo dục và truyền thông.
- Hệ quả là một khối lượng dữ liệu khổng lồ (tăng mạnh theo cấp số nhân lên quy mô Big Data) được sinh ra và tích lũy trong các kho dữ liệu, thiết bị lưu trữ. Điều này đặt ra nhu cầu cấp thiết phải có công nghệ khám phá tri thức và khai thác dữ liệu để trích xuất những thông tin, mô hình tiềm ẩn và hữu ích phục vụ cho khoa học, dự báo thảm họa tự nhiên, y tế và kinh doanh.

Câu 2: Vì sao dữ liệu dạng bảng thường khó giúp người dùng phát hiện tri thức?

- Bảng dữ liệu thô truyền thống chỉ liệt kê liên tiếp các con số và giá trị thuộc tính trên từng dòng.
- Cách liệt kê này không thể hiện trực quan được mối quan hệ giữa các đặc trưng, mức độ phân tách giữa các lớp hay các xu hướng nổi bật.
- Ngay cả chuyên gia giàu kinh nghiệm cũng khó hình dung được hình dạng phân bố của dữ liệu trong không gian hoặc phán đoán đặc trưng nào quan trọng, đặc trưng nào mang ý nghĩa phân loại mạnh nếu chỉ nhìn vào bảng số.

Câu 3: Hiển thị dữ liệu giúp người dùng khám phá cấu trúc, mẫu và quan hệ trong dữ liệu như thế nào?

- Hiển thị dữ liệu (Data Visualization) chuyển đổi dữ liệu từ dạng con số, bảng biểu sang hình ảnh, biểu đồ, đồ thị trực quan.
- Việc đưa các thuộc tính lên các không gian trực quan (như scatterplot 2D) cho phép mắt người trực tiếp quan sát cấu trúc phân bố của các điểm dữ liệu.
- Giúp nhận diện tức thì mức độ tách biệt giữa các lớp (ví dụ thấy lớp setosa tách biệt hoàn toàn so với hai lớp còn lại), phát hiện các mối quan hệ (như tương quan tuyến tính giữa petal length và petal width), đồng thời định hướng việc lựa chọn mô hình phân tách phù hợp.

Câu 4: Vai trò của người dùng trong quy trình khám phá tri thức là gì? Vì sao người dùng có kiến thức chuyên ngành nhưng không phải chuyên gia dữ liệu vẫn giữ vai trò quyết định?

- **Vai trò:** Người dùng giữ vai trò trung tâm và tham gia xuyên suốt: định hướng mục tiêu, đặt câu hỏi phân tích, tham gia tiền xử lý, lựa chọn mô hình, đánh giá, phản biện và kiểm chứng tri thức sinh ra.

- **Lý do giữ vai trò quyết định:**
    - Tri thức không được sinh ra chỉ nhờ thuật toán tính toán tự động mà là sự kết hợp giữa công cụ tính toán và hiểu biết con người.
    - Dù không chuyên về máy học hay thống kê, người dùng là chuyên gia trong lĩnh vực ứng dụng (bác sĩ, kỹ sư vận hành, chuyên gia marketing...). Chỉ có họ mới hiểu rõ bối cảnh thực tế, nhận diện được mẫu bất thường thật sự, các ràng buộc nghiệp vụ và đánh giá được mô hình có đáp ứng mục tiêu thực tiễn hay không. Một mô hình đạt độ chính xác kỹ thuật cao nhưng trái logic thực tế sẽ trở nên vô nghĩa.

Câu 5: Trình bày ba bước chính của quy trình khám phá tri thức và mô tả nội dung của từng bước.

Quy trình khám phá tri thức là một quá trình lặp phức tạp gồm 3 bước chính:

1. **Tiền xử lý (Preprocessing):** Tập hợp dữ liệu từ các nguồn khác nhau; chọn dữ liệu cần thiết (mẩu tin, trường dữ liệu); biểu diễn và chuyển đổi kiểu dữ liệu cho phù hợp với giải thuật khai thác; làm sạch dữ liệu (xử lý dữ liệu rỗng, dư thừa, không hợp lệ, tinh giảm dữ liệu).
2. **Khai thác dữ liệu (Data Mining):** Bước trung tâm nhằm khảo sát, phân tích tỉ mỉ lượng lớn dữ liệu để xây dựng các mô hình và phát hiện các mẫu/luật có ý nghĩa thông qua máy học, trí tuệ nhân tạo, phân tích thống kê đa chiều hoặc phương pháp trực quan hiển thị dữ liệu.
3. **Đánh giá kết quả (Evaluation):** Dịch, giải thích và kiểm định kết quả tri thức sinh ra dựa theo mục tiêu ban đầu của ứng dụng. Nếu kết quả chưa đạt yêu cầu, người dùng sẽ quay lại các bước trước để lặp lại quy trình.

Câu 6: Hãy nêu các nhiệm vụ chính của khai thác dữ liệu (phân lớp, hồi quy, gom nhóm, luật kết hợp) và cho ví dụ minh họa thực tế cho mỗi nhiệm vụ.

- **Phân lớp (Classification - học có giám sát):** Xây dựng mô hình phân loại dựa trên tập dữ liệu học có nhãn lớp. *Ví dụ:* Dựa vào tập thư điện tử đã gán nhãn sẵn là "thư rác" hoặc "thư bình thường" để xây dựng mô hình tự động dự báo một thư điện tử mới đến có phải thư rác hay không.
- **Hồi quy (Regression):** Xây dựng mô hình dự đoán dựa trên tập dữ liệu học có nhãn là các giá trị liên tục (số thực). *Ví dụ:* Xây dựng mô hình dự báo mực nước sông Mê Kông (kiểu số thực) dựa trên các yếu tố thời tiết, mùa.
- **Gom nhóm (Clustering - học không giám sát):** Xây dựng mô hình gom cụm dữ liệu chưa có nhãn sao cho các đối tượng trong cùng một nhóm có tính chất tương tự nhau, còn đối tượng giữa các nhóm khác nhau thì khác biệt nhau. *Ví dụ:* Gom nhóm học sinh trong một lớp sao cho các em cùng nhóm có thế mạnh học giỏi cùng ban (khoa học tự nhiên, khoa học xã hội).

- **Luật kết hợp (Association Rules):** Phát hiện mối liên quan và quy luật đồng xuất hiện giữa các biến trong dữ liệu. *Ví dụ:* Phát hiện quy luật giỏ hàng: nếu khách hàng mua bơ và bánh mì thì họ cũng mua sữa.

Câu 7: Vì sao hiển thị dữ liệu được xem là một trong những công cụ phổ biến và quan trọng trong khai thác dữ liệu?

- Theo khảo sát của KDNuggets (2018/19), hiển thị dữ liệu đứng ở vị trí phổ biến thứ tư trong các phương pháp khoa học dữ liệu và học máy.
- Hiển thị trực quan đóng vai trò cầu nối giúp con người "nhìn thấy" tri thức. Nó cung cấp công cụ tương tác mạnh mẽ giúp người dùng (ngay cả khi không chuyên sâu về toán/thống kê) có thể quan sát tổng quan dữ liệu, nhận diện xu hướng, phát hiện ngoại lệ, kiểm tra ranh giới phân lớp, tham gia điều chỉnh mô hình và giải thích kết quả, đảm bảo độ tin cậy của quy trình khai thác.

Câu 8: Tại sao quá trình khám phá tri thức cần lặp lại nhiều lần?

- Quá trình khám phá tri thức là một quá trình tương tác và lặp phức tạp. Khai thác dữ liệu đòi hỏi việc xây dựng mô hình, tạo tri thức và kiểm định lại kết quả theo mục tiêu ban đầu.
- Nếu mô hình chưa đạt yêu cầu, có độ lệch hoặc không phù hợp với thực tiễn nghiệp vụ, người phân tích bắt buộc phải quay lại các bước tiền xử lý (như làm sạch thêm, chọn lại thuộc tính) hoặc áp dụng thuật toán/tham số khai thác dữ liệu khác để tinh chỉnh cho tới khi đạt được tri thức thỏa mãn.

Câu 9: Trong ví dụ tập dữ liệu iris, từ scatterplot 2D giữa petal length và petal width, người dùng có thể rút ra những tri thức gì mà bảng dữ liệu thô không thể cung cấp?

- Nhận thấy ngay lập tức lớp **setosa** tách biệt hoàn toàn so với hai lớp còn lại (versicolor, virginica) do kích thước cánh hoa nhỏ hơn rõ rệt.
- Phát hiện mối quan hệ đồng biến, gần như tuyến tính giữa chiều dài và chiều rộng cánh hoa bên trong các lớp.
- Cung cấp gợi ý định hướng mô hình: chỉ ra rằng các mô hình phân tách tuyến tính hoặc phi tuyến đơn giản hoàn toàn có thể phân loại tốt trên tập dữ liệu này.

Câu 10: Giải thích vì sao các công cụ hiển thị trực quan dữ liệu giúp "đưa người dùng vào trong vòng lặp" của quá trình khám phá tri thức.

- Người dùng thường là chuyên gia nghiệp vụ nhưng không hiểu sâu các công thức toán, entropy hay hàm mất mát. Hiển thị trực quan đóng vai trò như chiếc cầu nối biểu diễn dữ liệu và mô hình thành hình ảnh trực quan (biểu đồ hộp, scatterplot, heatmap...).
- Nhờ vậy, người dùng có thể can thiệp vào từng công đoạn: kiểm tra dữ liệu ở bước tiền xử lý; dùng mắt quan sát mẫu để trực tiếp tham gia xây dựng cây quyết định hoặc chọn véctơ hỗ trợ; và diễn giải được lý do mô hình ra quyết định. Trực quan hóa biến người

dùng từ một người đứng ngoài nhận kết quả thụ động thành một thành phần chủ động tương tác, kiểm chứng và phản biện tri thức trong toàn bộ vòng lặp.

CHƯƠNG 2: PHƯƠNG PHÁP HIỂN THỊ DỮ LIỆU (MỤC 2.6)

Câu 1: Hãy mô tả sự khác nhau giữa biểu đồ tần suất và biểu đồ hộp trong việc thể hiện phân bố dữ liệu và nêu ví dụ loại dữ liệu phù hợp với mỗi biểu đồ.

- **Sự khác nhau:**
    - **Biểu đồ tần suất (Histogram):** Thể hiện chi tiết hình dạng phân phối của biến liên tục qua các khoảng giá trị (bins) liền kề. Cho thấy rõ các đỉnh phân phối (đơn đỉnh, đa đỉnh), độ lệch (lệch trái, lệch phải) và độ nhọn. Phù hợp cho biến số liên tục (ví dụ: phân bố thuộc tính chiều rộng cánh hoa petal width trong tập iris).
    - **Biểu đồ hộp (Boxplot):** Thể hiện tóm tắt phân bố dữ liệu qua 5 con số thống kê cô đọng: Min, Q1, Median (trung vị), Q3 và Max, cùng khoảng tứ phân vị IQR và các điểm ngoại lai (outliers) nằm ngoài râu. Boxplot không thể hiện được chi tiết cấu trúc phân bố đa đỉnh nhưng cực kỳ mạnh mẽ trong việc phát hiện điểm bất thường và so sánh phân bố giữa nhiều thuộc tính/nhóm. Phù hợp cho việc so sánh tóm tắt độ phân tán của nhiều thuộc tính (ví dụ: so sánh đồng thời 4 thuộc tính của tập iris).

Câu 2: Nhận xét về điểm thi tốt nghiệp THPT môn Toán từ biểu đồ tần suất và biểu đồ hộp (Hình trang 49):

- **Từ biểu đồ tần suất (Histogram):**
    - Phổ điểm tập trung chủ yếu trong dải điểm trung bình từ khoảng 4.0 đến 6.0 điểm, với các cột tần số cao nhất rơi vào các mốc 4.0, 4.4, 4.8 và 5.0 (nhiều mốc đạt trên 55.000 đến hơn 63.000 thí sinh).
    - Phân phối điểm có dạng phân bố tương đối chuẩn nhưng xuất hiện các bậc/răng cưa cục bộ rõ rệt tại các mức điểm chẵn và lẻ, giảm dần đều về hai phía điểm liệt (dưới 1 điểm) và điểm xuất sắc (9.0 đến 10.0).
- **Từ biểu đồ hộp (Boxplot thu nhỏ ở góc trên):**
    - Giá trị trung vị (đường gạch giữa hộp) nằm ở mức xấp xỉ 4.6 - 4.8 điểm.
    - Nửa giữa của tập dữ liệu (hộp IQR từ Q1 đến Q3) dao động trong khoảng từ khoảng 3.5 đến gần 6.0 điểm.
    - Râu biểu đồ trải dài từ sát điểm 0 đến gần điểm 9. Có sự xuất hiện của các điểm tròn ngoại lai (outliers) ở cả hai đầu cực trị: các điểm sát 0 (điểm liệt) và các điểm rất cao đạt từ trên 9.0 đến 10.0 điểm.

Câu 3: Cho tập dữ liệu nhiều chiều (ví dụ iris), hãy vẽ biểu đồ hệ trục tọa độ song song, scatter matrix và giải thích những điểm khác biệt chính giữa các nhóm quan sát, rút trích được những thông tin quan trọng gì từ những phương pháp hiển thị này.

- **Biểu đồ hệ trục tọa độ song song (Parallel coordinates):** Mỗi thuộc tính biểu diễn bằng một trục thẳng đứng song song; mỗi bông hoa là một đường gấp khúc nối qua 4 trục.
    - *Thông tin rút trích:* Các đường của lớp *setosa* tách biệt hoàn toàn ở giá trị rất thấp trên hai trục petal length và petal width. Hai lớp *versicolor* và *virginica* chồng lấn nhiều ở hai trục đài hoa (sepal length, sepal width), nhưng phân tách tương đối tốt ở hai trục cánh hoa (petal), trong đó *virginica* có giá trị cao nhất. Thuộc tính petal length cho khả năng phân tách mạnh nhất.
- **Scatterplot Matrix:** Ma trận các ô phân tán giữa từng cặp biến, đường chéo là biểu đồ tần suất của từng biến.
    - *Thông tin rút trích:* Cho cái nhìn toàn diện về mọi quan hệ song đôi. Các ô liên quan đến cặp thuộc tính cánh hoa (petal length, petal width) thể hiện tương quan đồng biến mạnh và tạo thành 3 cụm tách biệt rõ ràng. Ngược lại, các thuộc tính đài hoa (sepal) cho thấy khả năng phân tách kém do sự chồng lấn lớn giữa versicolor và virginica.

Câu 4: Nêu ưu điểm của các phương pháp hình học (scatterplot 2D, scatter matrix, parallel coordinates). Khi nào chúng không còn hiệu quả? Đề xuất hướng khắc phục khi dữ liệu lớn.

- **Ưu điểm:** Biểu diễn trực tiếp mối quan hệ không gian, tương quan đồng biến/nghịch biến, phân bố cụm tự nhiên, biên phân tách lớp và phát hiện phần tử cá biệt.
- **Khi không còn hiệu quả:**
    - Scatterplot 2D chỉ xem được 2 biến. Scatter matrix bị bùng nổ số ô khi số chiều vượt quá khoảng 20 biến (tăng theo bình phương bậc hai), gây choáng ngợp và không gian hiển thị bị thu nhỏ quá mức.
    - Khi số lượng phần tử dữ liệu quá lớn (Large N), xảy ra hiện tượng chồng lấp điểm dữ liệu (overplotting) hoặc các đường gấp khúc giao nhau chằng chịt trong parallel coordinates tạo thành khối màu rối mắt.
- **Hướng khắc phục:**
    - Dùng độ trong suốt (transparency/alpha) để giảm tác động chồng lấp.
    - Áp dụng các kỹ thuật giảm chiều dữ liệu (như PCA) để đưa dữ liệu nhiều chiều về 2-3 chiều trước khi vẽ.
    - Tích hợp các công cụ tương tác như phân vùng, chọn lọc (brushing), tô sáng (highlighting), liên kết đa khung nhìn (linking).

Câu 5: Đề xuất phương pháp hiển thị cho dữ liệu tài chính của 4 công ty (A, B, C, D) với 5 chỉ số tài chính và giải thích ưu điểm.

- **Phương pháp đề xuất:** Sử dụng **Phương pháp biểu tượng Starglyphs (Radar Glyph)** hoặc **Hệ trục tọa độ song song (Parallel Coordinates)**.

- **Ưu điểm của phương pháp đề xuất:**
    - Với *Starglyphs*: Do số lượng công ty ít (4 công ty) nhưng mỗi đối tượng có 5 thuộc tính tài chính khác nhau, Starglyphs mã hóa 5 biến thành 5 tia góc $360^{\circ}/5 = 72^{\circ}$ chuẩn hóa. Mỗi công ty tạo thành một đa giác hình ngôi sao đặc trưng. Người quản lý có thể đặt 4 hình ngôi sao cạnh nhau để so sánh trực quan toàn diện hồ sơ (profile) tài chính, nhận diện ngay công ty nào phát triển toàn diện (đa giác lớn) hay lệch về chỉ số nào mà không cần rà soát từng con số trong bảng.
    - Với *Parallel Coordinates*: Cho phép xếp 5 chỉ số tài chính lên 5 trục song song, mỗi công ty là một đường màu riêng, giúp so sánh trực tiếp thứ hạng và sự biến động giữa các chỉ số của 4 công ty.

Câu 6: So sánh trực quan hóa dữ liệu dựa trên phương pháp biểu tượng và phương pháp hình học; trường hợp nào phương pháp biểu tượng cho hiệu quả tốt hơn?

- **So sánh:**
    - *Phương pháp hình học (Scatterplot, Parallel Coordinates):* Tập trung vào không gian tọa độ và thể hiện tương quan cấu trúc, quan hệ phân bố giữa các biến hoặc sự phân tách lớp.
    - *Phương pháp biểu tượng (Glyphs, Chernoff Face, Starglyph):* Nén toàn bộ nhiều chiều của một đối tượng dữ liệu cụ thể vào một hình vẽ/biểu tượng tổng hợp duy nhất (khuôn mặt, ngôi sao...).
- **Trường hợp biểu tượng hiệu quả tốt hơn:** Khi cần so sánh, nhận dạng nhanh các "chân dung" tổng thể hoặc phát hiện mẫu tương đồng/dị biệt giữa các đối tượng riêng lẻ dựa trên trực giác nhận dạng thị giác tự nhiên của con người (ví dụ so sánh đặc điểm tội phạm giữa các bang qua mặt người Chernoff face, hoặc so sánh hồ sơ năng lực của các thực thể khi số chiều từ 5 - 15 biến và số phần tử quan sát không quá lớn).

Câu 7: Hãy chỉ ra cách treemap sử dụng giải thuật squarified layout để hiển thị dữ liệu:

- Dữ liệu cho: labels = ['Điện thoại', 'Laptop', 'Máy tính bảng', 'Phụ kiện', 'Dịch vụ'], sizes = [40, 25, 15, 12, 8] (Tổng kích thước = 100).
- **Cách thực hiện của Squarified Tree Map:**
    1. *Khởi tạo:* Gán toàn bộ không gian khung vẽ hình chữ nhật ban đầu với diện tích tổng tỷ lệ với 100.
    2. *Sắp xếp:* Dữ liệu được sắp xếp giảm dần theo kích thước (Điện thoại: 40, Laptop: 25, Máy tính bảng: 15, Phụ kiện: 12, Dịch vụ: 8).
    3. *Phân chia và tối ưu tỷ lệ cạnh (aspect ratio):* Thay vì cắt ngang hay cắt dọc toàn bộ (như Slice-and-Dice), thuật toán tiến hành xếp các phần tử vào một cạnh ngắn nhất của khung hình hiện tại sao cho các hình chữ nhật con tạo ra có tỷ lệ chiều càng gần hình vuông càng tốt (aspect ratio gần 1 nhất).

4. Phần tử lớn nhất ("Điện thoại" chiếm 40% diện tích) được đặt vào trước tạo khối vuông vắn; không gian còn lại tiếp tục được lặp đệ quy để xếp "Laptop" (25%), "Máy tính bảng" (15%), sau đó lấp đầy các ô nhỏ hơn là "Phụ kiện" (12%) và "Dịch vụ" (8%). Kết quả tạo nên bố cục các khối hình chữ nhật cân đối, trực quan và không bị quá dẹt.

Câu 8: Giải thích ưu điểm của treemap so với hiển thị theo cấu trúc cây phân cấp (explorer) khi hiển thị dữ liệu phân cấp.

- Cấu trúc cây truyền thống (explorer/node-link) chiếm rất nhiều không gian hiển thị, khi dữ liệu có độ sâu lớn hoặc hàng trăm, hàng ngàn nút thì màn hình bị tràn, phải cuộn trang nhiều lần và người dùng bị mất ngữ cảnh tổng thể. Cây explorer cũng không thể hiện trực quan được độ lớn/trọng số của các nút nếu không ghi số thủ công.
- **Ưu điểm của Treemap:** Khai thác tối đa toàn bộ không gian màn hình 2D bằng cách lồng các hình chữ nhật. Nó cho phép hiển thị từ hàng ngàn đến hàng triệu phần tử trong một khung nhìn duy nhất. Người dùng đồng thời thấy được cấu trúc phân cấp lẫn kích thước tương đối (thông qua diện tích) và thuộc tính bổ trợ (thông qua màu sắc) của từng phần tử.

Câu 9: Cho cấu trúc thư mục gồm nhiều tầng, nêu rõ thông tin trực quan có thể rút ra từ biểu đồ biểu diễn phân cấp hướng tâm (như kiểu Sunburst/Radial).

- Biểu đồ phân cấp hướng tâm biểu diễn gốc ở tâm và các cấp phân nhánh tỏa dần ra các vành khuyên bên ngoài.
- *Thông tin rút trích được:* Cung cấp cái nhìn bao quát toàn bộ độ sâu của các tầng thư mục; dễ dàng nhận diện nhánh thư mục nào chiếm dung lượng lớn nhất (dựa vào độ rộng cung tròn), nhánh nào phân nhánh nhiều tầng con phức tạp nhất, và phát hiện các thư mục rác hoặc thư mục có cấu trúc bất thường mà không làm mất đi bối cảnh toàn cục của toàn hệ thống tập tin.

Câu 10: Hãy cho biết lợi ích của các công cụ tương tác trực quan như multiple views, brushing và linking với một bảng dữ liệu trong khám phá thăm dò dữ liệu.

- **Multiple views:** Cung cấp nhiều góc nhìn khác nhau đồng thời từ cùng một bộ dữ liệu (như vừa xem phân bố bằng histogram, vừa xem tương quan bằng scatterplot) giúp bổ trợ thông tin và tránh bị phiến diện.
- **Brushing & Linking:** Cho phép người dùng trực tiếp dùng chuột quét chọn (brushing) một nhóm phần tử trên một biểu đồ, ngay lập tức hệ thống tự động đánh dấu/tô sáng (linking) chính tập phần tử đó trên tất cả các khung nhìn còn lại.
- *Lợi ích:* Duy trì tính nhất quán thông tin qua các góc nhìn, hỗ trợ kiểm tra giả thuyết, khám phá các mẫu ẩn đa chiều và giúp người dùng không chuyên vẫn có thể chủ động dẫn dắt quá trình phân tích một cách nhanh chóng.

CHƯƠNG 3: HIỂN THỊ DỮ LIỆU CHO BƯỚC TIỀN XỬ LÝ (MỤC 3.5)

Câu 1: Biểu đồ tần suất (histogram) cho biết những thông tin gì trong dữ liệu? Cho ví dụ về một tình huống histogram giúp phát hiện vấn đề trong dữ liệu.

- **Thông tin cung cấp:** Cho biết miền giá trị (thang đo), hình dạng phân bố dữ liệu (lệch trái, lệch phải, chuẩn), độ phân tán, các vùng tập trung mật độ cao/thấp, hiện tượng đa đỉnh (multimodal), và sự hiện diện của các giá trị ngoại lai.
- **Ví dụ phát hiện vấn đề:** Trong tập dữ liệu segment, quan sát histogram của các thuộc tính A3 và A7 thấy dữ liệu dồn toàn bộ vào một cột duy nhất (phương sai gần như bằng 0), cho thấy thuộc tính này không có thông tin phân biệt lớp và nên được loại bỏ. Ngoài ra, histogram của A6, A8, A9 phát hiện phân bố lệch cực mạnh và các giá trị ngoại lệ bất thường vượt trên 1000 cần phải chuẩn hóa hoặc biến đổi.

Câu 2: Vẽ biểu đồ boxplot cho một tập dữ liệu bất kỳ và nhận xét về các giá trị ngoại lệ.

- *Nhận xét dựa trên tập segment trong giáo trình (Hình 3.2):* Biểu đồ hộp thể hiện rất rõ sự phân tán và các giá trị ngoại lệ (các điểm tròn nằm ngoài hai râu). Các thuộc tính A6, A7, A8, A9 xuất hiện một lượng lớn điểm ngoại lai cực trị (ở A7 và A9 có điểm vượt quá 1000 trong khi phần lớn dữ liệu nằm sát 0). Những giá trị bất thường này sẽ làm méo ranh giới phân hoạch nếu dùng các mô hình nhạy cảm với khoảng cách như SVM tuyến tính hay kNN.

Câu 3: Scatterplot 2D có thể giúp phát hiện mối quan hệ tuyến tính giữa hai biến như thế nào?

- Bằng cách ánh xạ hai biến lên hai trục tọa độ X và Y, mỗi quan sát là một điểm.
- Nếu các điểm dữ liệu phân bố tập trung kéo dài tạo thành một dải xiên theo hướng tăng dần (hoặc giảm dần), người phân tích có thể khẳng định ngay hai biến có quan hệ đồng biến (hoặc nghịch biến) tuyến tính. (Ví dụ thuộc tính petal length và petal width trong tập iris thể hiện đường dải điểm kéo dài xiên lên rất rõ).

Câu 4: Nhận xét về mức độ phân tách dữ liệu giữa các lớp trên scatter matrix của tập segment (Hình 3.3).

- Dữ liệu segment có cấu trúc phân cụm theo lớp khá rõ trên nhiều cặp thuộc tính liên quan đến hình dạng và màu sắc.
- Một số cặp thuộc tính như (A10, A12), (A11, A12), (A14, A15) hoặc (A1, A19) thể hiện sự phân tách rất tốt, các lớp tạo thành những dải cụm màu riêng biệt.
- Ngược lại, nhiều cặp thuộc tính như (A1, A3), (A4, A5), (A7, A8) các điểm phân bố hỗn loạn, chồng lấn mạnh mẽ, chứng tỏ các thuộc tính này đứng riêng lẻ không mang thông tin phân lớp tốt.

Câu 5: Trong hệ trục tọa độ song song (parallel coordinates), dấu hiệu nào cho thấy một thuộc tính chứa nhiều nhiễu hoặc không đóng góp nhiều cho phân lớp?

- Dấu hiệu là các đường gấp khúc của tất cả các lớp khác nhau tại trục thuộc tính đó đan xen chằng chịt, giao thoa hỗn loạn và chồng lấp hoàn toàn lên nhau, không tạo ra bất kỳ

dải màu hay vùng tập trung riêng biệt nào theo từng nhãn lớp (ví dụ các trục A3, A4, A5, A7 trong Hình 3.4 của tập segment).

Câu 6: Dùng parallel coordinates, xác định thuộc tính nào khó phân tách lớp nhất trên tập dữ liệu segment và giải thích vì sao.

- Thuộc tính khó phân tách lớp nhất là **A3, A7 và A9**.
- *Giải thích:* Giá trị của phần lớn các phần tử thuộc tất cả các lớp ở các trục này hầu như hội tụ về cùng một mức (phương sai thấp hoặc thưa) hoặc bị kéo dài bất thường bởi vài điểm ngoại lệ, khiến các đường biểu diễn của 7 lớp dồn cục vào một điểm, hoàn toàn không tạo ra được bất kỳ sự phân chia ranh giới nào giữa các lớp.

Câu 7: Tại sao việc loại bỏ giá trị ngoại lệ cần phải được cân nhắc cẩn thận? Hiển thị dữ liệu giúp ích gì trong việc quyết định giữ hay loại bỏ một nhóm dữ liệu bất thường?

- **Cần cân nhắc cẩn thận vì:** Điểm ngoại lai có thể là lỗi thu thập/nhiễu, nhưng cũng có thể là tri thức tiềm ẩn mang tính đột phá hoặc các ca bệnh hiểm nghèo, gian lận tài chính quan trọng. Loại bỏ tùy tiện sẽ làm mất thông tin then chốt của bài toán.
- **Vai trò của hiển thị:** Giúp người dùng quan sát vị trí của điểm ngoại lệ trong tương quan với các thuộc tính khác và nhãn lớp. Nếu điểm đó nằm cô lập hoàn toàn do sai sót thang đo thì có thể tự tin loại bỏ; nếu nó đại diện cho một nhóm nhỏ có hành vi đặc thù thì người dùng sẽ giữ lại để phân tích riêng.

Câu 8: Phát hiện điểm trùng lặp/lệch chuẩn bằng histogram và boxplot, sau đó đề xuất chiến lược xử lý.

- *Cách phát hiện:* Dùng histogram để quan sát đuôi kéo dài sang một bên (lệch chuẩn) và boxplot để thấy các điểm nằm xa hẳn ra ngoài ranh giới râu.
- *Chiến lược xử lý theo giáo trình:*
    1. Với phân bố lệch mạnh: Áp dụng các phép biến đổi logarit (log-transform), căn bậc hai hoặc co giãn mạnh (robust scaling).
    2. Với các điểm nhiễu ngoại lai: Sử dụng kỹ thuật lọc loại bỏ các điểm bất thường.
    3. Chuẩn hóa quy tâm về cùng thang đo (đặc biệt khi chuẩn bị cho các mô hình dựa trên khoảng cách).

Câu 9: Hãy nêu ví dụ về một tập dữ liệu mà hiển thị trực quan giúp người phân tích nhận ra cần chọn mô hình tuyến tính thay vì phi tuyến.

- *Ví dụ:* **Tập dữ liệu twonorm** (20 thuộc tính, 2 lớp).
- Khi quan sát trên scatterplot matrix hoặc scatterplot 2D sau khi chiếu PCA (Hình 3.8 và Hình 3.10), hai cụm điểm của hai lớp phân bố lệch nhau theo một hướng nhất quán, tạo thành hai vùng tách biệt mà không có hiện tượng uốn lượn hay bao bọc phức tạp. Trực quan hóa chỉ ra bài toán khả tách tuyến tính, giúp người phân tích tự tin chọn mô hình

tuyến tính (như Linear SVM, Logistic Regression) vừa huấn luyện nhanh, đơn giản, vừa tránh bị quá khớp (overfitting).

Câu 10: Hiển thị trực quan có thể giúp giảm việc thử-sai khi lựa chọn mô hình học máy bằng cách nào?

- Thay vì phải thử lần lượt hàng loạt thuật toán (tuyến tính, cây, mạng nơ-ron, SVM hạt nhân phi tuyến) một cách "mù quáng", hiển thị trực quan cung cấp thông tin tức thì về hình dạng, mức độ chồng lấn và cấu trúc hình học của dữ liệu. Người phân tích "nhìn thấy" ranh giới là phẳng hay cong, đơn giản hay phức tạp, từ đó chọn ngay lớp mô hình và hàm nhân phù hợp.

Câu 11: So sánh hai tập dữ liệu twonorm và ringnorm bằng scatterplot, nhận xét về khả tách lớp và đề xuất mô hình phù hợp.

- **Tập twonorm:** Các cặp biến trên scatter matrix cho thấy hai lớp tập trung thành hai khối dải tương đối tách biệt, có xu hướng phân chia bằng một mặt phẳng. → *Khả tách tuyến tính* → Đề xuất mô hình: **Hồi quy Logistic hoặc SVM tuyến tính (Linear SVM)**.
- **Tập ringnorm:** Scatter matrix cho thấy rõ hình ảnh phân bố "một lớp ở trung tâm - một lớp bao quanh" (cấu trúc vòng - tâm). Ranh giới phân chia là các đường cong uốn lượn khép kín. → *Phi tuyến mạnh* → Đề xuất mô hình: **SVM phi tuyến (hàm nhân RBF) hoặc mạng nơ-ron nhiều lớp**.

Câu 12: PCA giữ lại thông tin quan trọng bằng cách nào? Giải thích khái niệm "cực đại hóa phương sai".

- **Cách PCA giữ thông tin:** PCA tìm một phép biến đổi tuyến tính để chiếu dữ liệu từ không gian n-chiều sang không gian mới k-chiều ($k < n$) dựa trên việc tính toán ma trận hiệp phương sai và tìm các véctơ riêng tương ứng với các giá trị riêng lớn nhất.
- **Cực đại hóa phương sai:** Trong phân tích dữ liệu, phương sai thể hiện mức độ phân tán và lượng thông tin của dữ liệu theo một hướng. Hướng nào có phương sai càng lớn thì dữ liệu càng trải rộng và càng chứa nhiều thông tin phân biệt. Cực đại hóa phương sai nghĩa là chọn các trục thành phần chính mới sao cho hình chiếu của các điểm dữ liệu trên các trục đó có độ biến thiên phân tán lớn nhất, giảm thiểu tối đa hiện tượng mất mát thông tin ban đầu.

Câu 13: Dùng PCA giảm chiều dữ liệu iris, wine, diabetes, segment xuống 2 chiều, vẽ scatterplot 2D và so sánh khả phân tách lớp trước và sau giảm chiều.

- Khi chưa giảm chiều, dữ liệu phân tán trên nhiều trục (như 4 chiều ở iris hay 19 chiều ở segment), rất khó quan sát đồng thời sự phân tách tổng thể nếu không dùng ma trận phức tạp.
- Sau khi chiếu PCA xuống 2 thành phần chính (PC1 và PC2) và biểu diễn bằng scatterplot 2D (như minh họa với tập twonorm ở Hình 3.10): Dữ liệu được cô đọng về mặt phẳng 2D nhưng vẫn bảo toàn phần lớn phương sai. Cấu trúc cụm của các lớp lộ rõ, người xem thấy rõ vùng ranh giới phân tách lớp mà không cần phải đối chiếu hàng chục biểu đồ con.

Câu 14: Khi nào cần áp dụng PCA trước khi hiển thị dữ liệu nhiều chiều?

- Khi số lượng thuộc tính trong tập dữ liệu quá lớn (thường vượt quá 20 biến), làm cho các công cụ như scatterplot matrix hay parallel coordinates bị quá tải, chiếm nhiều không gian, rối mắt và mất dần khả năng cung cấp thông tin trực quan cho người phân tích.

CHƯƠNG 4: KHAI THÁC TRỰC QUAN DỮ LIỆU (MỤC 4.4)

Câu 1: Trình bày khái niệm khai thác trực quan dữ liệu và giải thích vì sao cách tiếp cận này được xem là lấy con người làm trung tâm.

- **Khái niệm:** Khai thác trực quan dữ liệu (Visual Data Mining) là hướng tiếp cận kết hợp chặt chẽ giữa các kỹ thuật hiển thị dữ liệu trực quan, khả năng tương tác của người dùng và các thuật toán máy học/khai thác dữ liệu nhằm khám phá tri thức hữu dụng từ dữ liệu.
- **Vì sao lấy con người làm trung tâm:** Cách tiếp cận này đặt chuyên gia vào vai trò giám sát và dẫn dắt thay vì để máy học hoàn toàn tự động theo kiểu "hộp đen". Nó khai thác năng lực nhận dạng mẫu thị giác nhạy bén cùng tri thức chuyên ngành của con người để chủ động can thiệp vào quá trình học, điều chỉnh tham số, kiểm tra giả thuyết và kiểm chứng mô hình.

Câu 2: So sánh khai thác dữ liệu truyền thống và khai thác trực quan dữ liệu về vai trò của người dùng, khả năng diễn giải và độ tin cậy của mô hình.

- **Vai trò của người dùng:**
    - *Truyền thống:* Rất thụ động; chỉ cung cấp dữ liệu, đặt một vài tham số ban đầu rồi chờ máy tính trả về kết quả; không có cách nào can thiệp vào các trạng thái trung gian.
    - *Trực quan:* Người dùng giữ vai trò trung tâm, tham gia chủ động và xuyên suốt vào từng bước xây dựng mô hình.
- **Khả năng diễn giải:**
    - *Truyền thống:* Mô hình thường phức tạp, dạng "hộp đen", khó hiểu lý do đưa ra quyết định.
    - *Trực quan:* Tính trực quan cao; quy trình phân tách và hình thành mô hình được biểu diễn rõ ràng qua hình ảnh giúp người dùng hiểu sâu sắc cơ chế phân lớp.
- **Độ tin cậy:**
    - *Truyền thống:* Người dùng thiếu niềm tin vào kết quả vì không kiểm chứng được tính hợp lý bên trong mô hình.
    - *Trực quan:* Độ tin cậy cao hơn hẳn vì tri thức được tạo ra có sự tham gia, giám sát và kiểm chứng trực tiếp của chuyên gia lĩnh vực.

Câu 3: Phân tích vai trò của khả năng nhận dạng mẫu bằng thị giác trong quá trình khám phá tri thức từ dữ liệu.

- Thị giác con người có năng lực tự nhiên cực kỳ mạnh mẽ trong việc phát hiện cấu trúc không gian, cụm dữ liệu, hình dạng ranh giới, xu hướng biến thiên và các phần tử bất thường mà các phép tính toán thống kê hay hàm số tối ưu tự động rất khó mô tả toàn diện. Khi dữ liệu được trực quan hóa, mắt người nhận biết ngay các điểm phân hoạch tốt, các dải thuần nhất hoặc các mẫu hình phân tách mà không cần thông qua các công thức toán phức tạp.

Câu 4: Thế nào là tiếp cận hợp tác trong khai thác trực quan dữ liệu? Nêu các lợi ích và thách thức của cách tiếp cận này.

- **Định nghĩa:** Là sự phối hợp tương tác giữa người dùng và hệ thống máy tính, trong đó kết hợp thế mạnh của con người (nhận dạng mẫu trực quan, tri thức chuyên gia, suy luận logic) với sức mạnh tính toán của máy tính (xử lý khối lượng dữ liệu lớn, tính toán tối ưu, tự động đề xuất phân hoạch).
- **Lợi ích:** Mô hình sinh ra nhỏ gọn, dễ hiểu hơn; hạn chế được hiện tượng học vẹt (overfitting); nâng cao độ tin cậy và khả năng diễn giải; rút ngắn thời gian thử-sai dò tìm tham số.
- **Thách thức:** Nếu làm thủ công hoàn toàn khi dữ liệu lớn sẽ tốn thời gian và công sức người dùng; việc phân chia mức độ can thiệp giữa người và máy đòi hỏi thiết kế giao diện tương tác và thuật toán phức tạp.

Câu 5: Mô tả nguyên lý xây dựng cây quyết định tương tác. Người dùng có thể can thiệp vào những bước nào của quá trình xây dựng cây?

- **Nguyên lý:** Dữ liệu huấn luyện tại nút đang xét được sắp xếp và hiển thị trực quan (ví dụ dạng thanh chữ nhật tô màu theo lớp). Người dùng trực quan quan sát các dải màu để xác định thuộc tính và điểm chia tách, hệ thống mở rộng cây tương ứng và tiếp tục đệ quy cho các nút con.
- **Các bước người dùng có thể can thiệp:**
    1. Chọn thuộc tính và tự do xác định điểm phân hoạch (hỗ trợ cả phân hoạch đa điểm n-ary).
    2. Gán nhãn lớp cho nút hiện hành để tạo nút lá.
    3. Chọn quay lại hoặc xóa một nút bất kỳ đã tạo để tái cấu trúc cây.
    4. Yêu cầu hệ thống tự động đề xuất thuộc tính và điểm phân hoạch tối ưu.
    5. Yêu cầu hệ thống xem trước phát triển cây (look-ahead) hoặc tự động mở rộng toàn bộ cây con tại nút đó.

Câu 6: Phân tích ưu điểm của giải thuật xây dựng cây quyết định tương tác (PBC) so với cây quyết định xây dựng hoàn toàn tự động (CART, C4.5).

- PBC cho phép thực hiện **phân hoạch đa điểm (n-ary)** tại một nút thay vì chỉ phân hoạch nhị phân bắt buộc như CART, giúp tạo ra các nút con thuần nhất ngay lập tức và giảm kích thước cây.

- Người dùng có thể linh hoạt quay lại sửa nút sai ở bất kỳ nhánh nào mà không bị ràng buộc bởi chiến lược tìm kiếm háu ăn (greedy) một chiều của thuật toán tự động.
- Tích hợp được tri thức chuyên ngành, giúp cây nhỏ gọn hơn đáng kể (thường chỉ bằng $1/2$ đến $1/3$ kích thước của CART) nhưng vẫn duy trì độ chính xác tương đương hoặc cạnh tranh, làm cho mô hình rất dễ diễn giải.

Câu 7: Trình bày ý tưởng chính của Viz-SVM và vai trò của trực quan hóa trong việc hiểu và điều chỉnh mô hình SVM.

- **Ý tưởng chính:** Đưa con người vào trung tâm quy trình học của SVM thông qua môi trường hiển thị nhiều khung nhìn liên kết (multiple views, linking, brushing giữa scatterplot matrix và parallel coordinates). Người dùng trực tiếp quan sát cấu trúc dữ liệu, dùng chuột chọn các ứng viên véctơ hỗ trợ nằm gần ranh giới phân tách lớp để đưa vào giải thuật tối ưu RSVM.
- **Vai trò của trực quan hóa:**
    - Biến đổi khái niệm siêu phẳng trừu tượng thành trực quan.
    - Giúp người dùng thấy được độ phức tạp hình học của ranh giới (thẳng hay cong) để chọn đúng loại hàm nhân (kernel tuyến tính hay phi tuyến).
    - Định hướng việc chọn tham số γ của hàm RBF một cách có cơ sở (ranh giới đơn giản thì chọn γ nhỏ, ranh giới phức tạp thì tăng γ) thay vì phải dò tìm tham số mù quáng.

Câu 8: So sánh Viz-SVM và SVM truyền thống về khả năng diễn giải mô hình và sự tham gia của người dùng.

- **SVM truyền thống (như LibSVM):** Hoạt động hoàn toàn tự động như một "hộp đen". Người dùng không thể can thiệp trong quá trình học, chỉ nhận được các kết quả đầu ra khô khan (tập véctơ hỗ trợ, độ chính xác) mà không hiểu vì sao mô hình ra quyết định như vậy hoặc các véctơ hỗ trợ có thực sự nằm ở ranh giới hay không.
- **Viz-SVM:** Người dùng trực tiếp quan sát không gian dữ liệu, tự tay chọn các véctơ biên và tham số dựa trên hình ảnh trực quan. Do đó, người dùng hiểu sâu sắc ranh giới phân tách được hình thành như thế nào, tăng cường tính minh bạch, khả năng giải thích và độ tin cậy vào kết quả phân lớp.

Câu 9: Trình bày nguyên lý của giải thuật OPTICS và vai trò của biểu đồ reachability trong việc phát hiện cấu trúc cụm.

- **Nguyên lý của OPTICS:** Dựa trên nhận xét rằng với $MinPts$ cố định, các cụm có mật độ cao (ε nhỏ) luôn nằm lọt bên trong các cụm có mật độ thấp hơn (ε lớn). Thuật toán không gán nhãn cụm cứng ngay từ đầu mà duyệt qua các điểm để tạo ra một **thứ tự xử lý điểm dữ liệu (cluster-ordering)** kèm theo hai đại lượng: khoảng cách cốt lõi (*core-distance*) và khoảng cách khả tiếp cận (*reachability-distance*).

- **Vai trò của biểu đồ reachability:** Biểu diễn thứ tự các điểm trên trục hoành và khoảng cách khả tiếp cận tương ứng trên trục tung.
    - Các vùng trũng dạng "thung lũng" trên biểu đồ đại diện cho các cụm dữ liệu đậm đặc.
    - Các "đỉnh cao" thể hiện vùng thưa hoặc ranh giới ngăn cách giữa các cụm.
    - Người dùng có thể thay đổi ngưỡng cắt theo trục tung để nhận diện các cụm lồng nhau ở nhiều mức độ mật độ khác nhau mà không cần chạy lại thuật toán.

Câu 10: So sánh OPTICS với DBSCAN trong bối cảnh khai thác trực quan dữ liệu.

- **DBSCAN:** Yêu cầu người dùng thiết lập cứng hai tham số toàn cục là ε và $MinPts$. Kết quả chỉ cho một phương án phân cụm duy nhất ở mức mật độ cố định đó; không thể phát hiện các cụm có mật độ biến thiên hoặc cụm phân cấp lồng nhau, rất khó tương tác.
- **OPTICS:** Không yêu cầu chọn trước một giá trị ε tối ưu. Nó xuất ra biểu đồ khả tiếp cận (reachability plot) trực quan, cho phép người phân tích dùng mắt nhận diện cấu trúc cụm có hình dạng bất kỳ và tương tác kéo thanh ngưỡng cắt để trích xuất cấu trúc cụm ở nhiều mức phân cấp linh hoạt.

Câu 11: Mô tả các quyết định can thiệp của người dùng trong quá trình xây dựng cây quyết định tương tác trên tập iris và segment.

- *Trên tập Iris:* Người dùng quan sát thanh chữ nhật của 4 thuộc tính; thấy thuộc tính *petal length* hoặc *petal width* có dải màu của lớp *setosa* tách biệt hoàn toàn → Người dùng quyết định chọn ngay thuộc tính này làm nút gốc và đặt điểm chia tách để phân lập ngay nhánh lá *setosa* thuần nhất. Với hai lớp còn lại chồng lấn nhẹ, người dùng chọn tiếp thuộc tính cánh hoa thứ hai để phân chia.
- *Trên tập Segment:* Quan sát 19 thuộc tính, người dùng nhận thấy A3, A7 không có khả năng phân tách nên chủ động bỏ qua. Người dùng ưu tiên chọn các thuộc tính có dải màu dài liên tục như nhóm A10, A11, A12 để đặt các điểm phân hoạch đa điểm, nhanh chóng tách các lớp thuần nhất như lớp 2 (sky) ra khỏi dữ liệu.

Câu 12: Áp dụng OPTICS cho tập iris, segment; vẽ biểu đồ khả tiếp cận và phân tích cấu trúc cụm thu được.

- Khi chạy giải thuật OPTICS trên tập dữ liệu:
    - Biểu đồ khả tiếp cận xuất hiện các thung lũng rõ rệt.
    - *Trên tập Iris:* Biểu đồ hiển thị một thung lũng sâu, tách biệt hoàn toàn ứng với cụm các điểm hoa *setosa* (do mật độ rất dày và khoảng cách nhỏ), tiếp theo là một đỉnh nhô cao rồi chuyển sang một vùng thung lũng rộng hơn nhưng có đáy gồ ghề hơn chứa hai lớp *versicolor* và *virginica* lồng nhau.
    - *Trên tập Segment:* Xuất hiện nhiều thung lũng tương ứng với các vùng ảnh đồng nhất (như vùng trời - sky, mặt cỏ - grass) nằm sâu bên dưới, ngăn cách bởi các đỉnh nhọn thể hiện ranh giới chuyển tiếp giữa các lớp ảnh tự nhiên.

Câu 13: Thảo luận vai trò của tri thức chuyên gia trong khai thác trực quan dữ liệu. Trong những trường hợp nào sự can thiệp của con người có thể làm giảm chất lượng mô hình?

- **Vai trò:** Giúp định hình bài toán, nhận diện biến quan trọng, loại bỏ nhiễu, hạn chế tình trạng học vẹt và kiểm chứng xem tri thức có phù hợp với thực tiễn ứng dụng hay không.
- **Trường hợp làm giảm chất lượng:**
    - Khi con người mang định kiến chủ quan sai lệch về dữ liệu, cố tình ép đặt các điểm phân hoạch hoặc chọn các thuộc tính không phản ánh bản chất khách quan.
    - Khi đối mặt với không gian quá nhiều chiều phức tạp vượt quá khả năng nhận biết thị giác, việc lựa chọn thủ công các điểm ranh giới có thể bị sót các vùng phân tách tinh vi (như thực nghiệm trên tập segment và satimage trong Bảng 4.6, Viz-SVM thấp hơn LibSVM khoảng 1%).

Câu 14: Khai thác trực quan dữ liệu phù hợp nhất với những loại bài toán và tập dữ liệu nào? Đề xuất hướng mở rộng ứng dụng thực tế.

- **Loại bài toán phù hợp:** Các bài toán phân tích đòi hỏi tính minh bạch, dễ hiểu và yêu cầu an toàn cao như chẩn đoán y tế, phát hiện gian lận tài chính, đánh giá rủi ro ngân hàng, phân tích ảnh viễn thám và an ninh hệ thống. Phù hợp với các tập dữ liệu có cấu trúc phân cụm phức tạp, ranh giới phi tuyến hoặc dữ liệu chứa nhiều nhiễu cần chuyên gia làm sạch.
- **Hướng mở rộng thực tế:** Tích hợp thành các môi trường lập trình luồng dữ liệu trực quan hoàn chỉnh (như công cụ V4Miner), kết hợp với học máy giải thích được (XAI) và các hệ thống tương tác người-máy trong thời gian thực để hỗ trợ ra quyết định lâm sàng hoặc điều hành doanh nghiệp.

CHƯƠNG 5: HIỂN THỊ DỮ LIỆU CHO GIẢI THÍCH KẾT QUẢ (MỤC 5.6)

Câu 1: Trình bày vai trò của hiển thị dữ liệu trong việc giải thích kết quả của các mô hình khai phá dữ liệu và máy học. Vì sao trực quan hóa đặc biệt quan trọng đối với các mô hình "hộp đen"?

- **Vai trò:** Giúp người phân tích hiểu rõ cấu trúc mô hình, cơ chế hoạt động, mối quan hệ giữa dữ liệu đầu vào và kết quả dự đoán; hỗ trợ "nhìn thấy" quá trình suy luận, phát hiện các giả định bất hợp lý và kiểm chứng mức độ tin cậy của tri thức trước khi ứng dụng.
- **Vì sao quan trọng với mô hình "hộp đen":** Các mô hình như SVM phi tuyến hay mạng nơ-ron sâu đạt độ chính xác rất cao nhưng con người không thể hiểu vì sao mô hình đưa ra dự đoán đó. Trong các lĩnh vực rủi ro cao (y tế, tài chính, an ninh), một dự đoán không có lời giải thích thuyết phục sẽ không thể chấp nhận được và dễ gây ra quyết định sai lầm. Trực quan hóa giúp "mở hộp đen", chiếu sáng ranh giới quyết định và chỉ ra mức độ đóng góp của từng thuộc tính.

Câu 2: So sánh khả năng giải thích của mô hình cây quyết định với các mô hình như SVM hoặc mạng nơ-ron. Vai trò của Tree-view trong việc nâng cao tính minh bạch của cây quyết định là gì?

- **So sánh:**
    - Cây quyết định vốn có cấu trúc phân cấp tường minh, biểu diễn dưới dạng các luật "NẾU - THÌ" rất dễ hiểu và tự nhiên đối với con người.
    - Ngược lại, SVM hay mạng nơ-ron dựa trên các siêu phẳng nhiều chiều và trọng số phi tuyến ma trận phức tạp, người dùng không thể tự diễn giải trực tiếp.
- **Vai trò của Tree-view:** Khi cây quyết định quá lớn (hàng trăm, hàng ngàn nút), ưu điểm dễ hiểu truyền thống bị phá vỡ. Tree-view cung cấp nhiều kỹ thuật hiển thị tiên tiến (explorer, radial, phân cấp đa khung nhìn) kết hợp chức năng tương tác (phóng to, thu gọn, cắt nhánh), giúp người dùng dễ dàng theo dõi toàn bộ cây lớn, trích xuất tức thì các luật quyết định và đánh giá độ tin cậy của từng nút lá.

Câu 3: Trình bày những thông tin chính có thể được rút ra từ một Tree-view của cây quyết định (độ sâu cây, số nút, thuộc tính phân tách, nhãn lớp, v.v.).

Từ Tree-view, người dùng có thể rút trích:

- Cấu trúc phân cấp, độ sâu của cây và tổng số nút.
- Thuộc tính phân tách và ngưỡng điều kiện tại mỗi nút rẽ nhánh dọc theo đường đi từ gốc đến lá.
- Nhãn phân lớp dự đoán tại các nút lá.
- Kích thước của nút (số lượng phần tử huấn luyện rơi vào nút đó).
- Độ tinh khiết, phân bố lớp và số lượng phần tử bị phân lớp sai (lỗi) tại nút, giúp xác định mức độ tin cậy của luật quyết định.

Câu 4: Vì sao mô hình SVM được xem là khó giải thích? Vis-SVM giải quyết những hạn chế này như thế nào thông qua hiển thị?

- **Khó giải thích vì:** SVM chỉ trả về một tập các véctơ hỗ trợ, hàm nhân và hệ số toán học trừu tượng. Người dùng không thể hình dung được hình dạng ranh giới phân lớp trong không gian nhiều chiều hay biết được thuộc tính nào quyết định việc phân loại.
- **Cách Vis-SVM giải quyết:** Chuyển trọng tâm từ việc hiển thị siêu phẳng trừu tượng sang **phân tích phân bố dữ liệu dựa trên khoảng cách tới siêu phẳng** (Hình 5.8). Kết hợp kỹ thuật linking và brushing từ các cột phân bố khoảng cách đến scatterplot matrix và parallel coordinates, giúp người dùng trực tiếp quan sát thấy các điểm biên quyết định và nhận diện các chiều thuộc tính có mức đóng góp phân tách lớn nhất vào mô hình.

Câu 5: So sánh cách tiếp cận giải thích toàn cục (global explanation) và cục bộ (local explanation). Tree-view, Vis-SVM và LIME thuộc loại nào? Giải thích lý do.

- **So sánh:**
    - *Giải thích toàn cục:* Mô tả toàn bộ hành vi, cấu trúc tổng thể của mô hình trên toàn bộ không gian dữ liệu.

- *Giải thích cục bộ:* Chỉ tập trung giải thích lý do mô hình đưa ra quyết định cho **một phần tử dữ liệu kiểm tra cụ thể** tại một thời điểm, bằng cách xấp xỉ hành vi trong vùng lân cận của phần tử đó.

- **Phân loại và lý do:**
  - **Tree-view:** Thuộc loại **Giải thích toàn cục** (mô tả toàn bộ cấu trúc phân nhánh của cả cây từ nút gốc đến tất cả các nút lá).
  - **Vis-SVM:** Thuộc loại **Giải thích toàn cục** (thể hiện phân bố toàn bộ dữ liệu đối với siêu phẳng phân lớp hoặc siêu cầu bao bọc).
  - **LIME:** Thuộc loại **Giải thích cục bộ** (*Local Interpretable Model-agnostic Explanations* - LIME xây dựng một mô hình thay thế đơn giản chỉ xung quanh vùng lân cận của điểm cần kiểm tra x).

Câu 6: Phân tích ưu và nhược điểm của LIME khi áp dụng cho các mô hình học máy phức tạp như SVM hoặc mạng nơ-ron sâu.

- **Ưu điểm:**
  - Độc lập với mô hình (model-agnostic): có thể giải thích cho bất kỳ mô hình "hộp đen" nào mà không cần can thiệp hay thay đổi cấu trúc bên trong.
  - Lời giải thích trực quan, dễ hiểu (dưới dạng biểu đồ thanh thể hiện trọng số đóng góp của từng thuộc tính cho kết quả dự đoán).
  - Áp dụng tốt cho nhiều dạng dữ liệu: dữ liệu bảng, văn bản và hình ảnh (super-pixel).
- **Nhược điểm:**
  - Phụ thuộc nhiều vào phương pháp sinh mẫu nhân tạo ngẫu nhiên (perturbation) và cách định nghĩa khoảng cách lân cận, dẫn đến kết quả giải thích có thể không ổn định giữa các lần chạy khác nhau.
  - Giải thích cục bộ không đảm bảo phản ánh đúng hành vi toàn cục của toàn bộ mô hình gốc.

Câu 7: So sánh Twokey plot với các cách liệt kê luật kết hợp truyền thống (dạng bảng). Twokey plot hỗ trợ người dùng tốt hơn ở những khía cạnh nào?

- **So sánh:** Dạng bảng truyền thống chỉ liệt kê danh sách tuyến tính hàng ngàn dòng luật với các con số support và confidence rời rạc, làm người dùng bị quá tải và rất dễ bỏ sót các luật thú vị.
- **Twokey plot hỗ trợ tốt hơn ở các khía cạnh:**
  - Thể hiện toàn bộ tập luật lên một biểu đồ phân tán 2 chiều (trục hoành là *support*, trục tung là *confidence*).

- Cho cái nhìn toàn cảnh về phân bố, phát hiện nhanh các cụm luật, dải luật hoặc các luật cá biệt.
- Khắc phục nghịch lý luật hiển nhiên (luật có support và confidence cực đại thường là luật hiển nhiên, ít giá trị), giúp người dùng dễ dàng khoanh vùng các luật nằm ở vùng trung gian có giá trị tri thức thực sự.
- Khai thác trực quan cấu trúc quan hệ tổ tiên - hậu duệ giữa các luật thông qua đoạn thẳng nối.

Câu 8: Trình bày sự khác biệt giữa giải thích dựa trên cấu trúc mô hình (model-based explanation) và giải thích dựa trên mô hình xấp xỉ (surrogate model).

- **Giải thích dựa trên cấu trúc mô hình (Model-based):** Khai thác trực tiếp cấu trúc nội tại vốn có của chính mô hình đó để giải thích (ví dụ trích xuất đường đi các nhánh điều kiện trong cây quyết định thông qua Tree-view).
- **Giải thích dựa trên mô hình xấp xỉ (Surrogate model):** Coi mô hình gốc là một hộp đen hoàn toàn; sử dụng một mô hình thứ hai có bản chất đơn giản, dễ giải thích (như hồi quy tuyến tính, cây quyết định nông) được huấn luyện để mô phỏng/xấp xỉ hành vi dự đoán của mô hình gốc trong một phạm vi xác định (như cách LIME huấn luyện mô hình xấp xỉ trên tập dữ liệu sinh xung quanh điểm cần kiểm tra).

Câu 9: Phân tích mối quan hệ giữa trực quan hóa và tương tác trong việc khám phá tri thức từ dữ liệu.

- Trực quan hóa và tương tác là hai yếu tố gắn liền mật thiết không thể tách rời.
- Trực quan hóa cung cấp hình ảnh biểu diễn dữ liệu và mô hình để con người quan sát.
- Tương tác (như lọc, phóng to, thu nhỏ, brushing, xoay, thay đổi tham số) cho phép người dùng tác động ngược lại hệ thống, đặt câu hỏi, kiểm tra các kịch bản giả thuyết và điều chỉnh quy trình.
- Sự kết hợp này tạo thành một vòng lặp kín giúp khuếch đại năng lực suy luận phân tích của con người, biến việc xem kết quả tĩnh thành một quá trình khám phá tri thức chủ động và sâu sắc.

Câu 10: Phân tích một đường đi từ nút gốc đến lá trên Tree-view và giải thích ý nghĩa từng điều kiện và quyết định phân lớp (Hình 5.2).

- Trong Hình 5.2 của giáo trình (tập dữ liệu shuttle):
  - Đường đi từ gốc đến nút lá được rút trích thành luật "NẾU - THÌ":

    IF $(A1 > 54)$ AND $(A9 \leq 2)$ AND $(A1 \leq 66)$ THEN $class = 1$

  - *Ý nghĩa điều kiện:* Một phần tử dữ liệu nếu thỏa mãn đồng thời thuộc tính A1 lớn hơn 54, thuộc tính A9 nhỏ hơn hoặc bằng 2, và thuộc tính A1 tiếp tục bị chặn trên nhỏ hơn hoặc bằng 66.

- *Quyết định phân lớp và thống kê:* Mẫu sẽ được phân loại vào **Lớp 1 (class = 1)**. Tại nút lá này, có tổng cộng **2960 phần tử** huấn luyện thỏa mãn, trong đó chỉ có duy nhất **1 lỗi** (tỷ lệ lỗi cực thấp: 0.03378%), chứng minh đây là một luật quyết định có độ tin cậy rất cao.

Câu 11: Minh họa biên quyết định và các véctơ hỗ trợ cho SVM tuyến tính trên tập iris; nhận xét mối quan hệ giữa chúng và kết quả phân lớp.

- Khi áp dụng SVM tuyến tính để tách lớp *setosa* ra khỏi các lớp còn lại trên tập Iris:
- *Minh họa & Nhận xét:* Siêu phẳng quyết định là một đường thẳng nằm lọt vào khoảng trống phân cách cực đại giữa cụm điểm *setosa* và cụm điểm *versicolor/virginica*. Các điểm nằm sát hai đường biên lề hỗ trợ song song với siêu phẳng chính là các **véctơ hỗ trợ (support vectors)**. Toàn bộ phương trình siêu phẳng phân lớp chỉ được quyết định bởi số ít các véctơ hỗ trợ này, các điểm hoa nằm xa biên hoàn toàn không ảnh hưởng đến vị trí siêu phẳng. Kết quả phân lớp hoàn hảo do lớp *setosa* khả tách tuyến tính tuyệt đối.

Câu 12: Áp dụng LIME giải thích dự đoán của mô hình phân lớp SVM hoặc Random Forest cho tập dữ liệu iris/segment; phân tích vai trò của các thuộc tính quan trọng nhất.

- Khi mô hình đưa ra dự đoán nhãn lớp cho một mẫu x cụ thể, LIME sinh các biến thể xung quanh x và vẽ biểu đồ thanh ngang thể hiện trọng số đóng góp của từng biến (như minh họa ở Hình 5.14):
- *Vai trò thuộc tính:* Biểu đồ LIME chỉ ra rõ ràng thuộc tính nào ủng hộ dự đoán (thanh màu xanh/hướng dương) và thuộc tính nào phản đối (thanh hướng âm). Chẳng hạn với tập iris, thuộc tính *petal length* và *petal width* sẽ có chiều dài thanh vượt trội, khẳng định đây là hai đặc trưng quyết định khiến mô hình dự đoán mẫu x rơi vào lớp hoa tương ứng.

Câu 13: Xây dựng Twokey plot cho tập luật kết hợp; nhận xét về sự phân bố và các vùng luật đáng quan tâm.

- Trên đồ thị tọa độ $Support \times Confidence$ của Twokey plot (Hình 5.15):
  - Các luật có $Support$ rất cao thường có $Confidence$ vừa phải và nằm dồn về phía góc dưới bên phải.
  - Vùng góc trên bên phải (Support cao, Confidence cao) thường chứa rất ít luật hoặc là các luật hiển nhiên, ít mang lại giá trị kinh doanh mới.
  - **Vùng luật đáng quan tâm nhất:** Là **vùng trung gian** (Support ở mức vừa đủ, thường từ 0.1 đến 0.4, nhưng có Confidence rất cao từ 0.8 đến 1.0). Đây chính là nơi chứa đựng các tri thức tiềm ẩn, bất ngờ nhưng có độ tin cậy vững chắc để triển khai các chiến lược tiếp thị giỏ hàng.

Câu 14: Đề xuất một kịch bản thực tế (y tế, giáo dục, thương mại điện tử, an ninh mạng...) trong đó hiển thị dữ liệu đóng vai trò then chốt trong việc giải thích và ra quyết định dựa trên mô hình máy học tự động.

- **Kịch bản đề xuất trong Y tế (Hỗ trợ chẩn đoán bệnh sớm):**

- *Bối cảnh:* Một mô hình học sâu hoặc SVM phi tuyến được huấn luyện để phân loại bệnh nhân có nguy cơ mắc bệnh ung thư hoặc bệnh hiểm nghèo từ hồ sơ xét nghiệm máu và hình ảnh y khoa.
- *Vấn đề:* Bác sĩ không thể tiếp nhận một kết luận dự đoán xác suất "nguy cơ 98%" từ mô hình hộp đen mà không có lý do chuyên môn rõ ràng để chỉ định phác đồ điều trị.
- *Vai trò then chốt của hiển thị dữ liệu (Human-in-the-Loop):*
    1. Hệ thống sử dụng **LIME** để trực quan hóa giải thích cục bộ cho từng bệnh nhân: hiển thị biểu đồ thanh chỉ ra rằng nồng độ chỉ số sinh hóa X và protein Y vượt ngưỡng chính là hai yếu tố mang trọng số quyết định cao nhất.
    2. Sử dụng **Tree-view** rút trích luật phân loại dưới dạng "NẾU chỉ số X > a VÀ chỉ số Y > b THÌ nguy cơ cao".
    3. Bác sĩ đối chiếu các hình ảnh trực quan này với kiến thức y khoa để kiểm chứng tính logic. Trực quan hóa giúp bác sĩ hiểu rõ cơ chế, tin tưởng vào mô hình và đưa ra quyết định can thiệp điều trị chính xác, an toàn cho người bệnh.